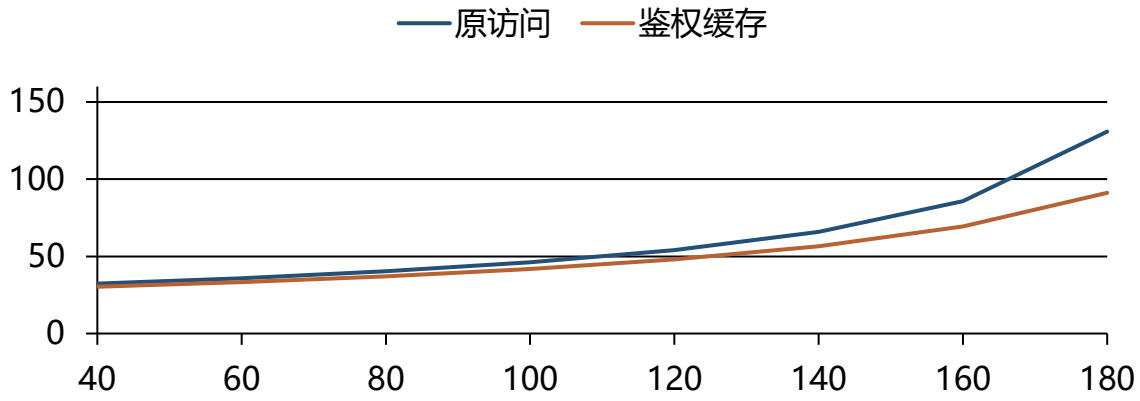
模拟网络：鉴权缓存降低高负载排队延迟

A 负载—延迟：缓存降低高负载排队

均值 ms / 请求率 次·秒⁻¹；鉴权访问比 0.90→0.65

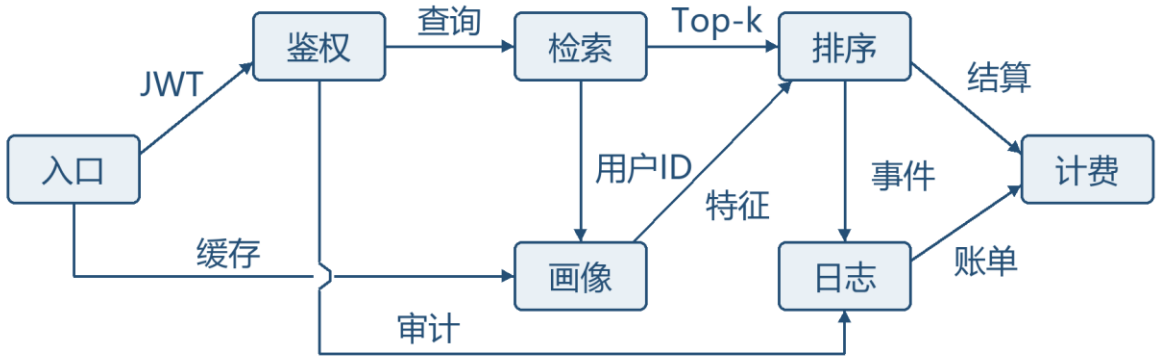


B 服务利用率：鉴权先接近饱和

	40	60	80	100	120	140	160	180
入口	0.18	0.27	0.36	0.45	0.55	0.64	0.73	0.82
鉴权	0.20	0.30	0.40	0.50	0.60	0.70	0.80	0.90
检索	0.16	0.25	0.33	0.41	0.49	0.58	0.66	0.74
排序	0.17	0.26	0.34	0.43	0.51	0.60	0.69	0.77
画像	0.14	0.21	0.28	0.35	0.42	0.48	0.55	0.62
日志	0.13	0.19	0.25	0.32	0.38	0.45	0.51	0.57
计费	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45

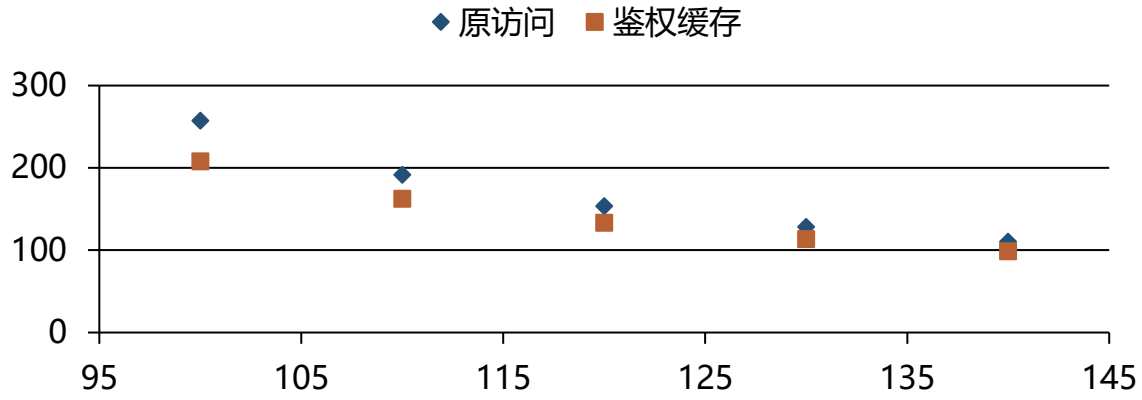
请求率 λ（次/秒） →；单元格：利用率 ρ

C 请求依赖：同步链与旁路交织



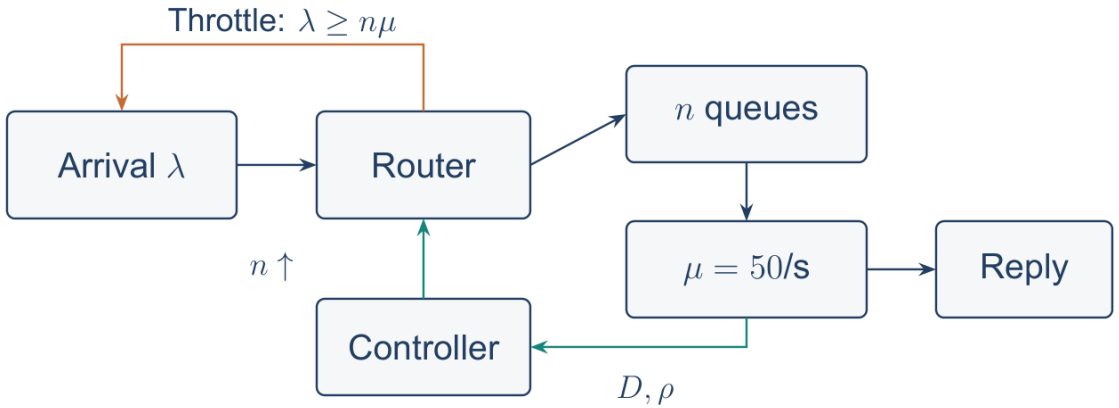
D 容量选择：扩容降低两种策略的延迟

λ=160；3×均值 ms / 容量成本指数（基准=100）



推理服务容量决策：负载与可靠性（模拟）

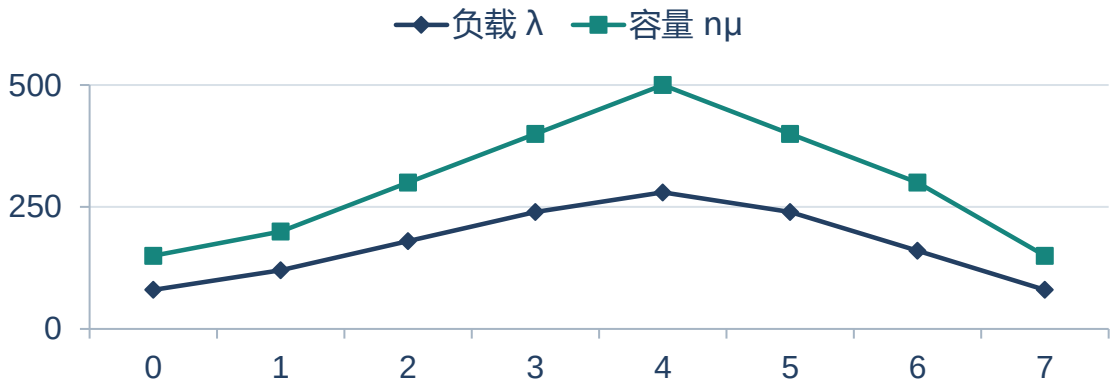
A 反馈调度与准入分支



B 平均延迟 ms；λ 单位 req/s；— 为失稳

n / λ	120	150	180	210	240	270	300
4	50	80	200	—	—	—	—
5	38	50	71	125	500	—	—
6	33	40	50	67	100	200	—
7	30	35	41	50	64	88	140
8	29	32	36	42	50	62	80
9	27	30	33	38	43	50	60

C 服务容量与负载（req/s；横轴 min）



D 均匀路由的队列模型

系统 | 泊松到达；λ < nμ

ρ = λ/(nμ)；D = 1000/(μ − λ/n) ms

策略 | n = ⌈λ/30⌉，每分钟调整

1 min 平台、瞬时调度；比较稳态均值

节点 | μ = 50 req/s，指数服务

均匀路由；功率 P = 120n + 1.6λ W

0.933
峰值 ρ | n=6

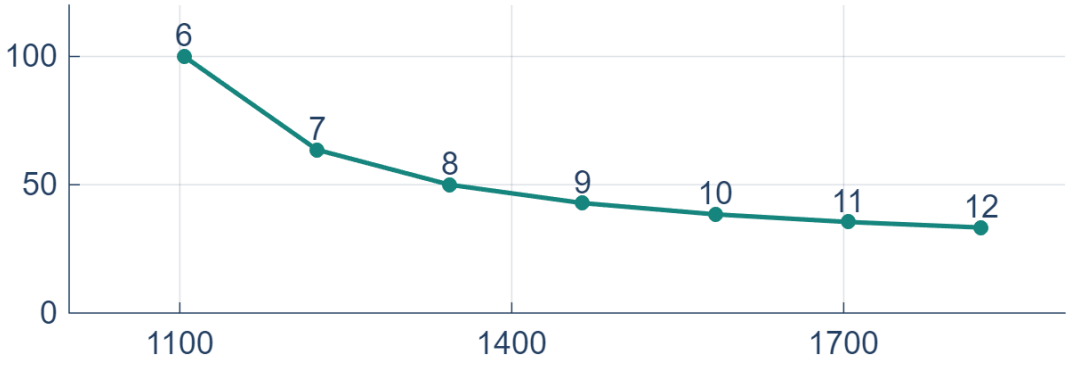
10
自适应副本数

20 ms
单次服务均值

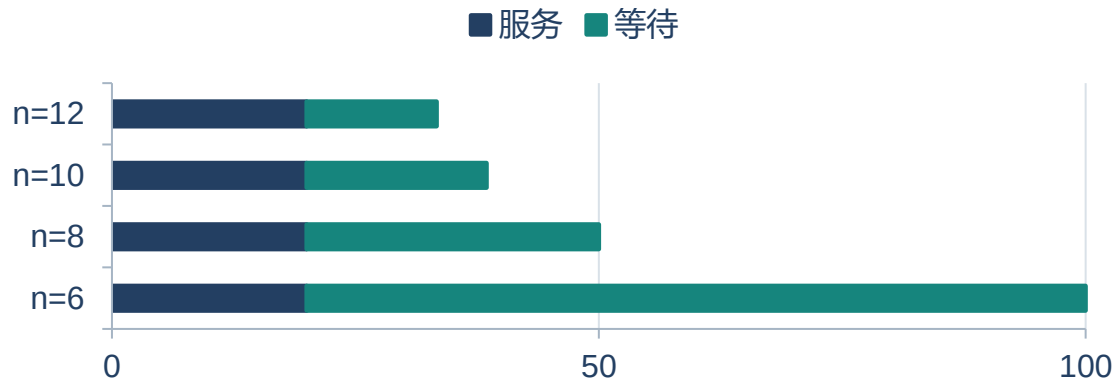
λ = 280 req/s 时，固定 n = 6 的 ρ = 0.933；增至 n = 10 后 D 从 300 ms 降至 45.5 ms。

成本—延迟权衡：40 ms 目标需要 10 副本

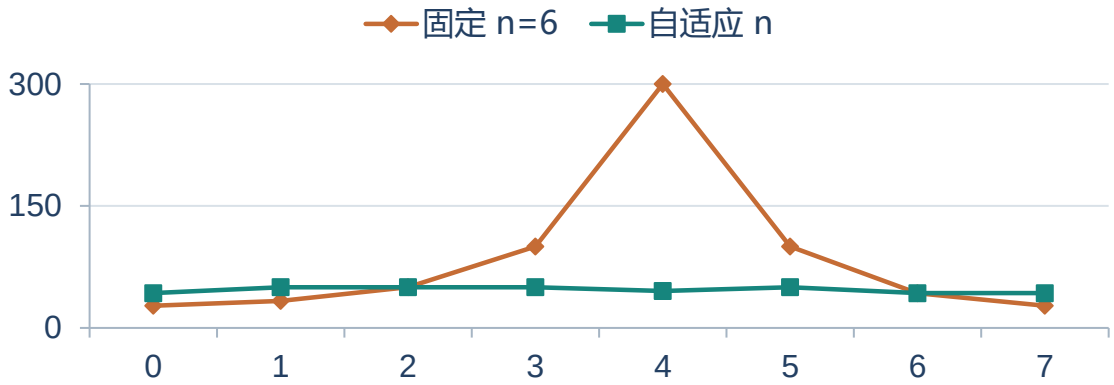
E 功率 W → 延迟 ms；点标签为副本数



F 延迟分解（ms）：服务时间为 20 ms



G 平台平均延迟（ms；横轴 min）



H 目标延迟决定最少副本数

目标 D	120/s	240/s	280/s
40 ms	5	10	12
60 ms	4	8	9
100 ms	3	6	7

λ = 240 req/s：n = 10 时 D = 38.5 ms、功率 1584 W；较 n = 6 增加 480 W，等待减少 61.5 ms。