从梯度下降到共轭梯度

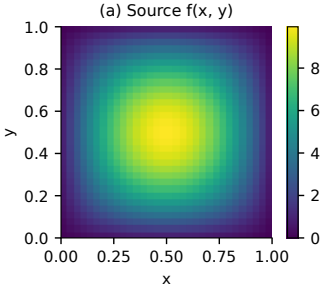
条件数、预条件与稀疏线性系统

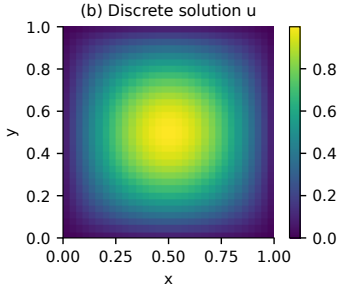
SKILL 应用测试

局部方程 → 能量几何 → 共轭方向 → 结构化预条件

从一张稳态场，得到一个线性系统

单位方形内求解 $-u_{xx} - \varepsilon u_{yy} = f$，边界 $u = 0$。u 是待求场，f 是源项，$\varepsilon = 0.01$ 表示纵向耦合较弱。





用已知解验证离散过程

选 $u_*(x, y) = \sin(\pi x)\sin(\pi y)$，

则 $f = (1 + \varepsilon)\pi^2 u_*$。

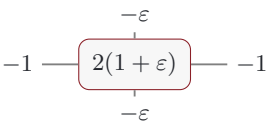
把场值放到网格上

每方向 32 个内部点，共 1024 个未知量。离散解与 u_* 的最大差约为 7.54×10^{-4}。

接下来把微分算子写成邻点间的代数关系，利用这套局部结构求解全部未知量。

一个五点模板，连接上千个未知量

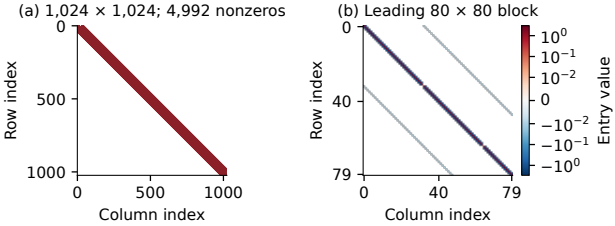
在单位方形求解 $-u_{xx} - \varepsilon u_{yy} = f$，边界 $u = 0$。每方向有 m 个内部点，$h = 1/(m+1)$。



$$L = I \otimes T + \varepsilon T \otimes I,$$

$$T = \mathrm{tridiag}(-1, 2, -1).$$

$\otimes$ 为 Kronecker 积，复制一维耦合。网格值按行展开为 x，有 $Lx = b$，$b = h^2 f$。



$m = 32$，$\varepsilon = 0.01$。

整体模式与左上角局部；按行编号后，非零元分布在五条带上。

稀疏结构直接决定存储与乘法成本

$n = m^2$，$\mathrm{nnz} = 5m^2 - 4m$；$m = 64$ 时 $n = 4096$，$\mathrm{nnz} = 20224$，乘法为 $O(\mathrm{nnz})$。

CSR 只存非零值、列索引和行指针；float64/32 位索引约 0.247 MiB，稠密存储为 128 MiB。

解方程等价于最小化二次能量

对称正定（SPD）：$A = A^{\mathsf{T}}$，且任意非零 v 满足 $v^{\mathsf{T}}Av > 0$。

$$f(x) = \tfrac{1}{2}x^{\mathsf{T}}Ax - b^{\mathsf{T}}x, \qquad \nabla f(x) = Ax - b.$$

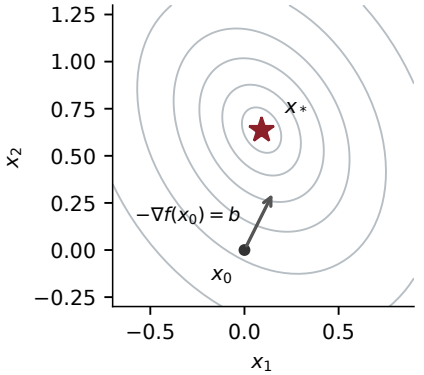
唯一极小点 x_* 满足 $Ax_* = b$。残差 $r = b - Ax$ 是负梯度；误差 $e = x_* - x$ 表示距真解的差。

把“离解多远”写成能量

$$\|e\|_A = \sqrt{e^{\mathsf{T}}Ae}, \qquad f(x) - f(x_*) = \tfrac{1}{2}\,\|e\|_A^2 .$$

等高线的轴向由特征向量决定，曲率由特征值决定。

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad x_* = \begin{bmatrix} 1/11 \\ 7/11 \end{bmatrix}.$$



两条主轴的曲率约为 4.62 与 2.38；较大特征值对应更陡的方向。

沿负梯度走，步长由一维最小化确定

最速下降沿 $r_k = b - Ax_k$ 更新。精确线搜索在这条直线上选择能量最低的位置，下面记作 GD。

$$\phi(\alpha) = f(x_k + \alpha r_k).$$

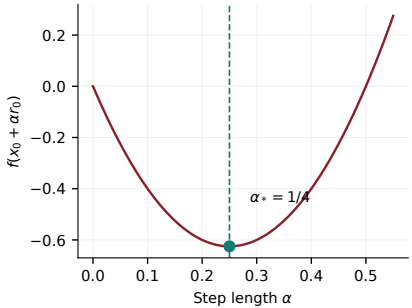
$$\begin{aligned}\phi'(\alpha) &= r_k^{\mathsf{T}}(Ax_k - b + \alpha A r_k) \\ &= -r_k^{\mathsf{T}} r_k + \alpha r_k^{\mathsf{T}} A r_k.\end{aligned}$$

令 $\phi'(\alpha_k) = 0$，得到

$$\alpha_k = \frac{r_k^{\mathsf{T}} r_k}{r_k^{\mathsf{T}} A r_k}, \qquad x_{k+1} = x_k + \alpha_k r_k.$$

本轮结束后，残差与刚走的方向正交

$r_{k+1} = r_k - \alpha_k A r_k$，因此
$r_{k+1}^{\mathsf{T}} r_k = 0$。

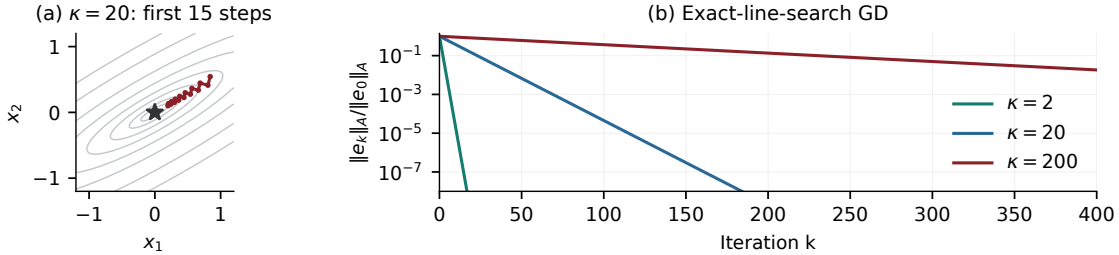


第 4 页的二维系统取 $x_0 = 0$：
$r_0 = (1, 2)^{\mathsf{T}}$，$r_0^{\mathsf{T}} A r_0 = 20$。
所以 $\alpha_0 = 5/20 = 1/4$，
$x_1 = (1/4, 1/2)^{\mathsf{T}}$。

条件数控制最速下降的收敛尺度

精确线搜索的梯度下降（GD）取 $x_{k+1} = x_k + \alpha_k r_k$。沿残差方向令导数为零：

$$\alpha_k = \frac{r_k^{\mathsf{T}} r_k}{r_k^{\mathsf{T}} A r_k}, \qquad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}}, \qquad \frac{\|e_k\|_A}{\|e_0\|_A} \le \left(\frac{\kappa - 1}{\kappa + 1}\right)^k.$$



右图取 $A = \mathrm{diag}(1, \kappa)$、$x_* = 0$、$x_0 = (1, 1/\kappa)^{\mathsf{T}}$，达到上述速率。曲率差异让迭代在狭长谷底反复转向。

左图将 $\kappa = 20$ 的系统旋转 30°，展示前 15 步路径。

把“方向正交”改写成能量几何中的共轭

沿方向 p 完成一次精确线搜索后，有 $p^{\mathsf{T}}\nabla f(x)=0$。再沿 q 移动，梯度改变 αAq。

保持已经完成的最优条件

$$p^{\mathsf{T}}\nabla f(x+\alpha q)=\underbrace{p^{\mathsf{T}}\nabla f(x)}_{0}+\alpha p^{\mathsf{T}}Aq.$$

选择 $p^{\mathsf{T}}Aq=0$，新一步保留旧方向上的最优条件。这样的两方向称为A 共轭。

$$\langle p,q\rangle_A=p^{\mathsf{T}}Aq.$$

这把矩阵定义的曲率纳入方向之间的关系。

共轭梯度（CG）逐步构造这些方向，把每次搜索积累为对整个子空间的优化。

二维实例：普通直角与共轭的区别

仍取 $A=\left[\begin{smallmatrix}4&1\\1&3\end{smallmatrix}\right]$。坐标单位向量 $e_1=(1,0)^{\mathsf{T}}$、$e_2=(0,1)^{\mathsf{T}}$ 满足

$$e_1^{\mathsf{T}}e_2=0,\qquad e_1^{\mathsf{T}}Ae_2=1.$$

改取 $p=(1,2)^{\mathsf{T}}$、$q=(-7,6)^{\mathsf{T}}$：

$$Aq=(-22,11)^{\mathsf{T}},\quad p^{\mathsf{T}}Aq=0.$$

换到能量坐标，关系变得直观

$A^{1/2}$ 为 A 的对称正定平方根。

$u=A^{1/2}p$，$v=A^{1/2}q$，则

$u^{\mathsf{T}}v=p^{\mathsf{T}}Aq=0$。

共轭方向在能量坐标中构成普通直角。

共轭方向保留已经完成的修正

当 $p_i^{\mathsf{T}} A p_j = 0$、$i \neq j$，两方向为$A$ 共轭。沿新方向优化后，先前各方向的最优条件仍保持。

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 3 \end{bmatrix}, \quad b = (1,2)^{\mathsf{T}}, \quad x_0 = 0,\ p_0 = r_0 = b.$$

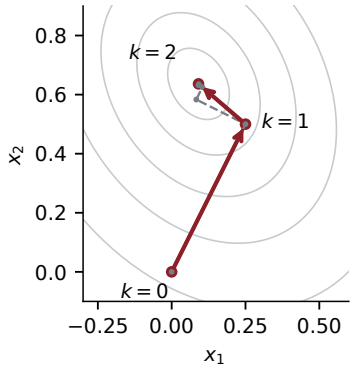
$$\alpha_0 = \tfrac{1}{4}, \qquad x_1 = (\tfrac{1}{4}, \tfrac{1}{2})^{\mathsf{T}},$$

$$r_1 = (-\tfrac{1}{2}, \tfrac{1}{4})^{\mathsf{T}}, \qquad \beta_0 = \frac{r_1^{\mathsf{T}} r_1}{r_0^{\mathsf{T}} r_0} = \tfrac{1}{16},$$

$$p_1 = r_1 + \beta_0 p_0 = (-\tfrac{7}{16}, \tfrac{3}{8})^{\mathsf{T}}.$$

旧方向导数 $p_i^{\mathsf{T}} \nabla f$ 的变化量为

$$\Delta(p_i^{\mathsf{T}} \nabla f) = \alpha p_i^{\mathsf{T}} A p_j = 0.$$



红线：CG 两步　灰虚线：GD 前五步。

第二步到达精确解

$p_0^{\mathsf{T}} A p_1 = 0$，$\alpha_1 = 4/11$，因此 $x_2 = x_1 + \alpha_1 p_1 = (1/11, 7/11)^{\mathsf{T}} = x_*$。

Krylov 子空间把矩阵乘法变成搜索空间

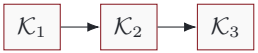
初始残差 r_0 与它反复乘 A 得到的向量，构成一个逐步扩展的搜索空间：

$$\mathcal{K}_k(A, r_0) = \operatorname{span}\{r_0, Ar_0, \dots, A^{k-1} r_0\}.$$

在已建立的空间中选择最优点

$$x_k = \arg\min_{x \in x_0 + \mathcal{K}_k} f(x).$$

等价地，$\|x_* - x_k\|_A$ 最小，
r_k 与已搜索的子空间正交。



每次矩阵乘法提供新的候选方向，短递推维护搜索方向与残差。

二维实例在第二步覆盖整个空间

$$r_0 = (1, 2)^{\mathsf{T}}, \quad Ar_0 = (6, 7)^{\mathsf{T}}.$$

两列行列式为 -5，故 $\mathcal{K}_2 = \mathbb{R}^2$。

$$x_* = \frac{7}{11} r_0 - \frac{1}{11} Ar_0 = (1/11, 7/11)^{\mathsf{T}}.$$

精确解已经属于第二步的搜索空间，因此第 8 页的两次线搜索即可到达 x_*。

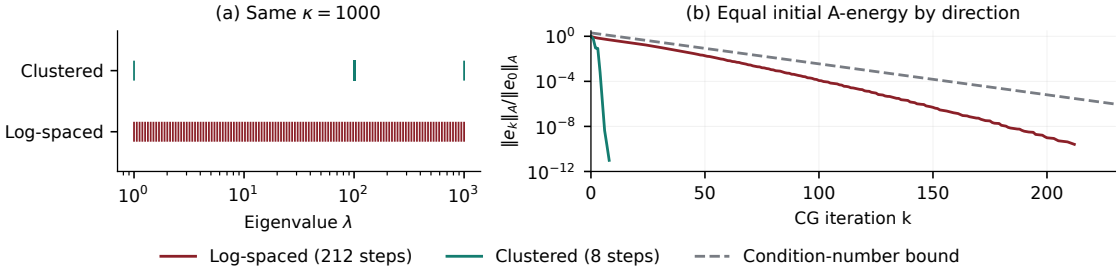
误差多项式给出另一种读法

$e_k = \pi_k(A) e_0$，$\pi_k(0) = 1$。本例 $\pi_2(t) = 1 - \frac{7}{11} t + \frac{1}{11} t^2$，
在两个特征值处均为零，两个特征方向的误差同时消失。

谱聚集可以大幅加速 CG

谱指 A 的特征值分布。误差多项式 π_k 在每个特征值处缩放对应方向的误差；特征值聚集时，同一个低阶多项式可以同时压低一整簇分量：

$$e_k = \pi_k(A)e_0, \quad \pi_k(0) = 1, \qquad \frac{\|e_k\|_A}{\|e_0\|_A} \le 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^k.$$



120 维，$x_0 = 0$、$(x_*)_i = \lambda_i^{-1/2}$，各特征方向初始 A 能量相同。聚集谱含 $1, 1000$ 与 118 个位于 $[100, 101]$ 的值。float64 真相对残差达 10^{-10}：聚集谱 8 步，对数谱 212 步。

CG 用短递推保存方向搜索的成果

初始化 $r = b - Ax$、$p = r$。每轮沿 p 搜索，再用新残差与旧方向组成下一方向。

$$q_k = Ap_k, \qquad \alpha_k = \frac{r_k^{\mathsf{T}} r_k}{p_k^{\mathsf{T}} q_k},$$

$$x_{k+1} = x_k + \alpha_k p_k,$$

$$r_{k+1} = r_k - \alpha_k q_k,$$

$$\beta_k = \frac{r_{k+1}^{\mathsf{T}} r_{k+1}}{r_k^{\mathsf{T}} r_k},$$

$$p_{k+1} = r_{k+1} + \beta_k p_k.$$

```
r = b - A @ x
p, rr = r.copy(), r @ r
target = 1e-8 * np.linalg.norm(b)
for k in range(5000):
    if np.sqrt(rr) <= target: break
    q = A @ p
    alpha = rr / (p @ q)
    x += alpha * p
    r -= alpha * q
    rr1 = r @ r
    p = r + (rr1 / rr) * p
    rr = rr1
true_residual = b - A @ x
```

从核心运算核算成本

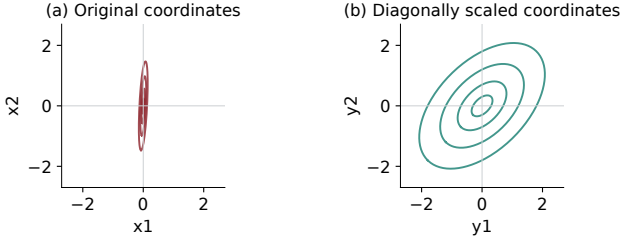
每步 1 次稀疏矩阵向量乘法（SpMV）、2 次内积及向量更新，存储少量 n 维向量。

A, b, x 为系统与初值，np 为 NumPy；最后重算真残差，按第 18 页的标准检查结果。

预条件通过改变坐标，改善能量几何

选易解的 SPD 矩阵 $P = CC^{\mathsf{T}}$，令 $y = C^{\mathsf{T}}x$，得到

$$\widetilde{A}y = C^{-1}b, \qquad \widetilde{A} = C^{-1}AC^{-\mathsf{T}}.$$



$A = \left[\begin{smallmatrix} 200 & -10 \\ -10 & 2 \end{smallmatrix}\right]$，$P = \mathrm{diag}(200, 2)$。
条件数由约 134 降至 3，等能量曲线更均衡。

预条件共轭梯度（PCG）在原坐标中实现这一过程，每轮计算 $z = P^{-1}r$。
收敛界中的条件数变为 $\kappa(\widetilde{A})$。

选择 P 时同时考虑几何改善与求解成本：越贴近 A 的结构，越需要高效实现它的逆作用。

预条件同时处理尺度与耦合

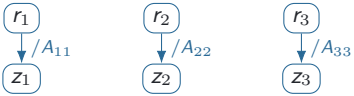
令 $P = CC^{\mathsf{T}}$、$y = C^{\mathsf{T}}x$，等价系统为 $\widetilde{A}y = C^{-1}b$，$\widetilde{A} = C^{-1}AC^{-\mathsf{T}}$。$\widetilde{A}$ 保持 SPD，PCG 收敛界使用 $\kappa(\widetilde{A})$。

Jacobi：对角均衡，消除变量尺度

对第 3 页的 L 做对称缩放，构造 $A = SLS$，$\varepsilon = 0.01$。$S = \mathrm{diag}(s)$，s 沿每行由 1 几何增至 20。

$$P_J = \mathrm{diag}(A), \qquad z_i = r_i/(P_J)_{ii}.$$

$m = 32$：$\kappa(A) = 16895.05$，
对角均衡后 $\kappa_J = 440.69$。



各分量分别除以对应对角元

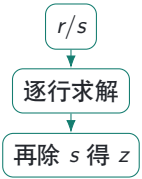
Line：行块预条件，保留强耦合

$$P_B = S[I \otimes (T + 0.02I)]S.$$

每行求解同一个三对角系统，长度 m 的 Cholesky 因子复用于全部 m 行。
$m = 32$：$\kappa_B = 5.35$。



按强 x 耦合分行



实际计算的是 $P^{-1}r$。SciPy 的参数 `M` 接受这个逆作用。代码中的 `apply_Pinv` 即对应操作。

行块预条件：一个带状因子服务所有网格行

$P_B = S[I \otimes B]S$，其中 $B = T + 2\varepsilon I$。先解尺度、再解每行三对角系统、最后恢复尺度：

$$P_B^{-1} r = S^{-1}[I \otimes B^{-1}]S^{-1} r.$$

```
from scipy.linalg import (
    cholesky_banded, cho_solve_banded)
band = np.zeros((2, m))
band[0] = 2 + 2 * eps
band[1, :-1] = -1
chol = cholesky_banded(band, lower=True)
def apply_Pinv(r):
    U = (r / s).reshape(m, m).T
    Z = cho_solve_banded((chol, True), U)
    return Z.T.ravel() / s
```

带状存储与批量求解

band[0] 存对角，band[1] 存次对角。转置后，每一列是一个网格行的右端。

PCG 对 CG 递推的修改

先求 $z = P^{-1} r$，初始方向 $p = z$，令

$\rho = r^{\mathsf{T}} z$。

$\alpha = \rho / (p^{\mathsf{T}} A p)$，

$\beta = \rho_{\text{new}} / \rho$，

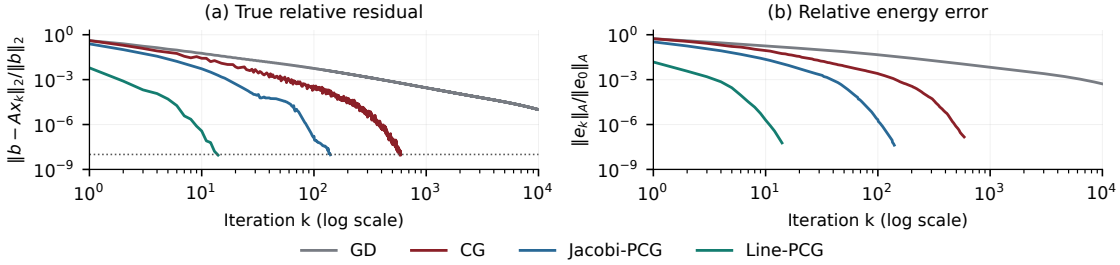
$p_{\text{new}} = z_{\text{new}} + \beta p$。

分解长度 m 的 B 后复用因子，每轮解 m 个右端，整体工作为 $O(m^2) = O(n)$。

m 为每行内部点数，s 为第 13 页的缩放向量。

同一系统上的四种迭代轨迹

$m = 32,\ n = 1024,\ A = SLS,\ \varepsilon = 0.01,\ s_i \in [1, 20]$。取 $x_* \sim \mathcal{N}(0, I)$（种子 20261111）、$b = Ax_*$、$x_0 = 0$，使用 float64。

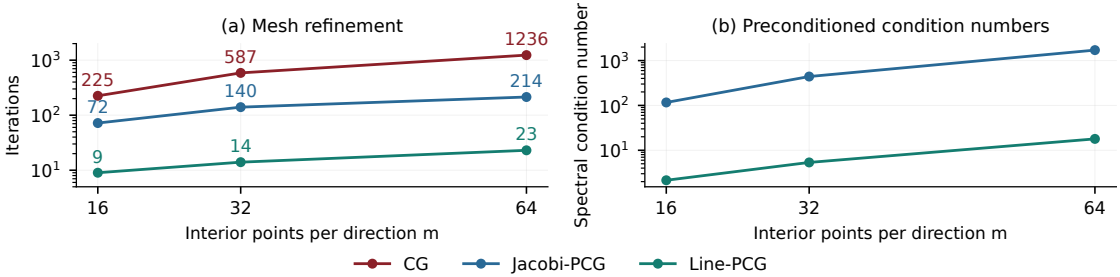


方法	GD	CG	Jacobi-PCG	Line-PCG
达到真相对残差 10^{-8} 的步数	> 10000	587	140	14
终止时真相对残差	1.01×10^{-5}	9.26×10^{-9}	9.49×10^{-9}	9.05×10^{-9}

GD 截至 10000 步。图中 $e_k = x_* - x_k$。行块保留强耦合，将 Jacobi-PCG 的 140 步降至 14 步。

网格加密后的收益与成本

$m = 16/32/64$ 对应 $n = 256/1024/4096$。保持 $\varepsilon = 0.01$、$s_i \in [1, 20]$ 与右端构造方法，全部按真相对残差 10^{-8} 停止。



每步增加多少工作

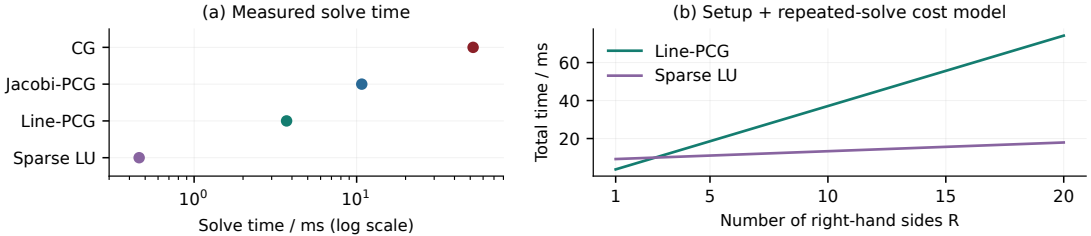
三方法都有 $O(\mathrm{nnz})$ 的 SpMV。Jacobi 加 n 次逐项除法；行块加 m 个长度 m 的三对角求解，总计 $O(n)$。

总成本如何判断

建预条件成本 + 迭代数 × 每步成本。行块的 κ_B 随网格加密由 2.14 升至 17.94；同一矩阵的多个右端可复用因子。

迭代数与每步成本，共同决定总时间

对 $m = 64$ 的同一系统，用 SciPy 1.18.1 在本机预热后重复 7 次，取中位数。求解阈值为 10^{-8}，时间单位为毫秒。



方法	CG	Jacobi-PCG	Line-PCG	稀疏 LU
准备	0.004	0.068	0.045	8.745
单次求解	52.066	10.752	3.706	0.459

右图按 $T(R) = T_{\text{setup}} + R\,T_{\text{solve}}$ 估算。行块减少迭代；同一矩阵的多个右端可以复用预条件或 LU 因子。

Windows 本机，线程环境设为 1。

用真残差停止，再核对误差尺度

SciPy 的 cg 接受 SPD 矩阵 A；算子 M 实现 P^{-1} 的作用。

用原方程检查停止条件

$$\|b - Ax\|_2 \le \max\{\texttt{rtol}\,\|b\|_2,\ \texttt{atol}\}.$$

返回后重算 $b - Ax$ 并检查 `info`；`rtol` 控制相对残差，`atol` 控制绝对残差。

用条件数换算误差尺度

$$\frac{\|e\|_2}{\|x_*\|_2} \le \kappa(A)\frac{\|r\|_2}{\|b\|_2}.$$

$\kappa \approx 1.69 \times 10^4$ 时，残差 10^{-8} 对应的通用相对误差上界约 1.69×10^{-4}。

```
import numpy as np, scipy.sparse.linalg as sla
M = sla.LinearOperator(A.shape, matvec=apply_Pinv)
x, info = sla.cg(A, b, M=M, rtol=1e-8, atol=0.0, maxiter=5000)
res = np.linalg.norm(b - A @ x)
assert info == 0 and res <= 1e-8 * np.linalg.norm(b)
```

行块实例（$m = 32$）：`info = 0`（收敛），$\|b - Ax\|_2 / \|b\|_2 = 9.05 \times 10^{-9}$。

精确算术下 CG 至多 n 步；舍入会损失共轭性，第 10 页 120 维例用了 212 步。用递推残差迭代，用真残差验收。

直接实现五点乘法，也能接入同一个 CG 接口

CG 只需要计算 Av。对 $A = SLS$，先缩放向量，在网格上执行邻点加权，再缩放回来。

```
def matvec(v):
    U = (s * v).reshape(m, m)
    V = (2 + 2*eps) * U.copy()
    V[:, :-1] -= U[:, 1:]
    V[:, 1:] -= U[:, :-1]
    V[:-1, :] -= eps * U[1:, :]
    V[1:, :] -= eps * U[:-1, :]
    return s * V.ravel()
Aop = sla.LinearOperator(
    (m*m, m*m), matvec=matvec,
    dtype=np.float64)
```

邻点边界直接反映零边界条件

切片只累加内部邻点；边界外 $u = 0$，对本页齐次边界无需增加右端项。

在 $m = 32$ 上做数值对照

同一测试向量，显式矩阵与算子乘法的相对差为 1.67×10^{-16}。

配行块预条件，真相对残差为 9.05×10^{-9}。

```
M = sla.LinearOperator(Aop.shape, matvec=apply_Pinv)
x, info = sla.cg(Aop, b, M=M, rtol=1e-8, atol=0)
res = np.linalg.norm(b - Aop @ x) / np.linalg.norm(b)
```

`sla` 为 `scipy.sparse.linalg`；矩阵自由实现主要存储向量及预条件数据。

把结构、收敛与成本连成一条求解路径

矩阵或任务特征	具体选择
对称正定且稀疏	CG / PCG，利用稀疏乘法与少量工作向量
变量尺度差异大	用对角预条件先做尺度均衡
沿某方向或变量组强耦合	按线或物理变量分块，保留局部耦合
同一矩阵、多个右端	复用预条件与因子，摊薄构建成本
对称不定 / 一般非对称	分别考虑 MINRES / GMRES

把三条线索连起来

条件数连接能量几何与收敛上界；共轭方向减少重复修正；预条件把矩阵结构转化为更少的迭代。

Shewchuk (1994), *An Introduction to the Conjugate Gradient Method.*

Barrett 等，*Templates for the Solution of Linear Systems*，§2.3.1、§3.2。

SciPy 官方接口：`cg`、`minres`、`gmres`。