Do-JEPA

从预测未来，到预测动作效果

From Masking to Intervention in Latent World Models

论文作者 Hossein Resani · Javen Qinfeng Shi
Adelaide University · AIML / Responsible AI Research Centre
arXiv:2609.37378v1 · 2026 年 9 月 29 日



从一次状态分叉，学习动作改变了什么、作用于哪里、如何传播。

让两个未来只在动作上不同

掩码训练：改变可见信息

C-JEPA 隐去物体槽，再从其余槽补全。
目标仍来自同一条日志轨迹：背景与结果的
相关性仍可能被模型用来预测。

历史 z → 隐去槽 → 预测未来

普通预测损失只约束未来是否接近目标，
没有指定变化中哪一部分由动作造成。

参考动作通常为物理 no-op；CausalWorld
使用围绕当前关节位置镜像的命令。

配对干预：改变世界发生的过程

完整状态 s_t + 相同噪声 / 背景

动作分支

$$a \longrightarrow z^{a}$$

参考分支

$$a_{\varnothing} \longrightarrow z^{a_{\varnothing}}$$

$$\Delta z = z^{a} - z^{a_{\varnothing}}$$

示例 $z^{a} = (3, 2, 7), \quad z^{a_{\varnothing}} = (1, 2, 7)$

差分 (2, 0, 0)：共享的后两维抵消。
它描述当前状态下“换动作”的效果。

配对消去两分支共享的成分；状态与背景交互的潜在成分不会自动消失。

差分之外，还要监督入口、传播与不变部分

历史 → 无动作基线 b	+	入口 m → 残差 r → 门控 G	=	$\hat{z}^a = b + r$

监督项	训练目标（省略批次平均）	具体职责
效果损失	$\|\widehat{\Delta z} - \Delta z\|_2^2$	约束动作造成的变化量与方向
入口损失	$\mathrm{CE}(y, m), \quad y_i \propto \|\Delta z_{t+1}^i\|_2^2$	首步响应能量归一化，指定直接作用槽
传播损失	$\mathrm{BCE}_{\mathrm{bal}}(G, y^{\mathrm{edge}}) + \lambda_{\mathrm{sp}}\|G\|_1$	响应晚一拍的槽对提供传播标签
槽不变损失	$\sum_{j \notin R}\left(\|\widehat{\Delta z}^j\|_2^2 + \lambda_g \sum_i G_{ji}\right)$	未响应槽效应归零，关闭流入门
背景损失	$\|\widehat{\Delta z}(c) - \widehat{\Delta z}(c')\|_2^2$	同物理状态换背景，效果应一致
总目标	两分支预测 + 上述加权损失 + R	保留事实预测与防坍缩正则

槽模型把动作放入残差路径；全局 LeWM 潜在只有 K=1，使用效果损失而无槽门控。

训练用配对真值，测试只给历史与动作

从模拟器到监督

保存完整状态 → 两次 rollout → 编码未来
首步差分：入口；响应时间：传播；
全时域无响应：不变槽；换背景：context twin。

从模型到检验

预测效果：同一历史输入动作与参考动作后相减。
规划：使用事实预测搜索动作。
物理评估：训练 / IID 数据拟合读出探针。

训练变体	使用的数据	额外约束
Obs	事实分支	普通未来预测
Aug	事实 + 参考；有时含背景孪生	各样本独立预测，不比较分支
Paired	与 Aug 完全相同	加效果损失
Do-JEPA full	配对 + 背景孪生	加背景损失；槽模型按设置加槽损失

指标分工：事实误差测未来；效果误差测动作差分；AUROC 测是否响应；结构 F1 测路径。

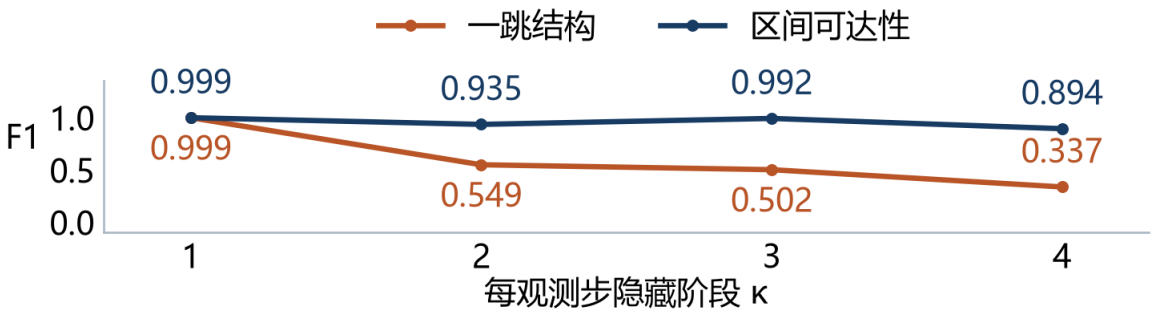
Aug 与 Paired 看见相同数据；两者的差异才能隔离“显式比较两条未来”的贡献。

预测得准，不会自动把动作送到正确入口

四物体环 + 三干扰槽：测试反转训练相关性

入口消融	Top-1 ↑	干扰槽 mask ↓	效果 MSE ↓
稀疏 mask	0.000	1.000	0.0110
+ 效果损失	0.000	1.000	0.0100
+ 入口损失，温度 1.0 → 0.7	0.9995	0.000082	0.00093

效果损失可由后续传播补偿错误入口；稀疏性决定“几个槽”，首步标签决定“哪个槽”。



传播监督的独立证据

边 AUROC：0.624 → 0.975

3/3 种子恢复四条环边。

观测间隔内多跳传播，会混合先后顺序。

入口要看首步响应；传播要看时间顺序。观测变粗时，可识别的关系转向区间可达性。

背景不变性必须落到承载物理的潜在方向

状态 Push-T：背景损失权重 0.25

两次独立种子的 OOD 误差降低 43.9% / 55.2%；
IID 误差增加 4.2% / 3.5%。
权重由另一种子的 IID–OOD 曲线选定。

为什么潜在惩罚可能伤害物理精度

CausalWorld 诊断：192 维空间中两个方向
承载约 99.8% 的解码物理误差。均匀压低
潜在差异，可能把误差留在这些关键方向。

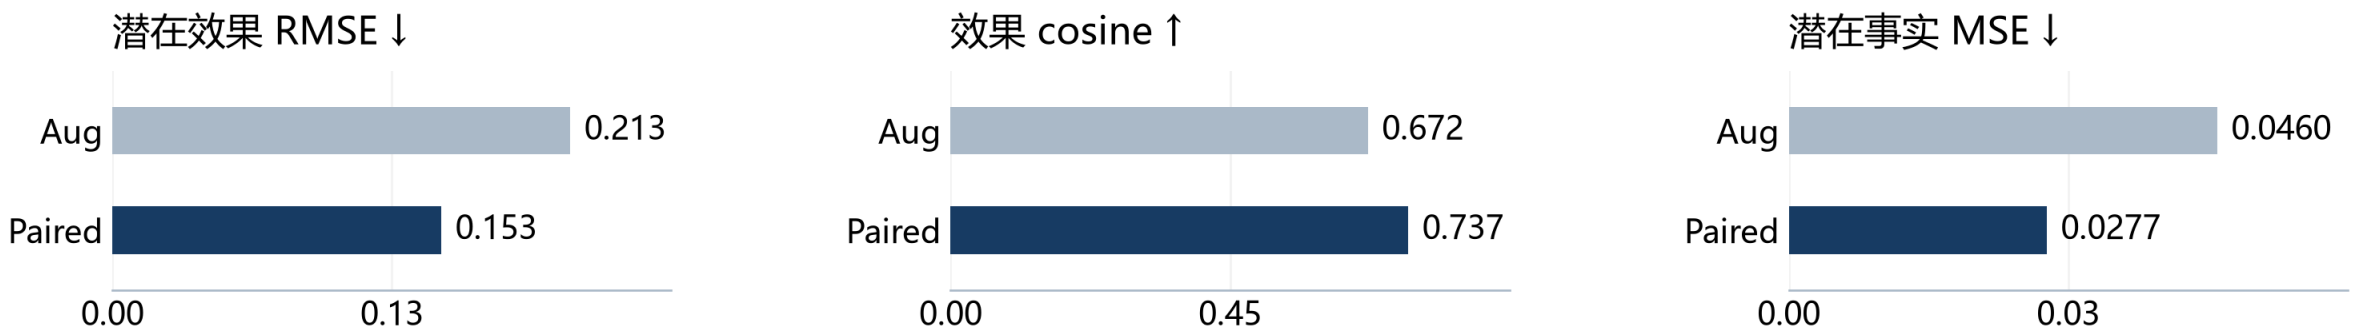
冻结视觉槽 / OOD	事实误差 (px) ↓	响应效果 (px) ↓	响应 AUROC ↑	背景敏感 (px) ↓
Mask	39.02	20.25	0.485	19.91
Aug	24.88	16.79	0.666	12.59
Do-JEPA	27.19	17.89	0.691	13.74

相对 Mask 六项指标均改善；相对同数据 Aug，响应检测更好，事实与效果误差更高。

固定状态变量上，背景孪生能消除捷径；学习到的潜在距离与物理距离可能不一致。

像素端到端：效果收益随训练动作分布迁移

LeWM 微调：同数据 Aug → Paired（富集配对，50% 响应）



潜在空间由各模型自己学习；还需用物理位移读出检验动作效果。

响应物理 RMSE 变化	自然动作测试	未按结果筛选 holdout
自然动作训练	−13.5%	−5.5%
富集动作训练	+5.9%	+4.7%

自然专家动作训练后，响应物理效果误差下降 13.5%；独立抽取动作的 holdout 下降 5.5%。

CausalWorld：训练方式决定事实精度的代价

从头训练，α = 1：Paired 相对 Aug（3 个独立基准实例）

测试偏移	响应效果 RMSE	潜在背景敏感	事实 RMSE	响应 AUROC
视觉相关性反转	−3.9%	−66.2%	+52.8%	−0.054
质量 / 摩擦 + 背景独立	−20.3%	−65.4%	+51.5%	−0.070
物理改变 + 视觉反转	−19.5%	−66.2%	+51.1%	−0.073

改变训练方案：效果精度与事实预测的取舍

方案	事实 RMSE / OOD	效果 RMSE / 物理偏移	事实误差各split ≤ +10%
从头 α = 1	+51.8%	−19.9%	0/3
从头 α = 0.25	+10.6%	−12.8%	1/3
从 Aug 微调 α = 1	−0.9%	−13.3%	3/3

从已收敛 Aug 模型继续训练 2,000 步，可保留事实精度并改善动作效果。

动作效果更准，也要保住规划所用的动力学

开发集 50 个回合：直接全量微调，效果误差 −29.1%，规划成功率 94% → 54%。

冻结基础预测器

$$F_{\text{base}}(z, a)$$

→

同权重适配器差分

$$\delta = g_\phi(h^a) - g_\phi(h^{a \leftarrow a_\varnothing})$$

→

$$F_{\text{adapt}} = F_{\text{base}} + \delta$$
$$a = a_\varnothing \Rightarrow \delta = 0$$

约束训练

秩 ≤16 的可训练修正
惩罚偏离基础模型的 5 步轨迹
仅选 rollout 误差 ≤ 基础 1.2× 的检查点
固定编码器与基础预测器权重
三项一同引入，未单独消融中心化。

独立规划检验：600 个配对回合

自然动作适配器 87.7% vs. 基础 87.8%
成功率差 −0.17 个百分点
90% CI [−2.20, +1.87]，落入 ±3 pp
TOST 等效检验；回合使用配对起点与目标。
结论是保留规划能力；没有显示规划提升。

中心化适配器 + 多步保持损失 + 漂移筛选，使规划成功率与原模型落在 ±3 个百分点内。

Do-JEPA 的贡献：让世界模型接受干预问题的检验

研究问题	最有力证据	适用条件 / 实际含义
动作进入哪里?	合成槽 Top-1 99.95–100%	对象对齐、单直接目标；首步先于传播
效果沿哪里传播?	3/3 种子恢复环图；AUROC 0.975	时间分辨率决定一跳边或区间可达性
像素中能否学会动作效果?	自然动作物理误差 −13.5%	同数据对照；训练干预分布影响迁移
怎样减少精度代价?	CausalWorld 微调：物理效果 −13.3%	物理偏移均值；事实 OOD 误差 −0.9%
能否用于控制?	600 回合规划等效于基础模型	需要保持多步动力学；效果增益未变成成功率提升

数据要求：完整状态可恢复，两个分支共享噪声；背景孪生只改观测。
真实世界的近似配对会混入状态与噪声差异，需另行建模。

把事实预测、动作效果、作用结构与规划分开评估，才能知道模型究竟学到了什么。