长上下文
企业知识助手如何扩容

从单机瓶颈到 Prefill / Decode 解耦集群

性能边界 · KV 内存 · 调度策略 · 集群运行

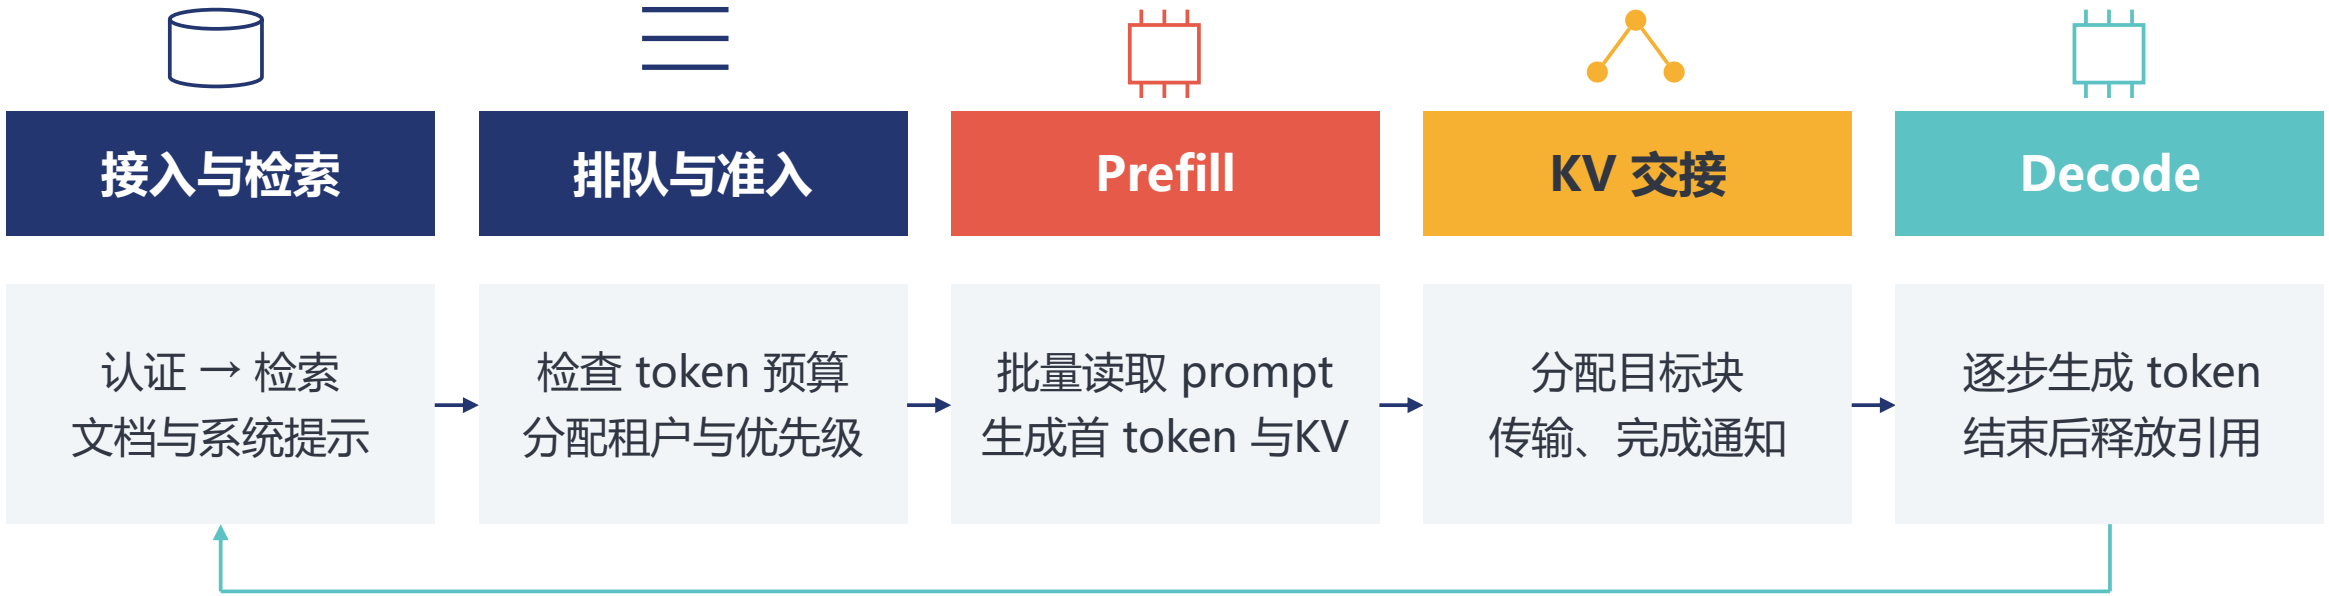
2026 年 10 月 18 日

先固定一个可验收的知识问答场景

维度	设计示例：企业知识助手	扩容时要保住什么
模型与精度	Qwen2.5-7B-Instruct；BF16 权重 / KV	答案质量、引用正确性与权限边界
请求长度	基线 8,192 输入 + 256 输出 token	压力组：输入升至 32,000 token
复用与租户	16 个活跃会话；同租户 6,144 token 前缀	跨租户缓存隔离；热 / 冷请求分别统计
延迟目标	p95 TTFT ≤ 2 s；p95 请求 TPOT ≤ 40 ms	同时满足两项的请求比例 ≥ 95%
到达过程	基线 Poisson；另加阶跃与突发回放	从 0.2 req/s 扫到失稳，再退回容量边界

容量的分母是满足质量与延迟目标的请求；后续内存、网络和成本都沿用这组参数。

请求走完五段链路，首 token 才能到达用户



流式返回：逐 token → detokenize → SSE → 浏览器

同机服务省掉跨设备 KV 交接；解耦把它加入 TTFT 关键路径，并增加一处故障边界。

TTFT、TPOT 与 ITL 描述不同的等待



$$TTFT = t_1 - t_0$$

$$TPOT = (t_n - t_1) / (n - 1)$$

指标	观测单位	容量判定中的作用
ITL	相邻 token 到达间隔	发现输出卡顿；需定义 token 加权或请求加权
p95	请求指标的95分位	联合达标率需逐请求同时核对TTFT与TPOT
有效吞吐	req/s 或 token/s；goodput 为达标 req/s	goodput = 完成请求速率 × 联合 SLO 达标比例

256 个输出 token、TTFT 2 s、TPOT 40 ms，对应单请求端到端延迟约 12.2 s。

Prefill 吃计算，Decode 反复读取权重与历史 KV

Prefill · 一次处理多个 token

输入矩阵较大，权重读入被多个 token 摊薄。

长序列注意力工作随上下文增加；一次长 prefill 会延长共批 decode 的等待。

目标：压低首 token 执行时间与排队时间。

Decode · 每轮推进一个 token

每个活跃序列每轮生成一个 token。

小批次常受内存带宽约束；并发上升后 KV 读取、计算与通信都可能成为瓶颈。

目标：保持步间节奏，并利用批次摊薄权重读取。

调度器同时面对“长任务快速启动”和“短步持续推进”；拆池的收益来自解除这两类资源竞争。

KV 容量按 token 累积，不能只看模型参数量

$$M_KV = 2 \times L \times H_KV \times d_head \times b \times T$$

Qwen2.5-7B 配置	取值	BF16 KV 推导
层数 L / KV头数 H_KV	28 / 4	2 × 28 × 4 × 128 × 2 B
头维度 / 每元素字节	3,584 ÷ 28 = 128 / 2 B	57,344 B = 56 KiB / token
8,192 输入 / 256 输出	448 MiB / 最多14 MiB	每会话上界 462 MiB
16 会话 / 无共享	16 × 462 MiB	7.219 GiB KV；另计权重与运行时

GPU 内存预算

权重常驻
+ 活跃 KV
+ 激活 / 工作区
+ CUDA Graph
+ 分配与安全余量

示例可用 KV 池为24 GiB时：8,192+256最多容纳53会话；32,000+256最多13会话。

共享前缀把重复计算与重复 KV 变成一份

16个会话 · 每个8,192输入 + 256输出 · 同租户完整前缀6,144 token



共享 336 MiB + 16 × 私有126 MiB = 2.297 GiB

token 顺序、模型版本、LoRA 与盐一致

完整块复用；引用计数归零才可回收

知识片段放在稳定前缀中才产生复用；把每次变化的检索结果插到前部，会使后续缓存键一起变化。

PagedAttention 用块表连接逻辑序列和物理 KV

逻辑视图：示意块大小4 token

请求 A	2	7	4
请求 B	2	7	9

物理块池：地址可以不连续

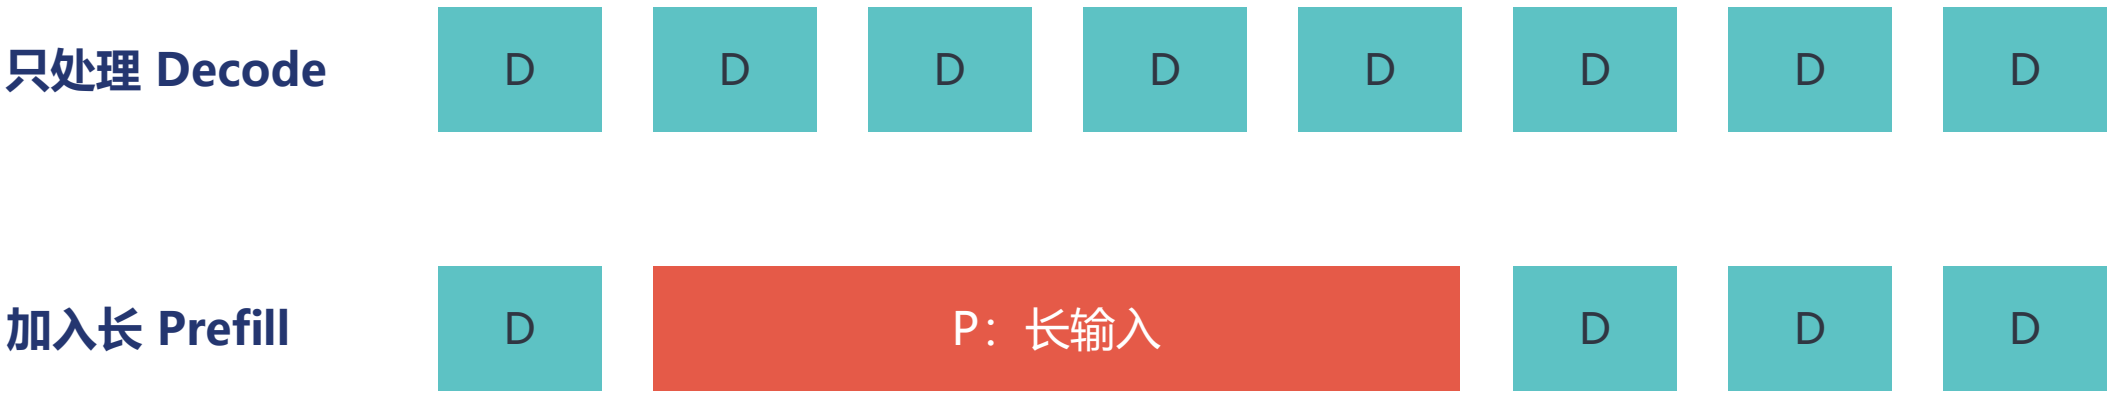
0	1	2	3	4
5	6	7	8	9

块2和块7由A/B共享；各自追加到块4与块9。
引用计数管理共享块；写入已共享的尾块时复制。

分页减少连续预留与外部碎片；最后一个块仍可能有内部碎片，容量模型必须计入尾块。

连续批处理提高利用率，长 prefill 仍会阻塞短步

同一GPU上的迭代示意（宽度表示相对执行时长）



新请求不必等整批结束；完成的序列退出，等待序列进入。
当长 prefill 占据一次迭代，其间已有输出流暂停，ITL尾部拉长。

将活跃序列数、每轮 token 预算和输入长度一起观察，才能区分计算饱和、队列积压与 KV 不足。

Chunked Prefill 把长输入拆进 Decode 的剩余预算

设计示例：每轮token预算 B=2,048；32个Decode序列先占32

先排 Decode
32 token

→

计算余量
2,048 − 32

→

放入 Prefill
最多2,016 token

→

下一轮继续
8,192输入约5轮

预算较小

单轮 prefill 较短，输出卡顿减轻；输入分更多轮完成。

预算较大

首 token 可更快完成；共批 decode 的迭代时长上升。

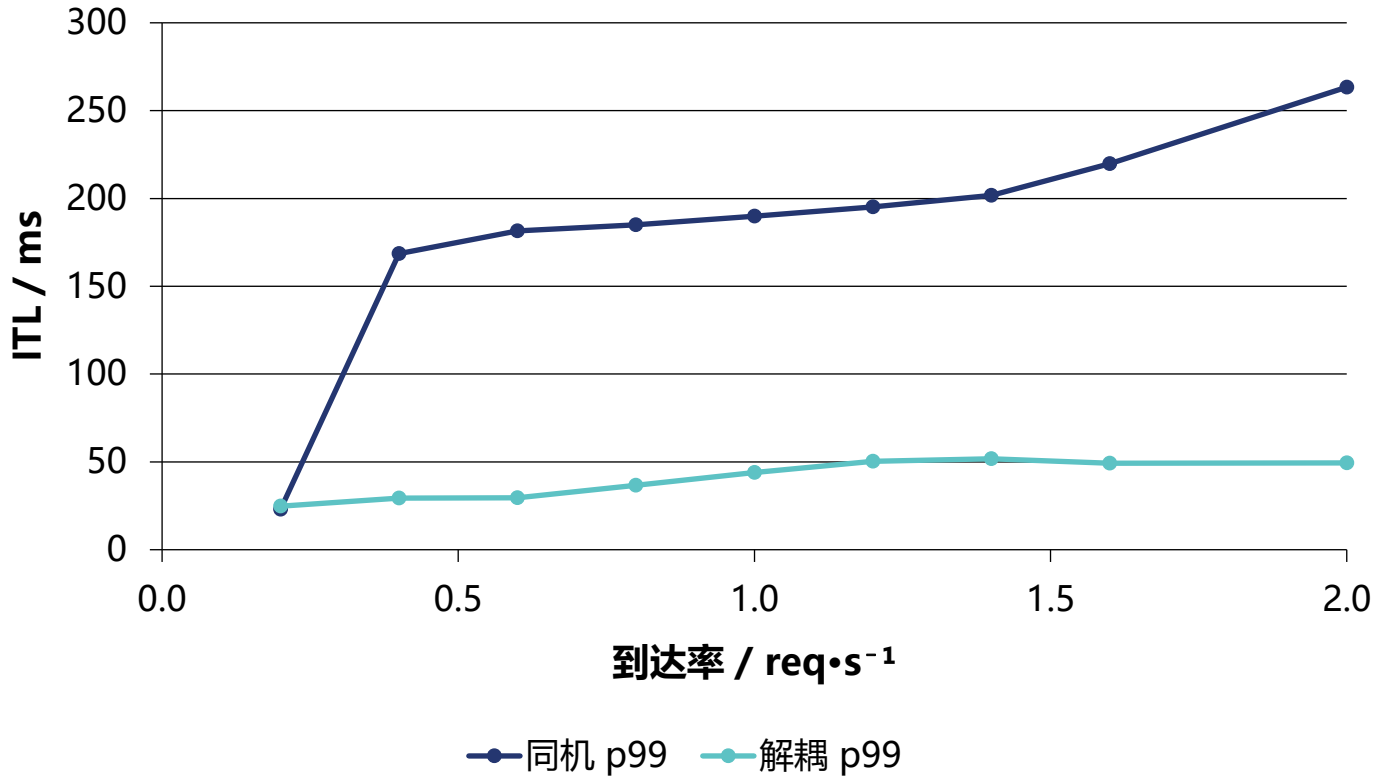
从冷缓存、长输入和突发流量回放中选择预算；以联合 SLO 达标率检验，避免只优化平均 token/s。

准入控制提前约束未来 KV，而非等到 OOM

入口门槛	预算 / 状态	动作与隔离边界
请求级	输入token + max_output ≤ 上限	超长请求转异步摘要或拒绝；显式返回原因
租户级	并发、排队token、缓存盐	交互请求与离线任务分队列；防止共享缓存跨权域
实例级	空闲KV块 − 已预留增长空间	先预留增长额度；内存不足时停止接入新会话
队列级	等待时间 + 预计执行 > deadline	及时拒绝或降级；取消后释放块与租约
调度级	优先级 + aging + 每租户权重	保障交互响应，同时给长期等待任务推进机会

内存抢占触发重算会同时放大计算与延迟压力；准入预算应覆盖输入、输出增长及传输驻留。

公开实验：ITL 尾部变平，TTFT 却超过目标



Qwen2.5-7B-Instruct
2×L40S 48 GB；无NVLink
约8K输入 / 256输出
每档100次Poisson到达
前缀缓存关闭
同机：单进程DP=2
解耦：1P+1D，NIXL

0.2 req/s 的中位TTFT
同机0.7 s → 解耦2.2 s
约470 MB KV传输耗时1.3 s

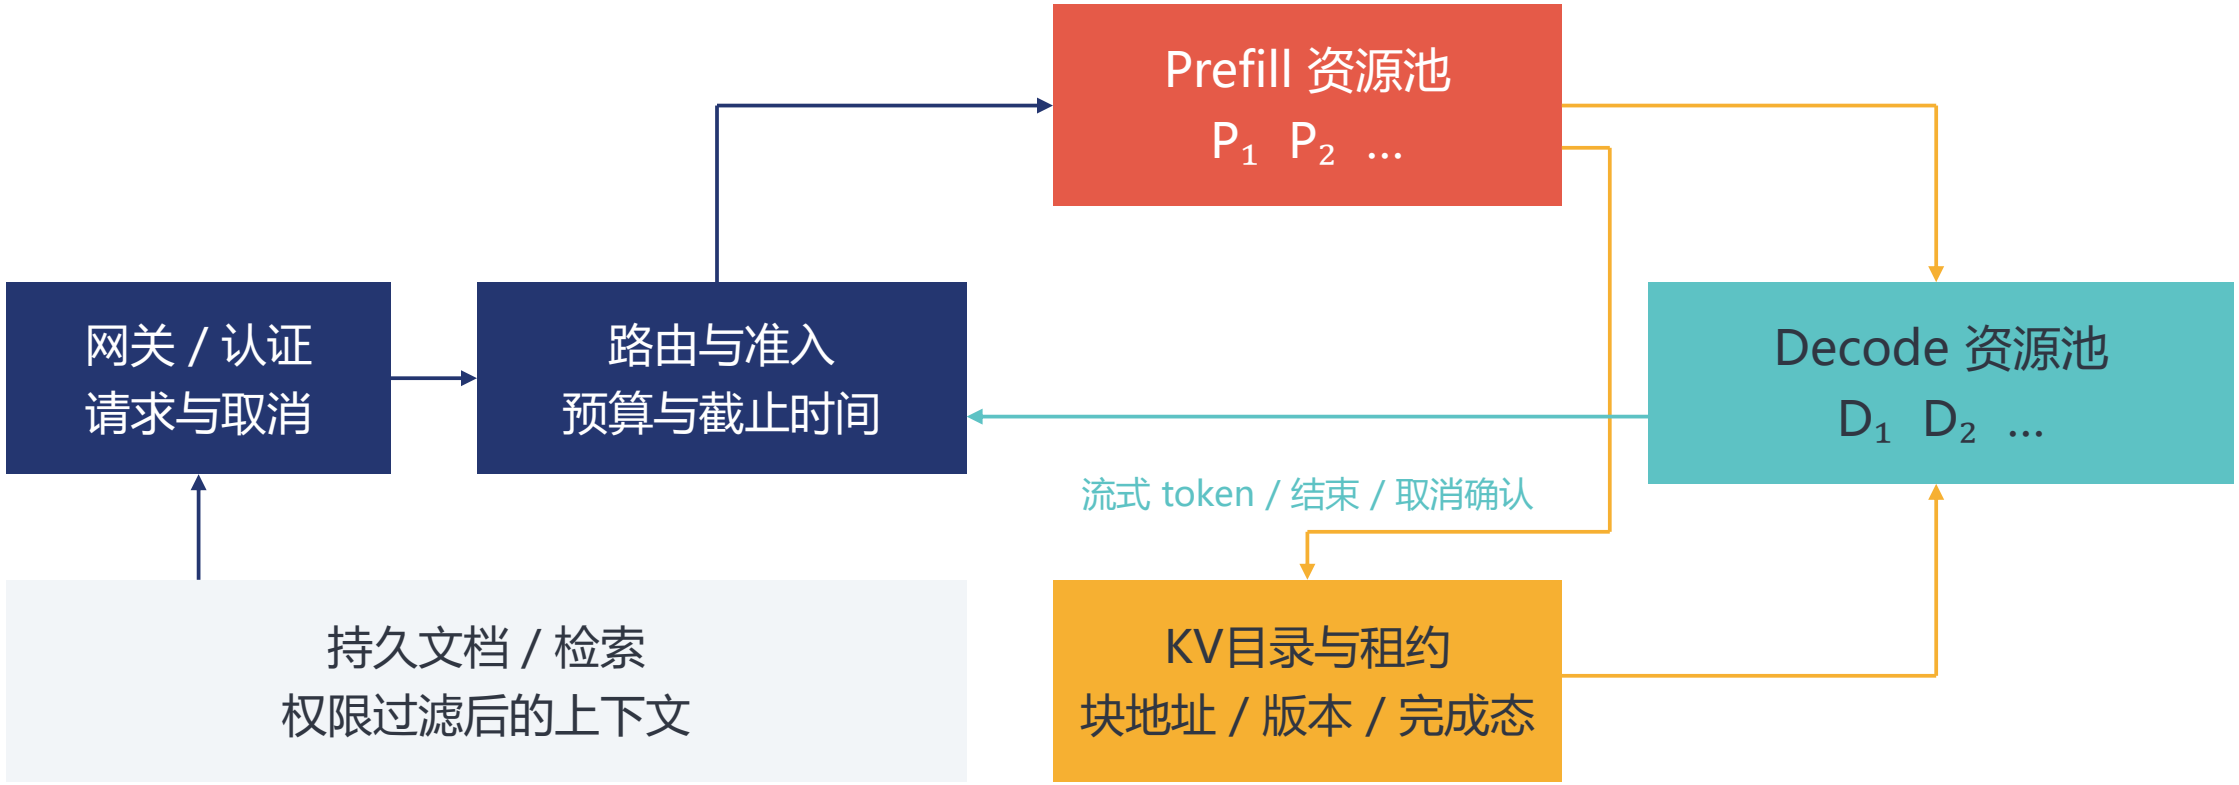
双 L40S 未支持 GPU P2P；解耦先解决了输出卡顿，传输完成检测与拷贝路径仍支配首 token。

TP / PP / DP / EP 解决不同的扩容约束

方式	拆分对象	主要收益	主要代价	本场景起点
TP	单层张量 / 算子	分摊权重与计算	每层集合通信；要求高带宽	模型能单卡时先测TP=1
PP	模型层 / 流水阶段	跨卡容纳大模型	流水气泡；阶段间等待	模型跨节点时考虑
DP	完整模型副本	请求水平扩容	重复权重；缓存分散	单卡可装下时增副本
EP	MoE专家	专家权重分布	token All-to-All；负载不均	Qwen2.5-7B为稠密模型
组合	TP×PP后再复制	适配容量与服务流量	运维和路由状态增多	P池与D池分别寻找配置

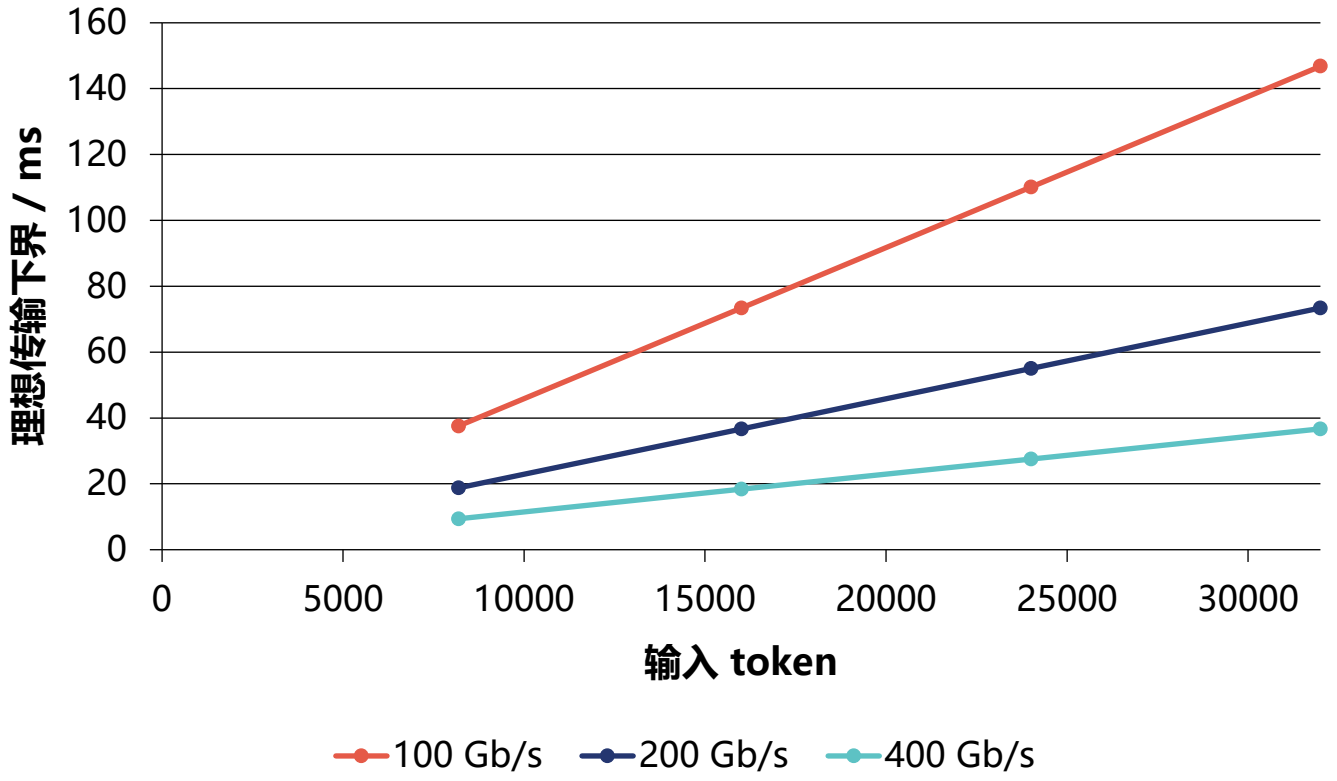
先满足单实例显存与时延，再复制实例扩吞吐；跨节点 TP 的通信成本必须与拆池传输一起测。

P/D 解耦将调度、KV 交接与输出流组成闭环



计算路径、KV数据路径、取消与租约控制路径分别限流；Decoder接管成功后才释放源端驻留。

网络线速给出下界，交接开销决定真实 TTFT



8,192 token → 448 MiB
100 Gb/s：37.6 ms
200 Gb/s：18.8 ms
400 Gb/s：9.4 ms

T交接 = 分配 + 协议 + 拷贝 + 完成检测 + 排队

公式按100%线速、无争用计算；实测要包含GPU↔NIC路径、主机中转、块布局变换和并发传输。

路由在缓存命中与队列等待之间做显式权衡

首 token 前主要开销：排队 + 未命中 Prefill + KV 交接

候选实例（示例）	缓存命中	排队 / 执行 / 交接	首 token预计
A：会话亲和	6,144 token	0.80 + 0.20 + 0.02 s	1.02 s
B：空闲副本	0 token	0.05 + 0.65 + 0.02 s	0.72 s
路由动作	选B并更新会话位置	携带相同token IDs、模型和模板版本	优先满足deadline

会话状态：conversation_id → 模型版本 → token前缀哈希 → KV位置 / 租约

多轮回传 KV 时必须保持聊天模板与实际 token 前缀一致；删除历史推理片段会破坏缓存语义。

资源池按瓶颈独立扩展，拓扑优先级进入调度

节点 1 · 同机高速互联

P分片
同层KV生产

D分片
同层KV消费

对应层KV留在本节点；PP激活跨节点

节点 2 · 同机高速互联

P分片
同层KV生产

D分片
同层KV消费

对应层KV留在本节点；PP激活跨节点

跨节点网络：测量端到端有效带宽与拥塞。
DistServe在25Gb/s跨节点测试床将对应阶段P/D配对到同节点；拓扑约束改变最优并行组合。

公开结果的比较单元必须固定模型、负载和 SLO

DistServe 2024	vLLM基线	DistServe	条件
代码补全 / OPT-66B	1.0×请求率	5.7×请求率	HumanEval；TTFT125ms / TPOT200ms
文档摘要 / OPT-66B	1.0×请求率	4.3×请求率	LongBench；TTFT15s / TPOT150ms
统一口径	每GPU达标请求率	目标达标率90%	FP16；A100-80GB；Poisson到达

MLPerf Server：带延迟约束的随机到达
MLPerf Offline：批量到达，优化总吞吐

采购复测锁定：模型/精度/准确率门槛
输入输出分布/硬件数/场景/计量单位

长上下文助手应重放自己的8K/32K分布；DistServe摘要输入受OPT窗口约束，被截到2,048 token。

失败恢复先保护流式语义，再选择重算或重试



重试共享总预算并加入退避与抖动；Decode故障同时影响多个Prefill源时，限流可阻断重试风暴。

把端到端 SLO 拆到队列、计算、传输与回收

层级	核心指标	联动诊断
用户边界	TTFT / 请求TPOT / ITL / 联合达标率	按输入长度、租户、热冷缓存分桶
调度	等待请求、队列token、抢占次数	排队升高且GPU未满：查准入或通信阻塞
GPU / KV	活跃序列、KV占用、前缀命中token	高抢占 + 低命中：查增长预留和缓存抖动
传输	字节、时长、失败、驻留	分离有效带宽与通知/排队时间
回收	取消耗时、泄漏块、重算请求	超时后仍占块会造成持续容量下降

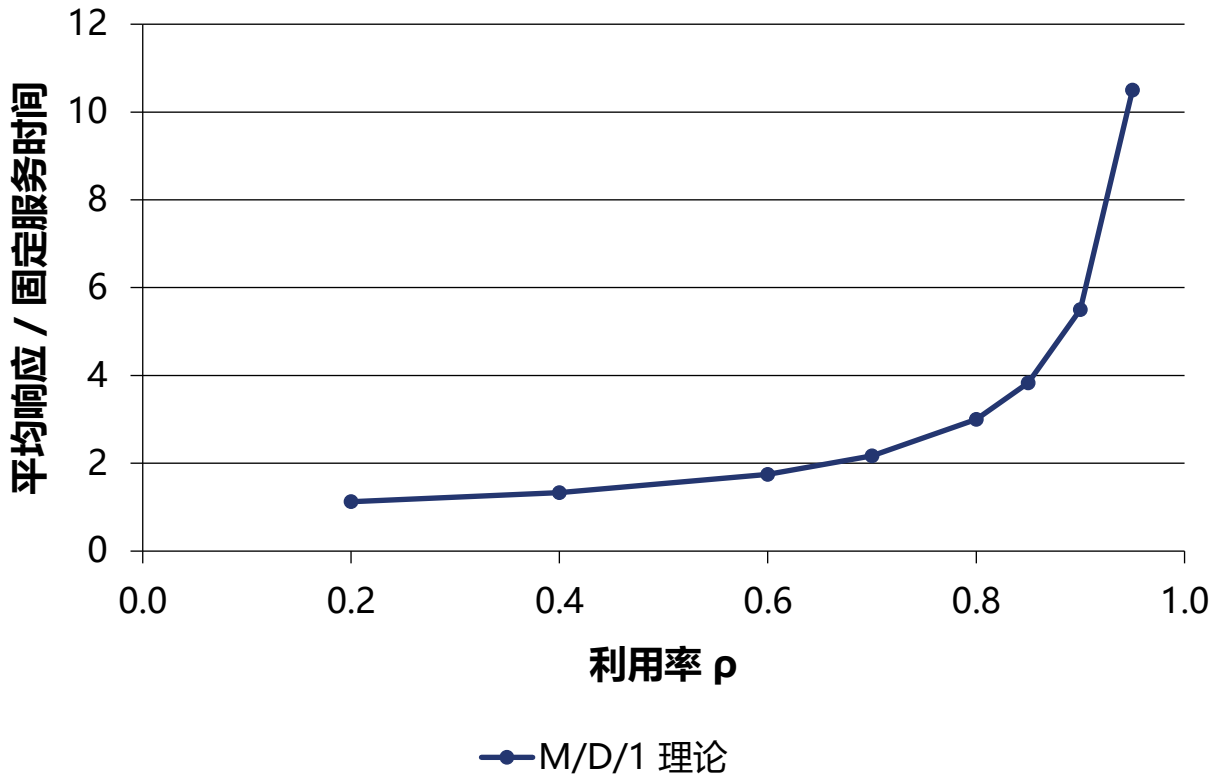
trace_id：接入 → 检索 → 排队 → prefill → transfer → decode → 结束/回收

指标分位数描述分布，trace解释个案；直方图桶应覆盖2s与40ms目标附近，避免聚合掩盖长尾。

容量边界对上下文长度与利用率都高度敏感

输入token	每会话KV上界	24GiB KV池上限
8,192	462 MiB	53
16,000	889 MiB	27
24,000	1,326.5 MiB	18
32,000	1,764 MiB	13

输出固定256 token；BF16 KV；
未计尾块、碎片与安全余量。



理论ρ从0.8升至0.95，平均响应从3倍升至10.5倍服务时间；扩容阈值应留在排队曲线拐点前。

成本除以有效工作量，重试和闲置才会显形

每千个达标请求成本 = 1,000 × 每小时总成本 / (3,600 × goodput)

设计算例（成本单位CU）	同机副本	P/D池
GPU + CPU/网络每小时费用	2×1 + 0.2 = 2.2 CU	2×1 + 0.4 = 2.4 CU
完成请求速率 / 联合达标比例	1.0 req/s / 80%	1.0 req/s / 95%
有效请求速率	0.80 req/s	0.95 req/s
每千个达标请求成本	0.764 CU	0.702 CU
与同机成本相等所需达标率	80%	87.3%（相同完成速率）

若解耦达标率低于87.3%，这组算例的额外运行费用尚未被有效产出抵消；成本门槛应进入压测。

上线用相同流量回放逐步验证，并保留同机回退池

01 正确性

冻结模型、tokenizer与聊天模板。

冷/热缓存输出对齐；检查跨租户隔离、引用与取消语义。

02 性能边界

同GPU预算对照
独立副本与P/D。

扫描长度与到达率、
前缀命中和突发；
测量联合达标率。

03 故障演练

注入慢链路、进程退出与租约过期。

确认重试受控，
故障后KV块已回收，
输出没有重复拼接。

04 灰度与回退

从小流量逐档放量。

达标率或错误率越线，
立即切回同机池；
保留完整链路追踪。

设计示例放量门槛：每档至少覆盖一个业务高峰；联合SLO≥95%，并核对正确性与每千达标请求成本。

先消除浪费，再用解耦隔离确证的阶段干扰

测到的主瓶颈	优先动作	转向下一步的证据
模型或KV放不下	量化/模型并行/长度与并发预算	保留质量目标后，内存与延迟稳定
重复前缀计算多	前缀缓存 + 版本/权限一致的路由	命中token上升，排队与prefill耗时下降
长prefill使输出卡顿	先调chunked-prefill；同预算对照P/D	真实KV交接开销小于TTFT余量
到达量超过单实例容量	复制实例；P与D按各自队列扩池	联合SLO与单位有效成本同时改善

架构选择的三条硬边界

显存容纳完整活跃状态 • 网络交接落在TTFT预算内 • 有效吞吐足以覆盖运营成本