容量：128k 上下文把显存并发压至 3 路

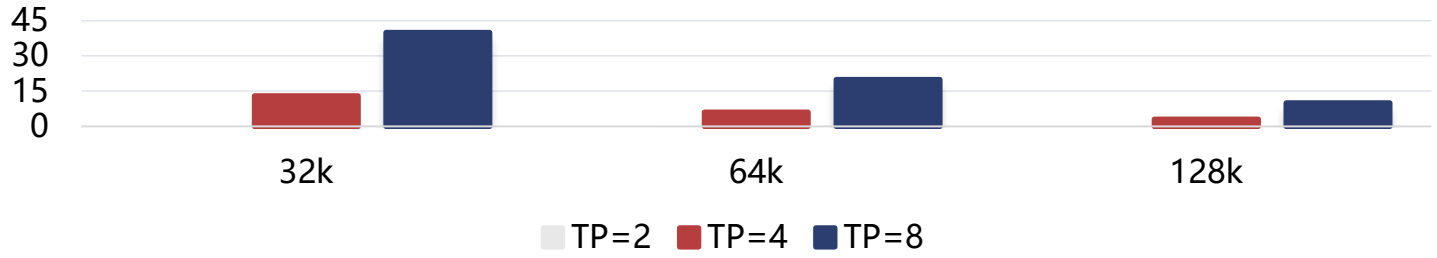
长上下文推理集群：容量、排队与能耗如何共同决定部署方案 · SKILL应用测试

一副本 = 4 × H100 SXM；BF16 权重预算 140 GB



GiB / 副本

可同时驻留的完整序列数



KV 随总长度线性增长

2 × 80 层 × 8 KV 头 × 128 维
× 2 byte = 320 KiB / token

32k / 64k / 128k
每序列占 10 / 20 / 40 GiB

接纳规则直接绑定显存

可用 KV = 4 × 80 GB − 140 GB
− 4 × 8 GiB = 135.6 GiB

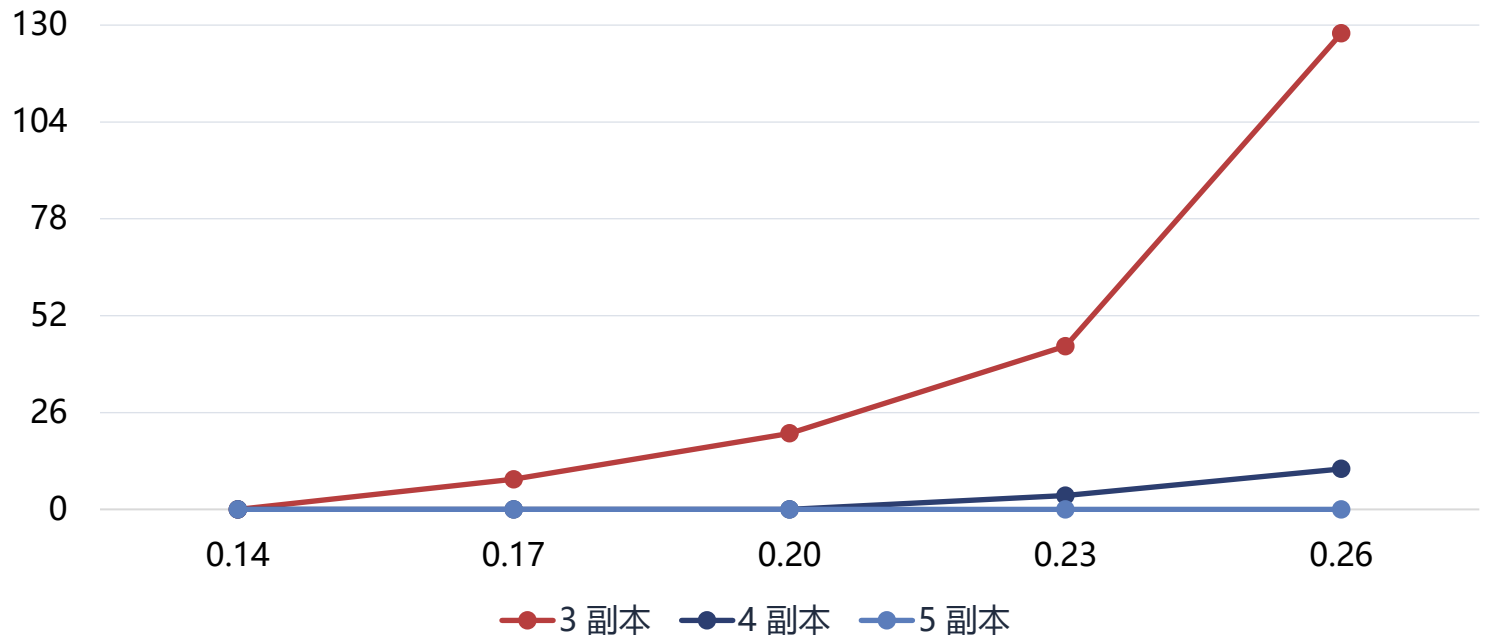
并发上限 = floor(135.6 / 40)
128k：3 路；留存余量 15.6 GiB

部署含义：先按“输入 + 最大输出”预留 KV；TP=4 的 128k 请求每副本最多接纳 3 路。

排队：85% 占用率已把尾部等待放大

128k 固定长度规划情景：每副本 3 个服务槽；平均驻留 32 s；到达率 λ = 0.24 请求/s

队列等待 p95（秒）随流量陡升



横轴：到达率（请求/s） · 目标：队列等待 p95 ≤ 10 s

扩容应在排队拐点之前

副本 / GPU	占用率	等待 p95
3 / 12	85.3%	58.5 s
4 / 16	64.0%	5.9 s
5 / 20	51.2%	0.0 s

M/M/c：$c = 3r$；$\rho = \lambda \times 32 / c$

$P(Wq>t)=C\cdot\exp[-(c/32-\lambda)t]$

$Wq95=\max[0,\ln(C/0.05)/(c/32-\lambda)]$

C 为 Erlang C 等待概率。

Poisson 到达；指数服务；FCFS。

32 s 驻留须用并发回放校准。

4 副本把占用率降至 64%，p95 等待降至 5.9 s；流量 +20% 时应重算接纳与副本数。

架构：拆分预填充前，先算 KV 搬运时间

DistServe（OSDI 2024）分离 Prefill / Decode，以减少阶段干扰；新成本是 KV 传输与额外权重副本

路由、接纳与两阶段资源池

接纳 / 路由
按长度分池；预留最大 KV

↓

Prefill 池
分块预填充；缓存公共前缀

↓

Decode 池
维持 TPOT；按 KV 余量接纳

KV 传输：Prefill 完成后进入 Decode 池

一次完整 KV 搬运的时间（秒）

总长度	100 Gb/s	200 Gb/s	400 Gb/s
32k	1.23	0.61	0.31
64k	2.45	1.23	0.61
128k	4.91	2.45	1.23

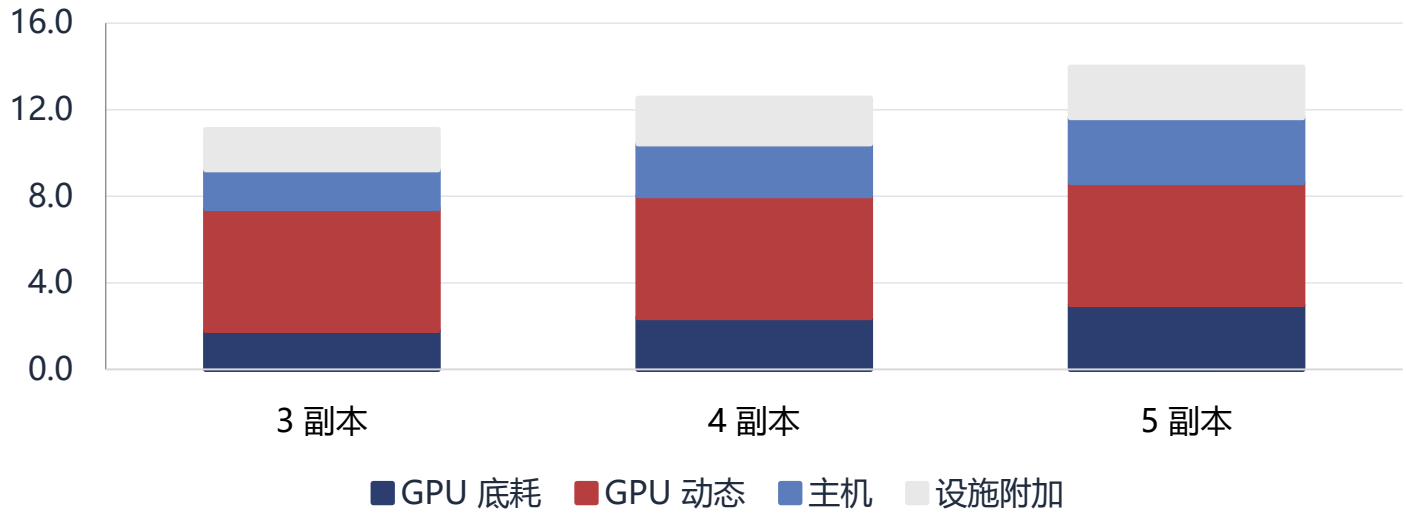
T = KV字节 / (带宽 ÷ 8 × 70%)
128k：42.95 GB / 35 GB/s = 1.23 s
λ = 0.24 时平均搬运 82.5 Gb/s；
2 倍突发需 164.9 Gb/s 有效吞吐。

若 TTFT 预算为 2 s，400 Gb/s 搬运已占 1.23 s；先测阶段干扰，再决定拆分与缓存复用。

能耗：16 张卡落在延迟与电力交集

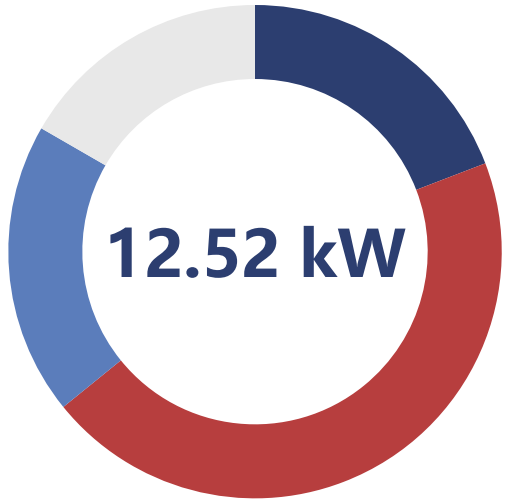
同一到达率 0.24 请求/s；功率随占用线性变化；GPU 150–700 W、主机 0.6 kW/副本、PUE = 1.20（假设）

副本越多，闲置与主机底耗越高



设施侧功率（kW） · 电力上限 13 kW

4 副本：电力构成



14.49 kWh / 千请求

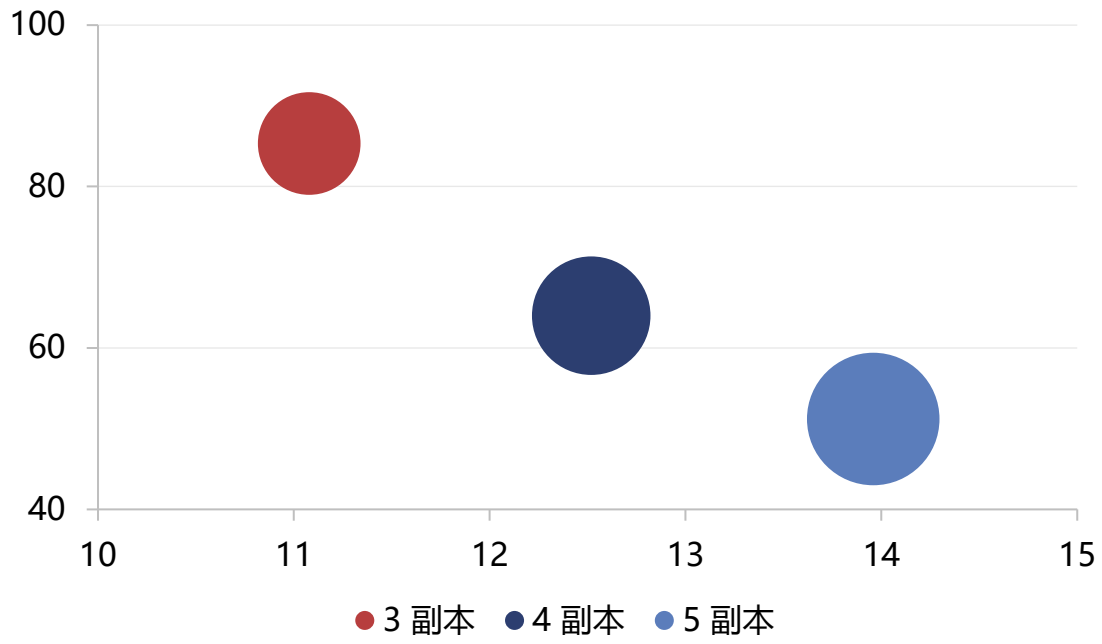
$P = 1.2 \times r \times [4 \times (0.15 + 0.55\rho) + 0.6]$ kW；每千请求用电 $E = P / (3.6\lambda)$。

3 副本超出等待 SLO；5 副本需 13.96 kW；4 副本在本情景满足 10 s 等待与 13 kW 电力约束。

部署：以 4 副本起步，把容错预算单列

容量、等待与功率共用同一输入：128k、3 槽/副本、32 s 驻留、0.24 请求/s；气泡面积代表服务槽数

占用率—功率决策平面



纵轴：槽占用率（%） · 横轴：设施功率（kW）

上线闸门：回放与容错一起过

方案	GPU	等待 p95	功率/kW	判断
3 副本	12	58.5 s	11.08	等待超标
4 副本	16	5.9 s	12.52	正常推荐
5 副本	20	0.0 s	13.96	电力超标

① 按 32k / 64k / 128k 分桶回放，核对 TTFT、TPOT、KV 峰值与达标吞吐。
② N−1 需 5 副本、约 14 kW 电力预算。
③ +20% 流量使 4 副本等待 20.6 s、功率 13.87 kW；13 kW 下限流 0.256/s。

决策顺序：长度预算决定槽数；回放校准驻留时间；排队选副本；最后同时校验功率与 N−1。