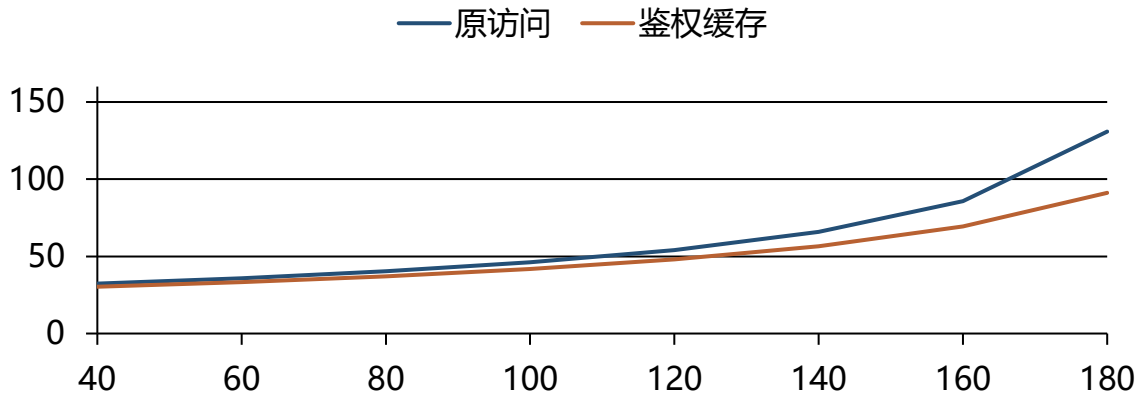
模拟网络：鉴权缓存降低高负载排队延迟

A 负载—延迟：缓存降低高负载排队

均值 ms / 请求率 次·秒⁻¹；鉴权访问比 0.90→0.65

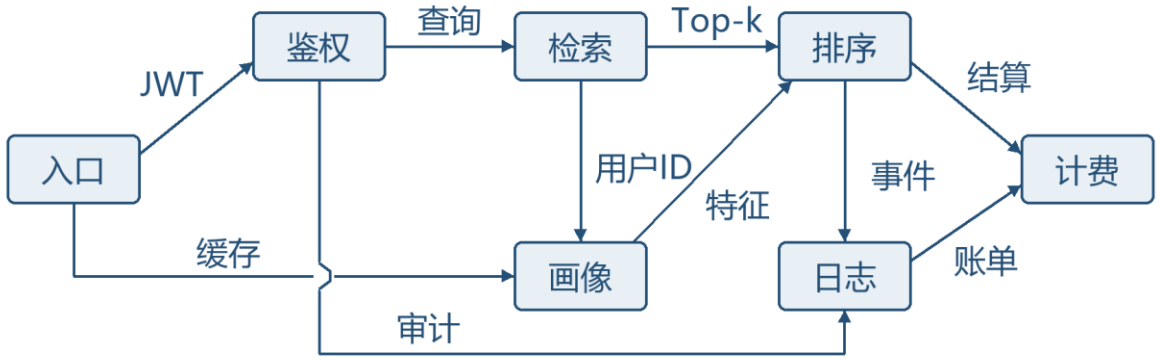


B 服务利用率：鉴权先接近饱和

	40	60	80	100	120	140	160	180
入口	0.18	0.27	0.36	0.45	0.55	0.64	0.73	0.82
鉴权	0.20	0.30	0.40	0.50	0.60	0.70	0.80	0.90
检索	0.16	0.25	0.33	0.41	0.49	0.58	0.66	0.74
排序	0.17	0.26	0.34	0.43	0.51	0.60	0.69	0.77
画像	0.14	0.21	0.28	0.35	0.42	0.48	0.55	0.62
日志	0.13	0.19	0.25	0.32	0.38	0.45	0.51	0.57
计费	0.10	0.15	0.20	0.25	0.30	0.35	0.40	0.45

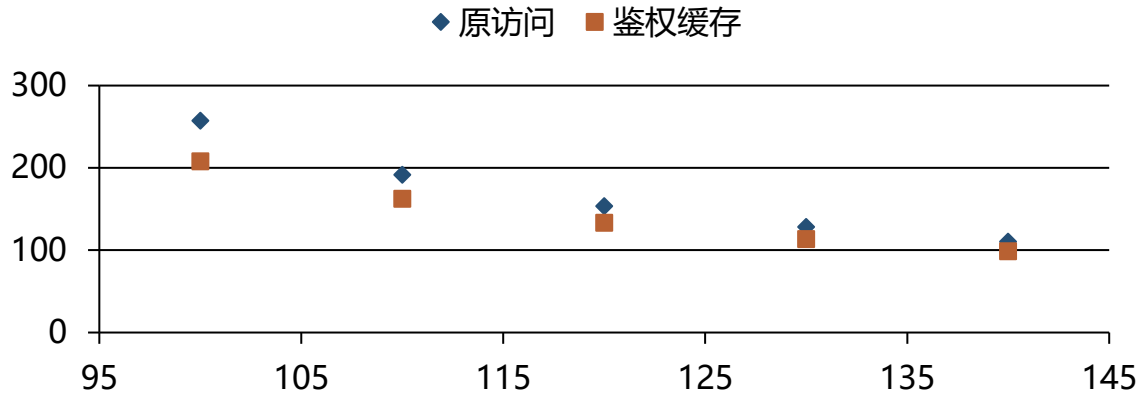
请求率 λ（次/秒） →；单元格：利用率 ρ

C 请求依赖：同步链与旁路交织



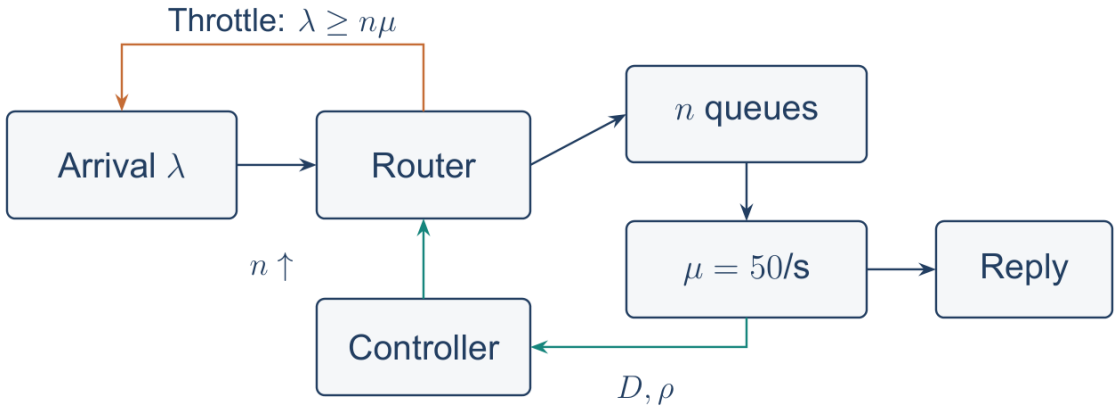
D 容量选择：扩容降低两种策略的延迟

λ=160；3×均值 ms / 容量成本指数（基准=100）



推理服务容量决策：负载与可靠性（模拟）

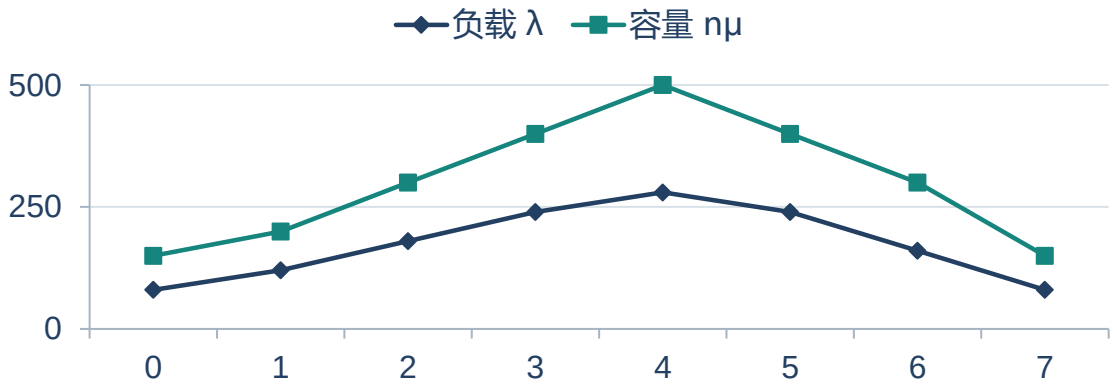
A 反馈调度与准入分支



B 平均延迟 ms；λ 单位 req/s；— 为失稳

n / λ	120	150	180	210	240	270	300
4	50	80	200	—	—	—	—
5	38	50	71	125	500	—	—
6	33	40	50	67	100	200	—
7	30	35	41	50	64	88	140
8	29	32	36	42	50	62	80
9	27	30	33	38	43	50	60

C 服务容量与负载（req/s；横轴 min）



D 均匀路由的队列模型

系统 | 泊松到达；λ < nμ

ρ = λ/(nμ)；D = 1000/(μ − λ/n) ms

策略 | n = ⌈λ/30⌉，每分钟调整

1 min 平台、瞬时调度；比较稳态均值

节点 | μ = 50 req/s，指数服务

均匀路由；功率 P = 120n + 1.6λ W

0.933
峰值 ρ | n=6

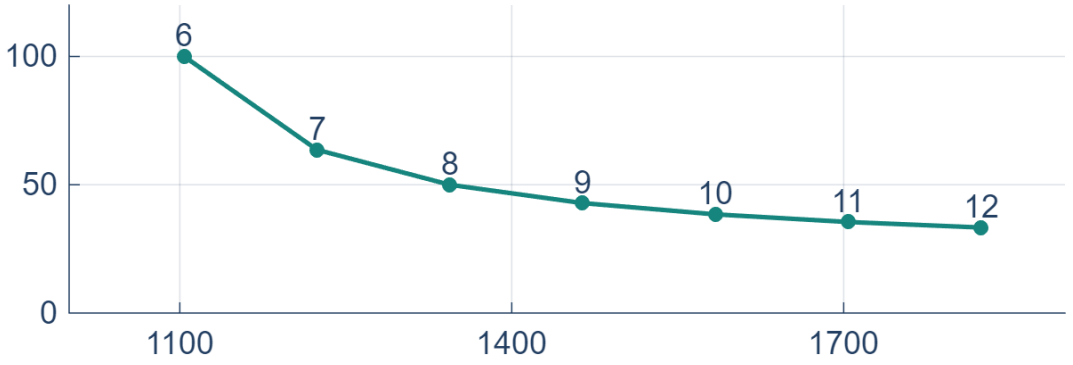
10
自适应副本数

20 ms
单次服务均值

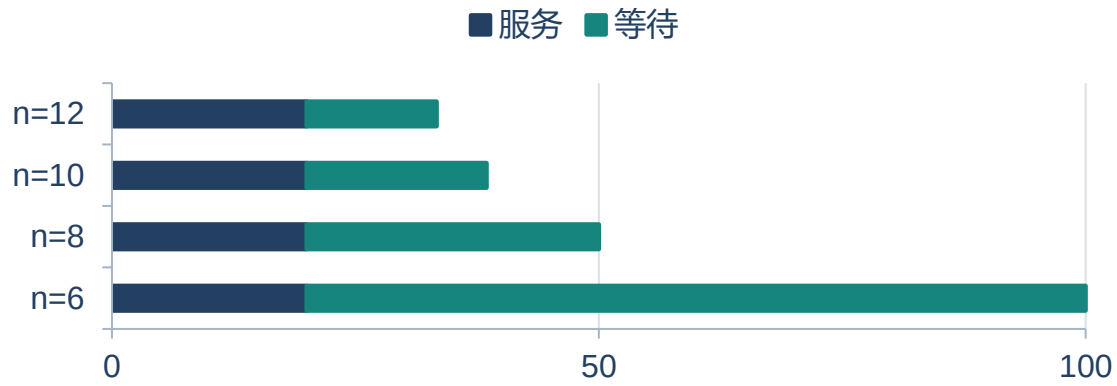
λ = 280 req/s 时，固定 n = 6 的 ρ = 0.933；增至 n = 10 后 D 从 300 ms 降至 45.5 ms。

成本—延迟权衡：40 ms 目标需要 10 副本

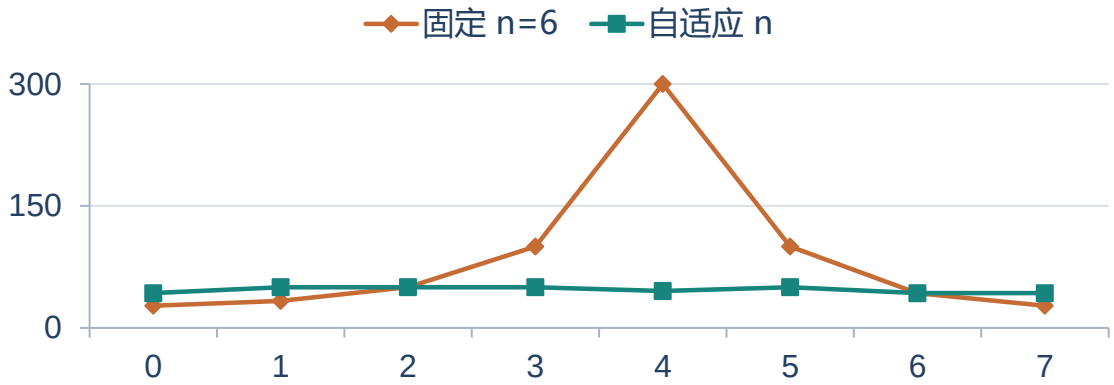
E 功率 W → 延迟 ms；点标签为副本数



F 延迟分解（ms）：服务时间为 20 ms



G 平台平均延迟（ms；横轴 min）



H 目标延迟决定最少副本数

目标 D	120/s	240/s	280/s
40 ms	5	10	12
60 ms	4	8	9
100 ms	3	6	7

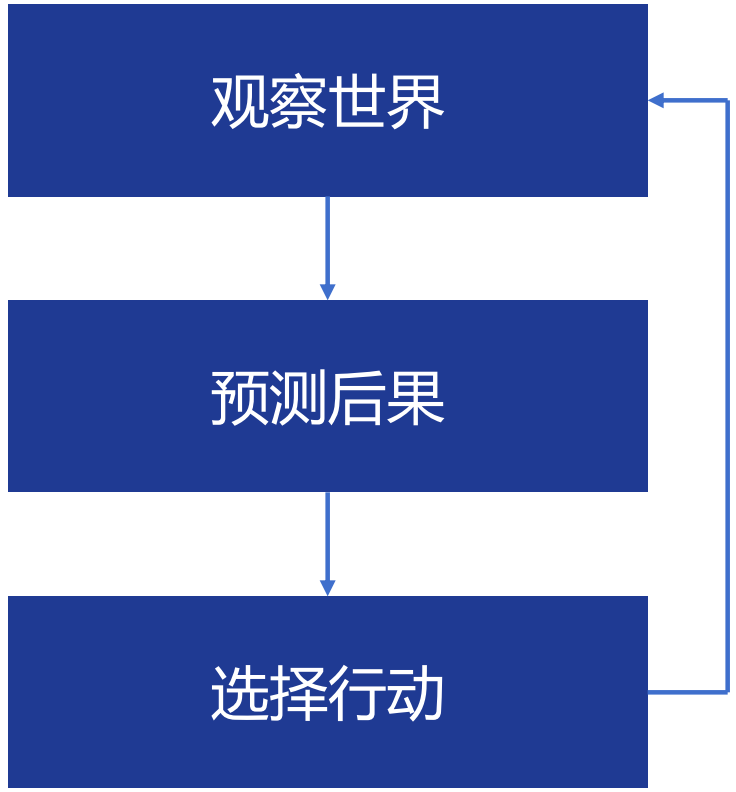
λ = 240 req/s：n = 10 时 D = 38.5 ms、功率 1584 W；较 n = 6 增加 480 W，等待减少 61.5 ms。

世界模型 2026

从视频预测
到可行动的仿真环境

技术已进入产品与工程系统，
价值取决于任务成功和现实验证。

SKILL应用测试
2026 年 10 月 17 日



世界模型的价值，来自动作改变未来

交互视频	画面 + 控制输入	预测后续画面	人或代理探索

Genie 3：720p、24 FPS

潜在状态	观察 + 动作序列	预测未来表征	规划器选择动作

V-JEPA 2-AC：目标图像规划

持久三维	文本、图像、视频	生成可编辑空间	引擎渲染与交互

Marble：导出 splat 与 mesh

把“生成什么”与“如何验证行动结果”连接起来，才形成可用的仿真系统。

2025—2026：研究演示走向可访问的系统

2025.06 V-JEPA 2
视频预训练连接机器人规划

→

2025.08 Genie 3
实时生成可探索环境

→

2025.11 Marble
开放生成与三维资产导出

2026.01 Project Genie
Ultra 用户开始体验

→

2026.02 Waymo
驾驶动作与多传感器仿真

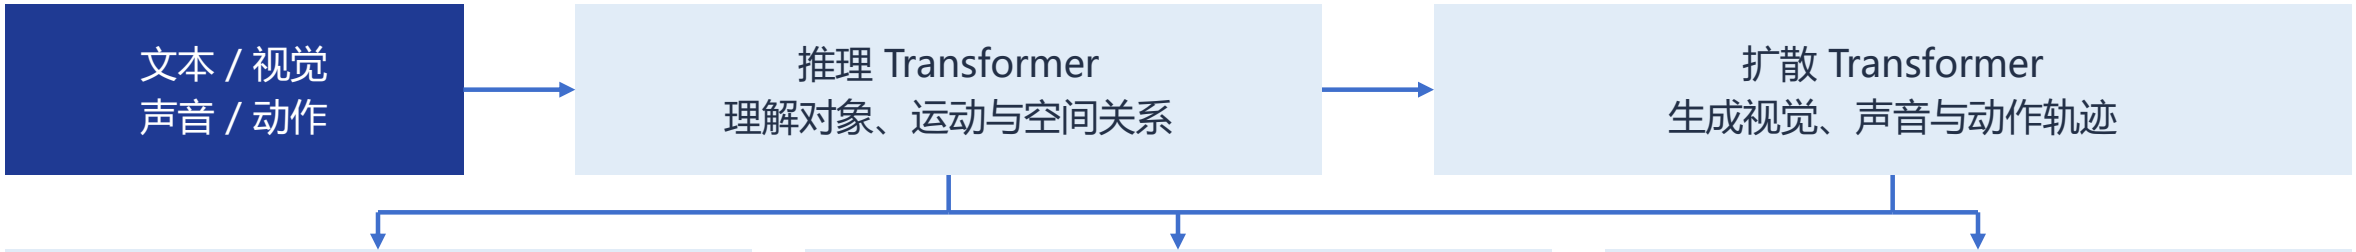
→

2026.05 Cosmos 3
推理、生成与动作统一

2026.09 World Labs 签署加入 AMD 的最终协议，预计年底前完成交易。
模型与计算平台开始更紧密地结合。

交互入口、领域适配与工具链正在形成产品；任务成功率与复现能力决定工程价值。

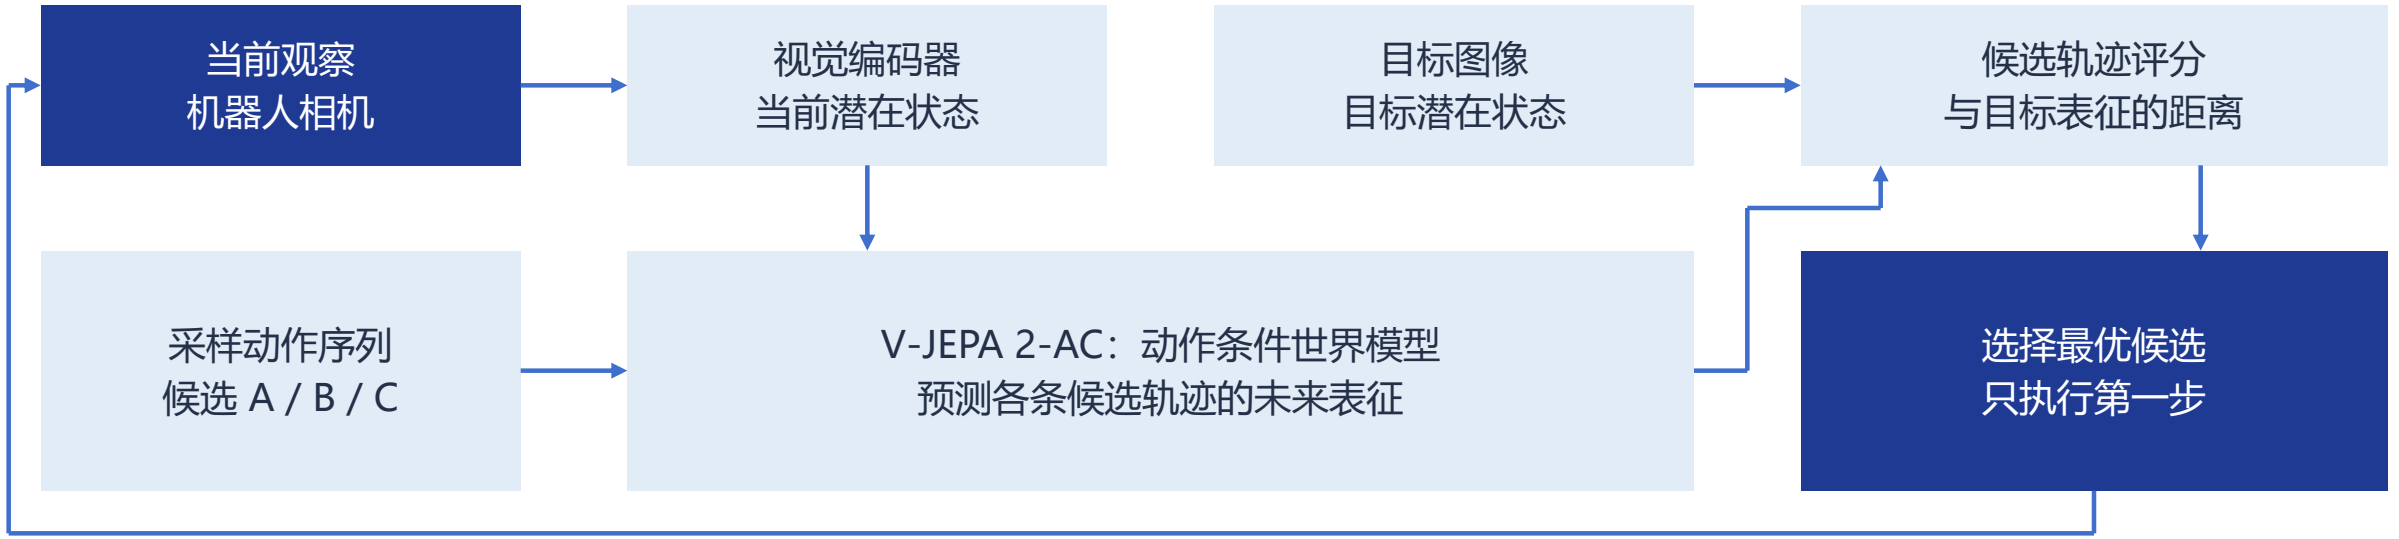
Cosmos 3 把推理与生成放入同一模型



理解	预测	行动
场景问答与物理推理	条件控制下的未来状态	具体机器人动作接口
4B · Edge 边缘部署 256p / 480p	16B · Nano 紧凑模型 理解、仿真与动作	64B · Super 高保真生成 较高计算需求

Cosmos 3 的工程交付，把开放模型、动作接口、后训练数据与部署算力接成工作流。

V-JEPA 2：在表征空间试走，再执行一步



>100 万小时
互联网视频预训练

<62 小时
DROID 机器人视频后训练

2 个实验室
Franka 机械臂零样本部署

V-JEPA 2-AC 将视频表征用于动作搜索，每轮执行后根据新观察重新规划。

Waymo：用可控长尾场景检验驾驶策略

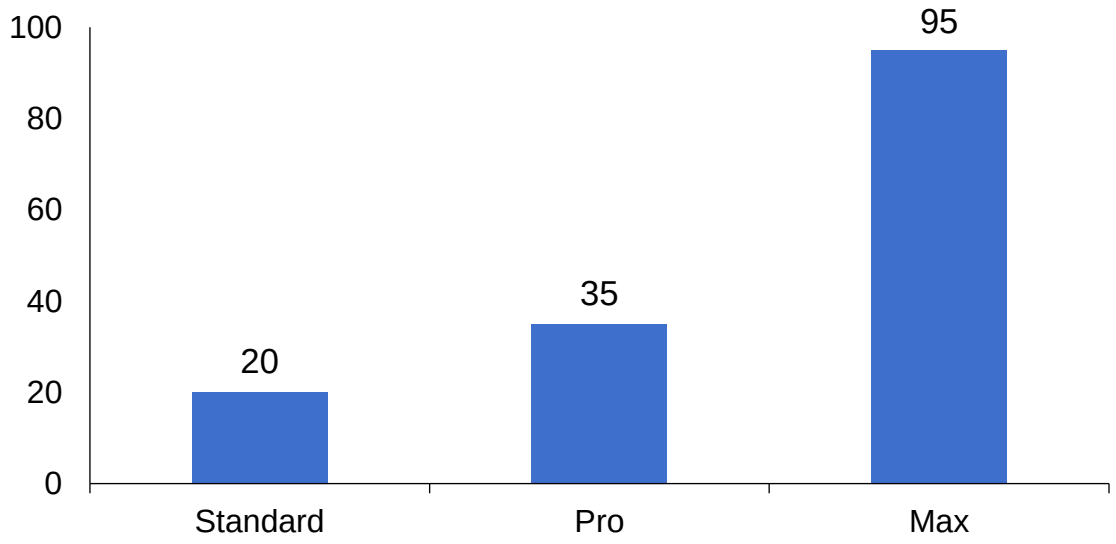


反事实问题：同一场景中，改变驾驶动作会发生什么？

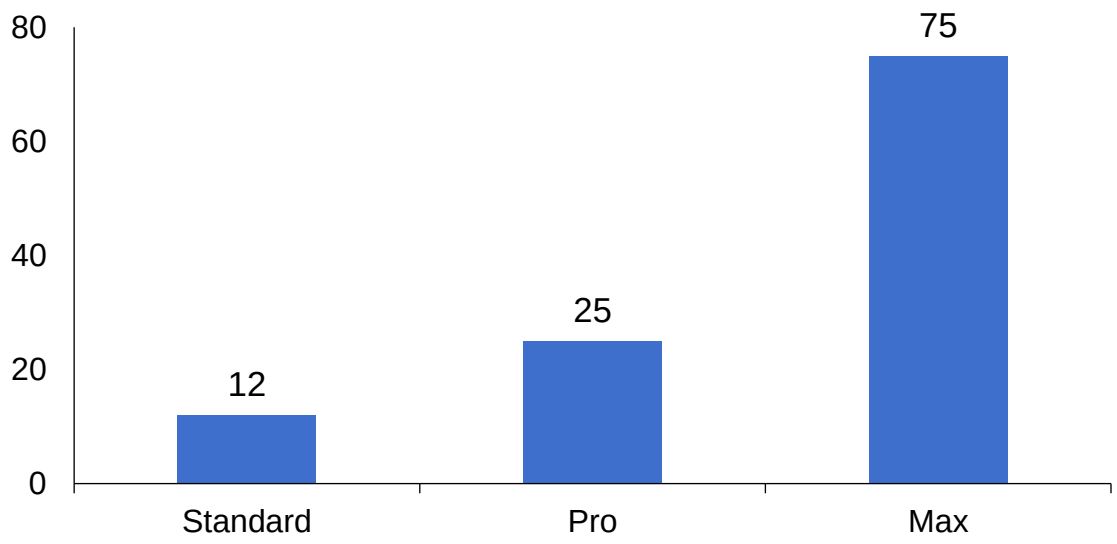
驾驶仿真的工程价值来自条件控制、传感器一致性与可复现的策略评估。

Marble 已把三维世界生成变成订阅产品

月费（美元 / 月）



世界生成额度（最多个 / 月）



Standard 支持导出 splat；Pro 增加高分辨率纹理网格与商业权利。
2026-10-17 的月度方案；生成上限为产品标示额度。

三维资产的交付价值取决于导出格式、编辑效率、商业权利与可用资产率。

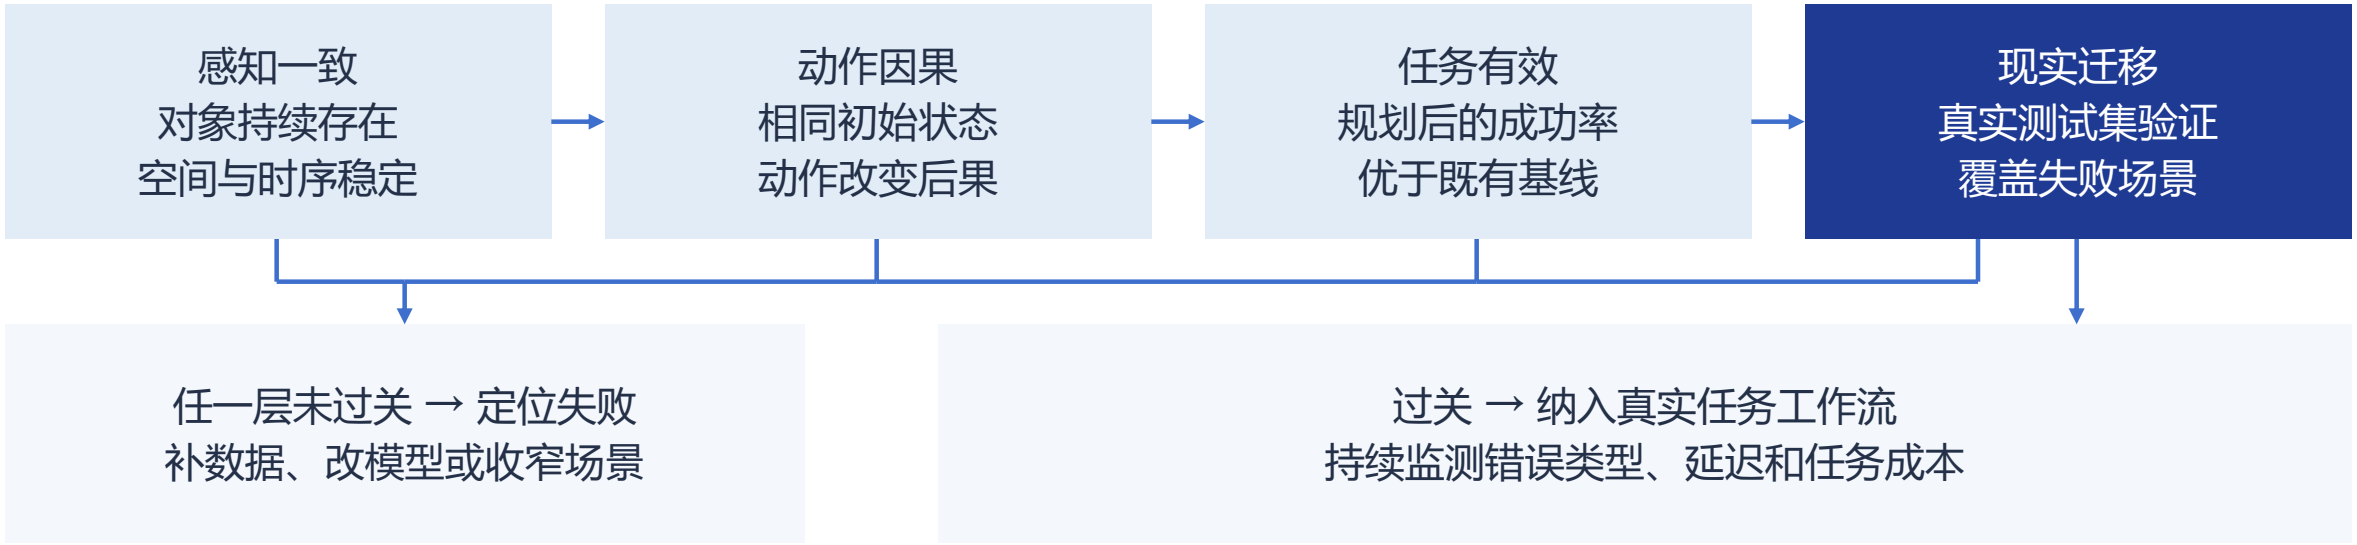
商业化分成四条路径，各自有不同的验收对象

交付路径	具体产品 / 系统	客户获得什么	主要验收关口
交互体验	Project Genie	可探索、可重混的世界	控制响应；60 秒体验时长
三维资产	Marble	可编辑并导出的空间	几何、材质、引擎集成
训练与测试	Cosmos / Waymo	可控的合成数据与场景	条件遵循；传感器一致性
机器人规划	V-JEPA 2-AC	以图像目标选择动作	任务成功；跨环境稳定性

体验产品按交互质量验收，工程系统按任务结果验收。
领域数据、动作接口与集成管线共同构成产品的交付系统。

三维资产、测试场景与机器人任务，为世界模型提供了具体的产品入口。

把评估从“看起来真实”推进到“任务有效”



每个有效任务成本 = （生成 + 筛选 + 集成 + 运行成本）÷ 通过验收的任务数

视觉伪影、控制迟滞和物理偏差，都会增加筛选成本并减少有效任务数。

先用真实数据校准仿真，再衡量任务收益；生成速度与视觉质量共同服务于这个目标。

未来 90 天：先拿到一个可验收的工作流

第 1—30 天	第 31—60 天	第 61—90 天
选定场景与既有基线 准备真实样本和失败分类	接入模型与资产管线 固定输入、动作和复测条件	开展真实任务对照 计算有效任务成本和收益

三维内容	资产能否进入引擎	编辑和导出是否可控	可用资产率与工时变化
机器人	目标与动作接口清晰	预测能否指导动作	真实任务成功与稳定性
驾驶仿真	长尾条件可描述	多传感器输出一致	场景覆盖与策略改进

推进条件：有效任务质量达标、相对基线有收益、失败可定位并复现。

世界模型正在成为仿真与内容生产的基础组件；竞争优势来自数据、评估与工作流的联结。

Do-JEPA

从预测未来，到预测动作效果

From Masking to Intervention in Latent World Models

论文作者 Hossein Resani · Javen Qinfeng Shi
Adelaide University · AIML / Responsible AI Research Centre
arXiv:2609.37378v1 · 2026 年 9 月 29 日



从一次状态分叉，学习动作改变了什么、作用于哪里、如何传播。

让两个未来只在动作上不同

掩码训练：改变可见信息

C-JEPA 隐去物体槽，再从其余槽补全。
目标仍来自同一条日志轨迹：背景与结果的
相关性仍可能被模型用来预测。

历史 z → 隐去槽 → 预测未来

普通预测损失只约束未来是否接近目标，
没有指定变化中哪一部分由动作造成。

参考动作通常为物理 no-op；CausalWorld
使用围绕当前关节位置镜像的命令。

配对干预：改变世界发生的过程

完整状态 s_t + 相同噪声 / 背景

动作分支

$$a \longrightarrow z^{a}$$

参考分支

$$a_{\varnothing} \longrightarrow z^{a_{\varnothing}}$$

$$\Delta z = z^{a} - z^{a_{\varnothing}}$$

示例 $z^{a} = (3, 2, 7), \quad z^{a_{\varnothing}} = (1, 2, 7)$

差分 (2, 0, 0)：共享的后两维抵消。
它描述当前状态下“换动作”的效果。

配对消去两分支共享的成分；状态与背景交互的潜在成分不会自动消失。

差分之外，还要监督入口、传播与不变部分

历史 → 无动作基线 b	+	入口 m → 残差 r → 门控 G	=	$\hat{z}^a = b + r$

监督项	训练目标（省略批次平均）	具体职责
效果损失	$\|\widehat{\Delta z} - \Delta z\|_2^2$	约束动作造成的变化量与方向
入口损失	$\mathrm{CE}(y, m), \quad y_i \propto \|\Delta z_{t+1}^i\|_2^2$	首步响应能量归一化，指定直接作用槽
传播损失	$\mathrm{BCE}_{\mathrm{bal}}(G, y^{\mathrm{edge}}) + \lambda_{\mathrm{sp}}\|G\|_1$	响应晚一拍的槽对提供传播标签
槽不变损失	$\sum_{j \notin R}\left(\|\widehat{\Delta z}^j\|_2^2 + \lambda_g \sum_i G_{ji}\right)$	未响应槽效应归零，关闭流入门
背景损失	$\|\widehat{\Delta z}(c) - \widehat{\Delta z}(c')\|_2^2$	同物理状态换背景，效果应一致
总目标	两分支预测 + 上述加权损失 + R	保留事实预测与防坍缩正则

槽模型把动作放入残差路径；全局 LeWM 潜在只有 K=1，使用效果损失而无槽门控。

训练用配对真值，测试只给历史与动作

从模拟器到监督

保存完整状态 → 两次 rollout → 编码未来
首步差分：入口；响应时间：传播；
全时域无响应：不变槽；换背景：context twin。

从模型到检验

预测效果：同一历史输入动作与参考动作后相减。
规划：使用事实预测搜索动作。
物理评估：训练 / IID 数据拟合读出探针。

训练变体	使用的数据	额外约束
Obs	事实分支	普通未来预测
Aug	事实 + 参考；有时含背景孪生	各样本独立预测，不比较分支
Paired	与 Aug 完全相同	加效果损失
Do-JEPA full	配对 + 背景孪生	加背景损失；槽模型按设置加槽损失

指标分工：事实误差测未来；效果误差测动作差分；AUROC 测是否响应；结构 F1 测路径。

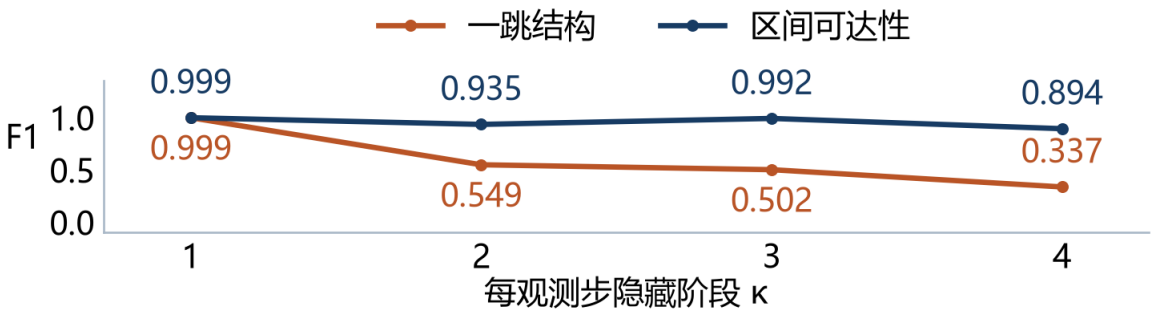
Aug 与 Paired 看见相同数据；两者的差异才能隔离“显式比较两条未来”的贡献。

预测得准，不会自动把动作送到正确入口

四物体环 + 三干扰槽：测试反转训练相关性

入口消融	Top-1 ↑	干扰槽 mask ↓	效果 MSE ↓
稀疏 mask	0.000	1.000	0.0110
+ 效果损失	0.000	1.000	0.0100
+ 入口损失，温度 1.0 → 0.7	0.9995	0.000082	0.00093

效果损失可由后续传播补偿错误入口；稀疏性决定“几个槽”，首步标签决定“哪个槽”。



传播监督的独立证据

边 AUROC：0.624 → 0.975

3/3 种子恢复四条环边。

观测间隔内多跳传播，会混合先后顺序。

入口要看首步响应；传播要看时间顺序。观测变粗时，可识别的关系转向区间可达性。

背景不变性必须落到承载物理的潜在方向

状态 Push-T：背景损失权重 0.25

两次独立种子的 OOD 误差降低 43.9% / 55.2%；
IID 误差增加 4.2% / 3.5%。
权重由另一种子的 IID–OOD 曲线选定。

为什么潜在惩罚可能伤害物理精度

CausalWorld 诊断：192 维空间中两个方向
承载约 99.8% 的解码物理误差。均匀压低
潜在差异，可能把误差留在这些关键方向。

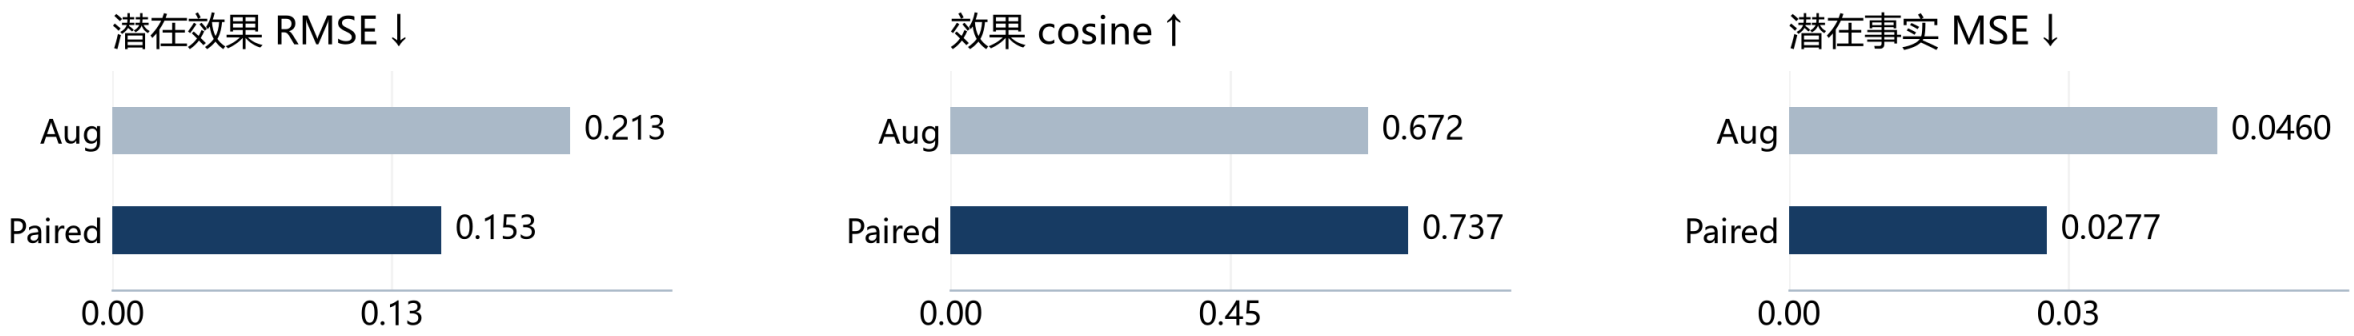
冻结视觉槽 / OOD	事实误差 (px) ↓	响应效果 (px) ↓	响应 AUROC ↑	背景敏感 (px) ↓
Mask	39.02	20.25	0.485	19.91
Aug	24.88	16.79	0.666	12.59
Do-JEPA	27.19	17.89	0.691	13.74

相对 Mask 六项指标均改善；相对同数据 Aug，响应检测更好，事实与效果误差更高。

固定状态变量上，背景孪生能消除捷径；学习到的潜在距离与物理距离可能不一致。

像素端到端：效果收益随训练动作分布迁移

LeWM 微调：同数据 Aug → Paired（富集配对，50% 响应）



潜在空间由各模型自己学习；还需用物理位移读出检验动作效果。

响应物理 RMSE 变化	自然动作测试	未按结果筛选 holdout
自然动作训练	−13.5%	−5.5%
富集动作训练	+5.9%	+4.7%

自然专家动作训练后，响应物理效果误差下降 13.5%；独立抽取动作的 holdout 下降 5.5%。

CausalWorld：训练方式决定事实精度的代价

从头训练，α = 1：Paired 相对 Aug（3 个独立基准实例）

测试偏移	响应效果 RMSE	潜在背景敏感	事实 RMSE	响应 AUROC
视觉相关性反转	−3.9%	−66.2%	+52.8%	−0.054
质量 / 摩擦 + 背景独立	−20.3%	−65.4%	+51.5%	−0.070
物理改变 + 视觉反转	−19.5%	−66.2%	+51.1%	−0.073

改变训练方案：效果精度与事实预测的取舍

方案	事实 RMSE / OOD	效果 RMSE / 物理偏移	事实误差各split ≤ +10%
从头 α = 1	+51.8%	−19.9%	0/3
从头 α = 0.25	+10.6%	−12.8%	1/3
从 Aug 微调 α = 1	−0.9%	−13.3%	3/3

从已收敛 Aug 模型继续训练 2,000 步，可保留事实精度并改善动作效果。

动作效果更准，也要保住规划所用的动力学

开发集 50 个回合：直接全量微调，效果误差 −29.1%，规划成功率 94% → 54%。

冻结基础预测器

$$F_{\text{base}}(z, a)$$

→

同权重适配器差分

$$\delta = g_\phi(h^a) - g_\phi(h^{a \leftarrow a_\varnothing})$$

→

$$F_{\text{adapt}} = F_{\text{base}} + \delta$$
$$a = a_\varnothing \Rightarrow \delta = 0$$

约束训练

秩 ≤16 的可训练修正
惩罚偏离基础模型的 5 步轨迹
仅选 rollout 误差 ≤ 基础 1.2× 的检查点
固定编码器与基础预测器权重
三项一同引入，未单独消融中心化。

独立规划检验：600 个配对回合

自然动作适配器 87.7% vs. 基础 87.8%
成功率差 −0.17 个百分点
90% CI [−2.20, +1.87]，落入 ±3 pp
TOST 等效检验；回合使用配对起点与目标。
结论是保留规划能力；没有显示规划提升。

中心化适配器 + 多步保持损失 + 漂移筛选，使规划成功率与原模型落在 ±3 个百分点内。

Do-JEPA 的贡献：让世界模型接受干预问题的检验

研究问题	最有力证据	适用条件 / 实际含义
动作进入哪里?	合成槽 Top-1 99.95–100%	对象对齐、单直接目标；首步先于传播
效果沿哪里传播?	3/3 种子恢复环图；AUROC 0.975	时间分辨率决定一跳边或区间可达性
像素中能否学会动作效果?	自然动作物理误差 −13.5%	同数据对照；训练干预分布影响迁移
怎样减少精度代价?	CausalWorld 微调：物理效果 −13.3%	物理偏移均值；事实 OOD 误差 −0.9%
能否用于控制?	600 回合规划等效于基础模型	需要保持多步动力学；效果增益未变成成功率提升

数据要求：完整状态可恢复，两个分支共享噪声；背景孪生只改观测。
真实世界的近似配对会混入状态与噪声差异，需另行建模。

把事实预测、动作效果、作用结构与规划分开评估，才能知道模型究竟学到了什么。

全球电力转型：2000—2025

清洁电力能否同时覆盖需求增长并压低化石发电？

2025 年估算 · 发电与需求增量

+886.9 TWh

清洁发电增量

+849.1 TWh

电力需求增量

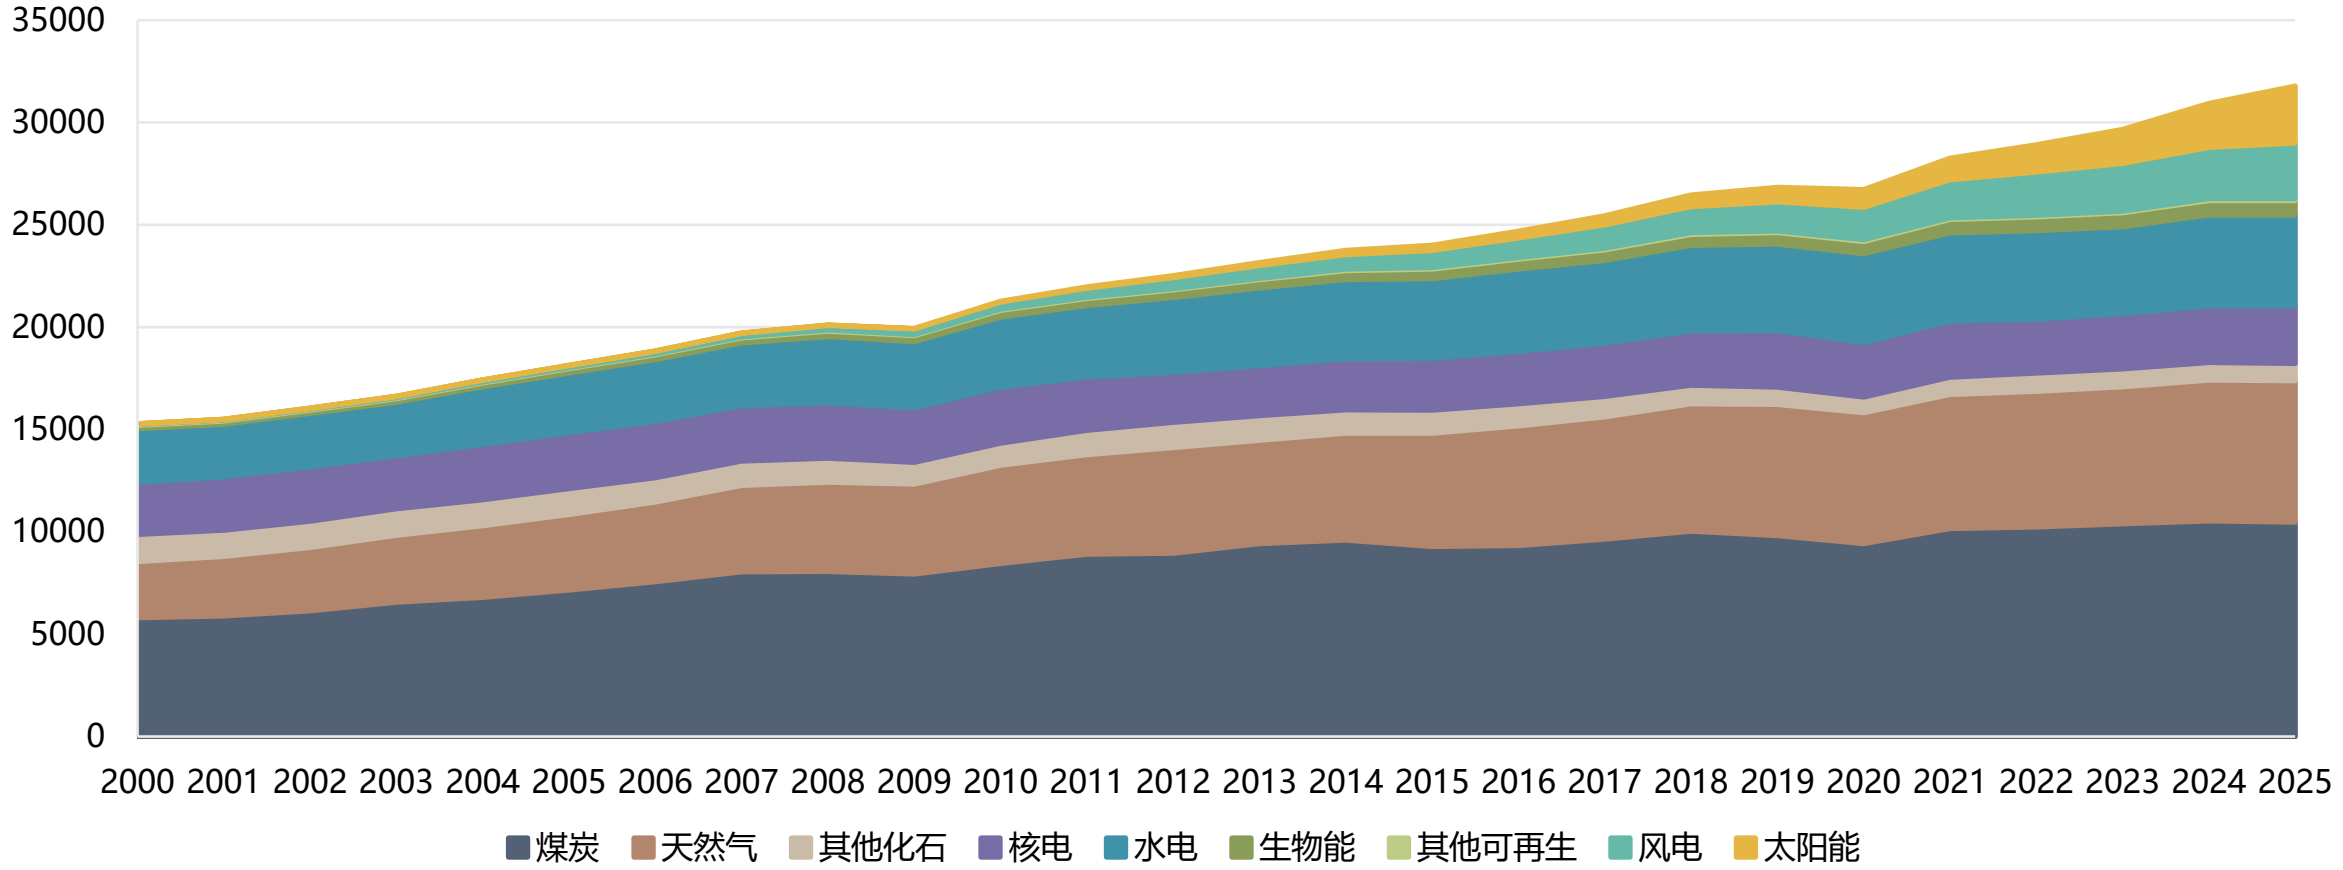
−37.8 TWh

化石发电增量

SKILL应用测试

清洁份额回升，化石发电量仍远高于 2000 年

全球发电结构 / TWh；2000—2024 年度数据，2025 年估算



清洁份额：35.3% → 42.6%；化石发电量同期增加 85%。

2025 年清洁增量超过需求增量 37.8 TWh

全球 2024→2025 发电增长贡献 / TWh；2025 年估算



净增量

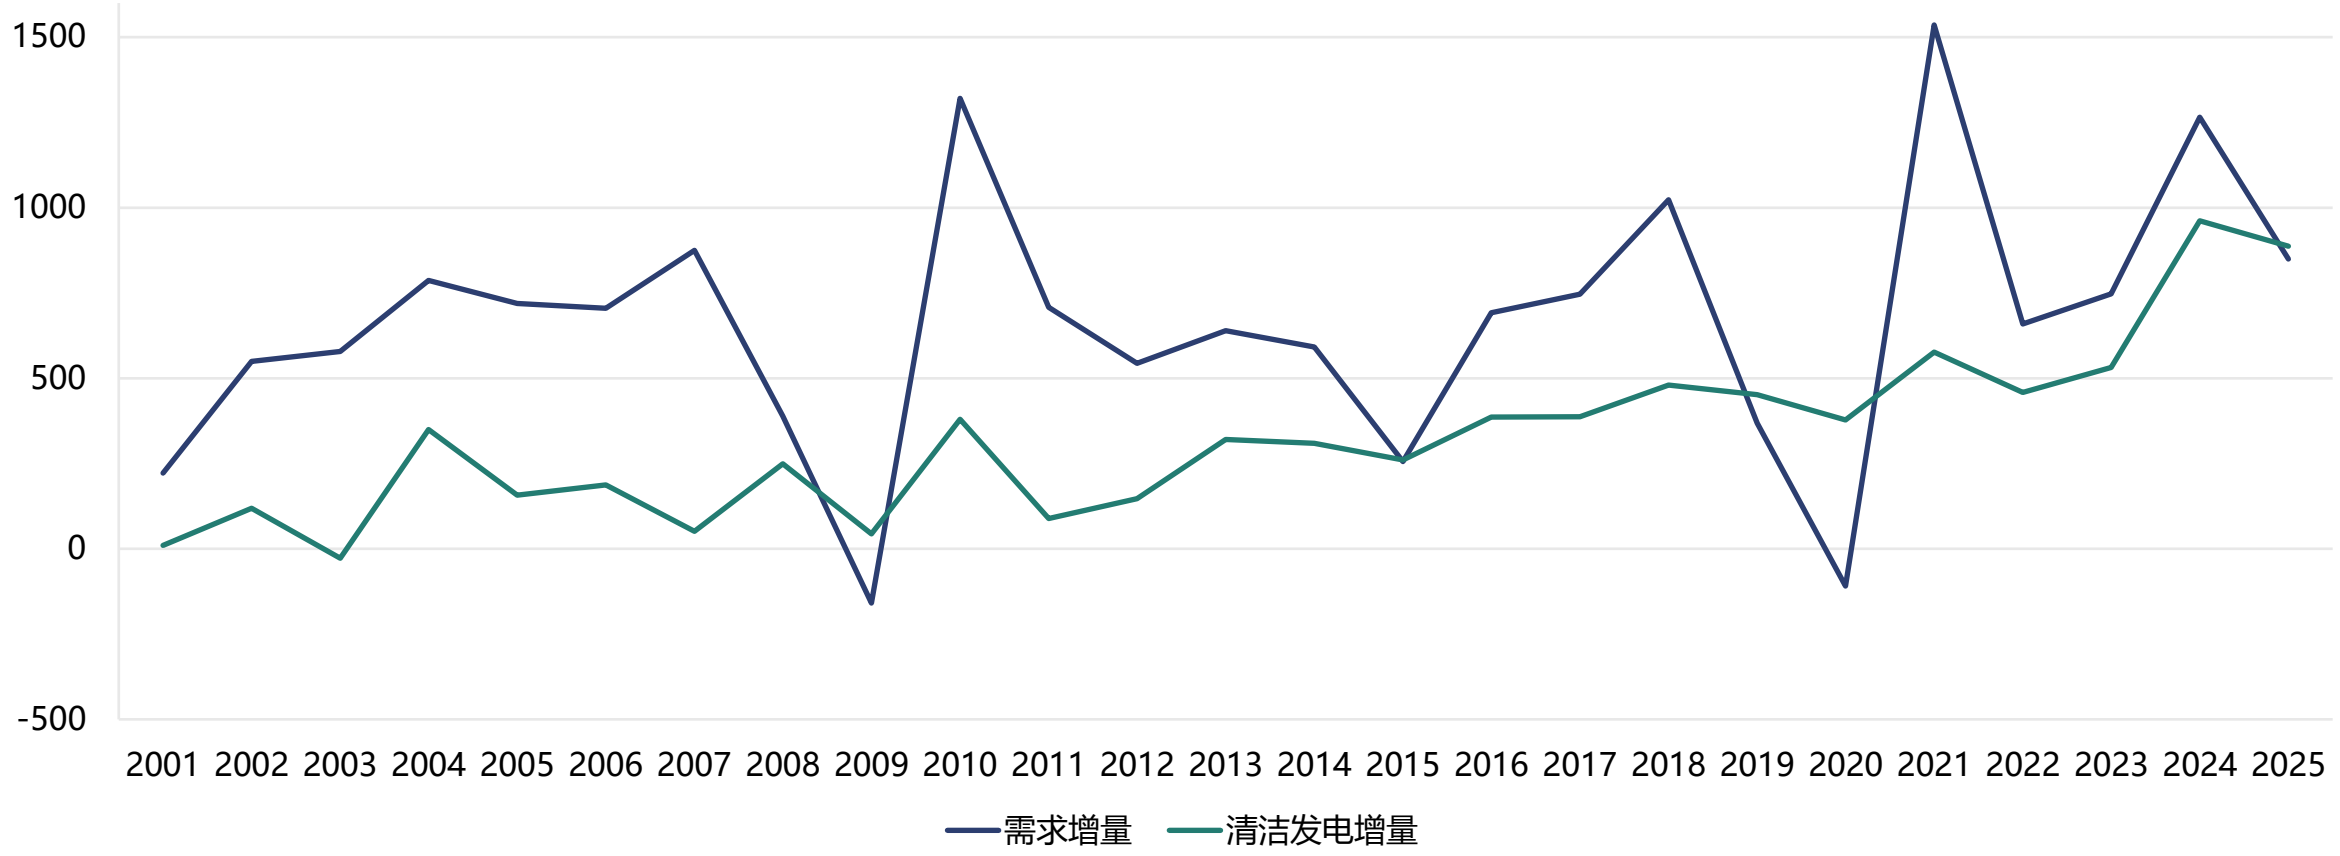
849.1

太阳能贡献总净增量的 74.8%

风光合计增加 840.5 TWh，煤电减少 62.5 TWh，天然气发电增加 36.3 TWh。

从补增量到挤出化石：两条增长曲线的交叉

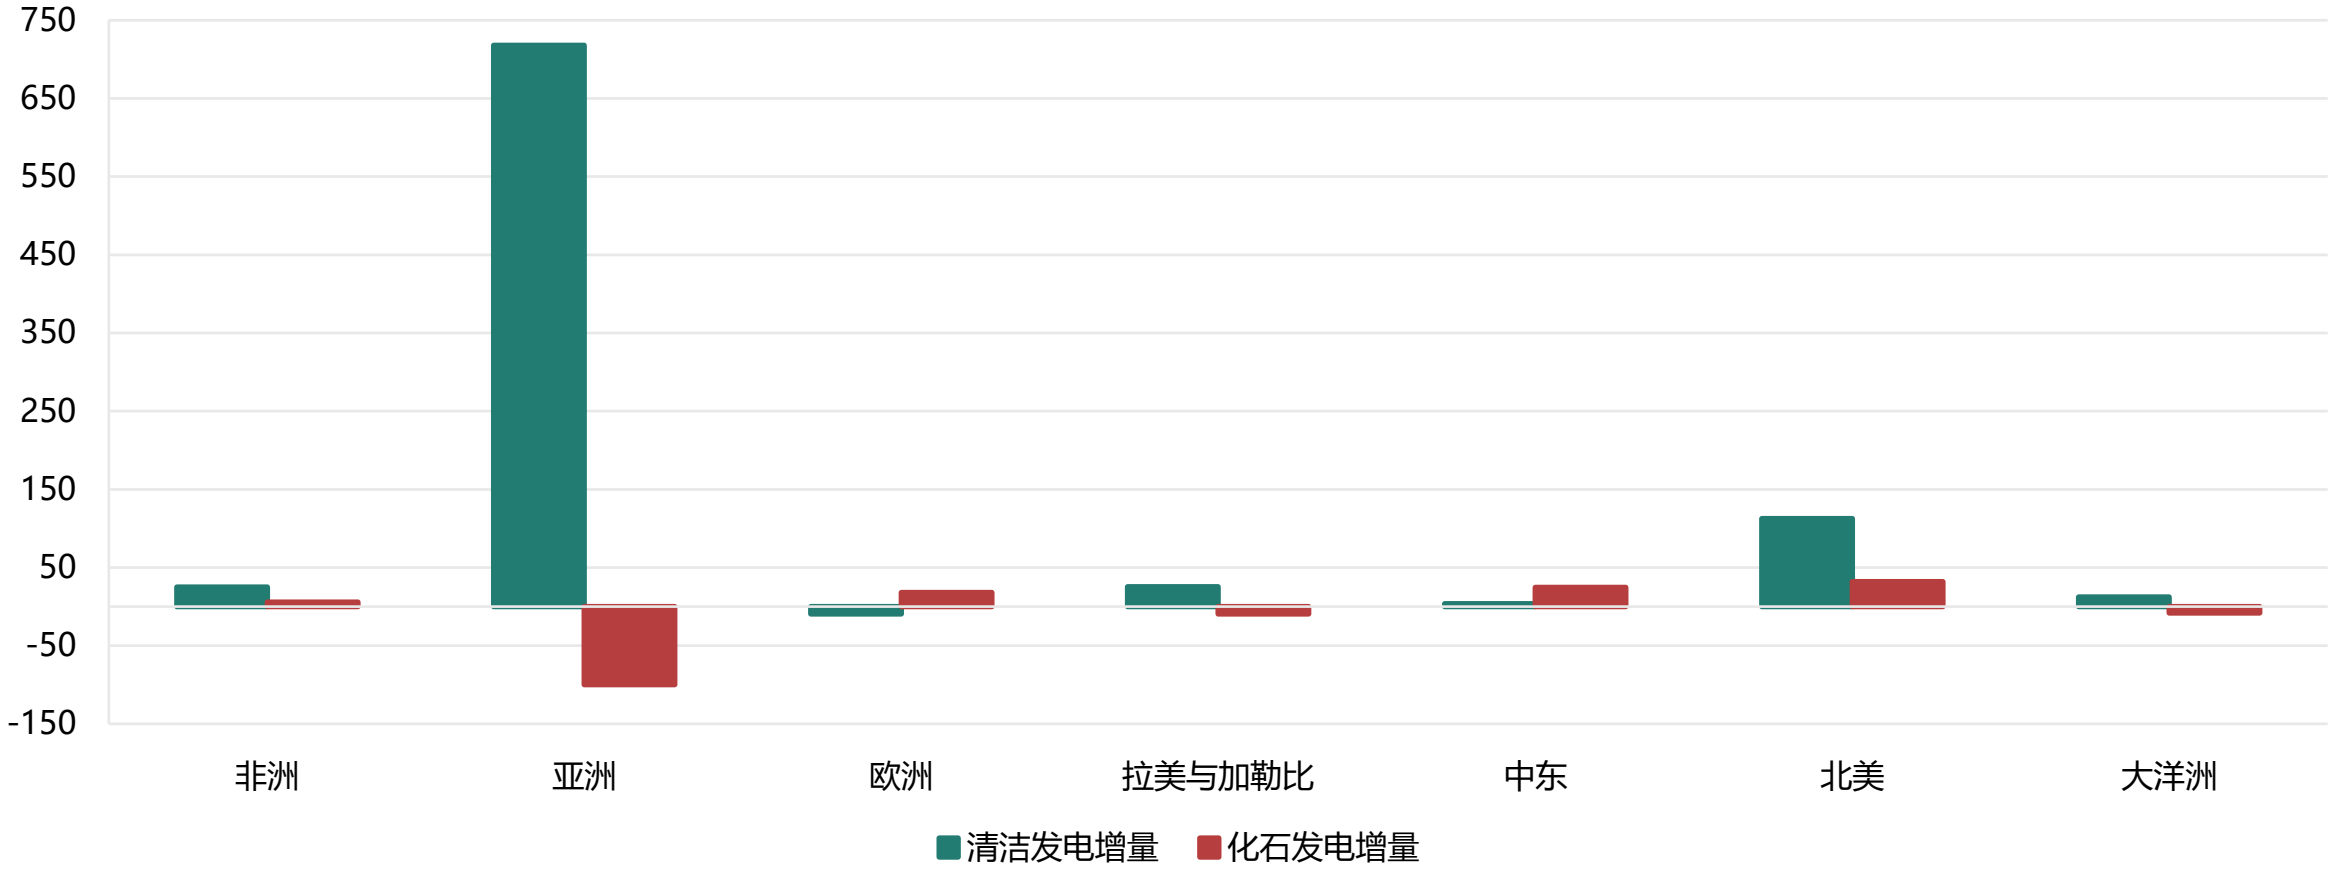
全球需求与清洁发电年度增量 / TWh；2001—2025，2025 年估算



清洁增量高于需求增量的年份，全球化石发电随之下降；2025 年差额为 37.8 TWh。

亚洲主导清洁增量，北美化石发电仍在增加

2024→2025 发电变化 / TWh；2025 年估算



亚洲清洁发电增加 717.8 TWh，占全球增量 80.9%。

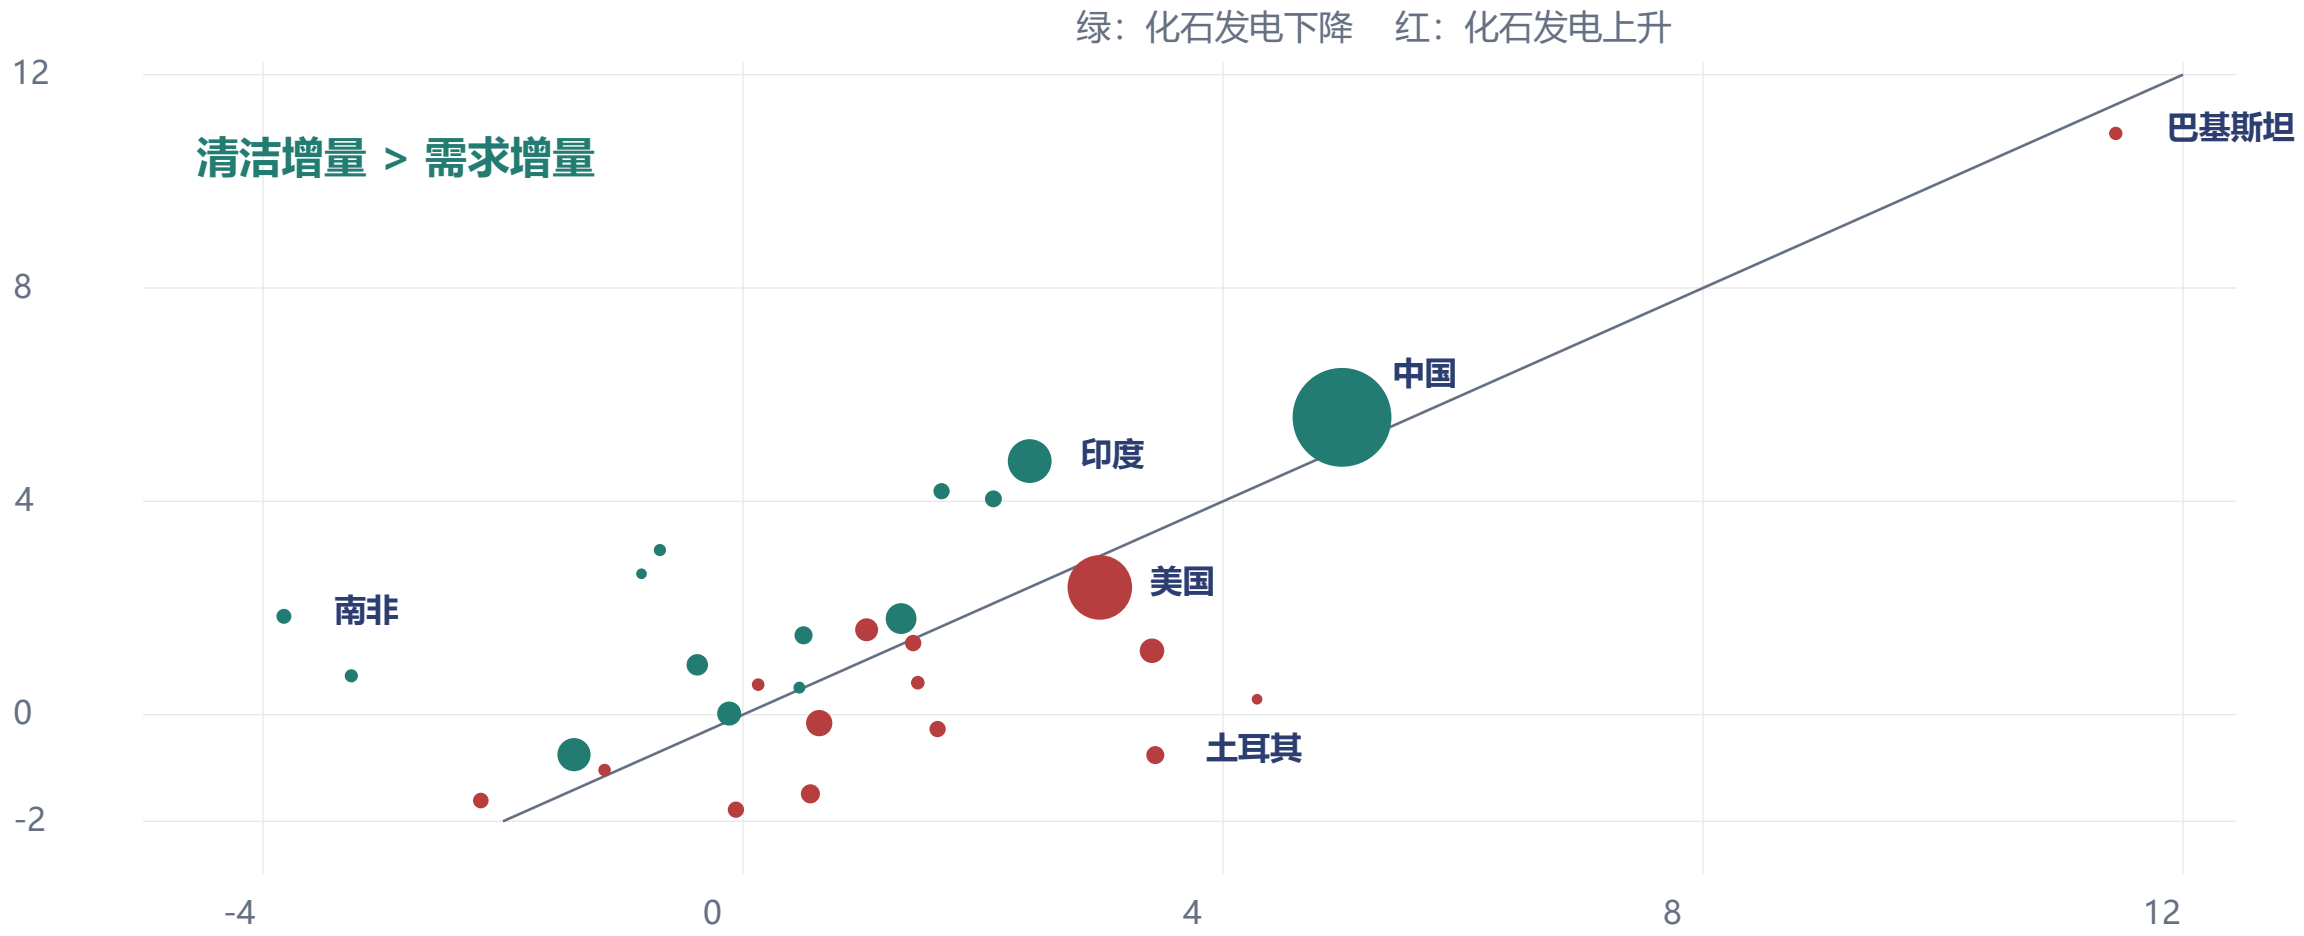
25 个主要用电国家，转型路径并不相同

2025 年发电份额 / %（估算）；浅→深：0% → 100%；—：缺值

	煤炭	天然气	其他化石	核电	水电	生物能	其他可再生	风电	太阳能
中国	54				13		—	11	11
美国	16	40		17				10	
印度	71						—		
俄罗斯	18	45		18	17		—		
日本	32	33					—		
巴西					52		—	16	12
加拿大		18		13	53		—		
韩国	31	28		30			—		
德国	21	17				10		27	18
法国				69	10				
伊朗		90					—		
墨西哥		62					—		
土耳其	34	22			16			11	11
英国		31		12		14	—	29	
越南	48				33		—		
意大利		47			16				17
中国台湾	36	49					—		
澳大利亚	43	16		—			—	14	20
西班牙		22		19	11			20	22
埃及		79		—			—		
南非	81						—		
泰国	18	65		—			—		
马来西亚	45	34		—	18		—		
巴基斯坦	15	21		12	20				19
波兰	50	14						14	11

需求增长与清洁增量决定化石发电方向

2025 年 30 国估算；横轴需求增幅 / %，纵轴清洁增量占上年需求 / %；气泡面积代表总发电

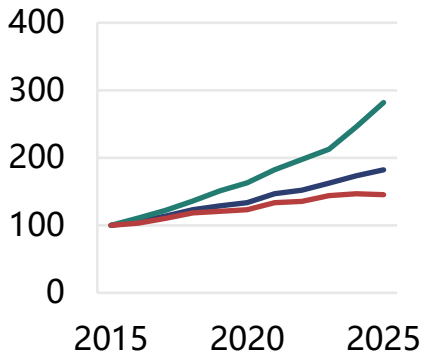


中国、印度的清洁增量超过新增需求；美国清洁增量落后于需求增量。

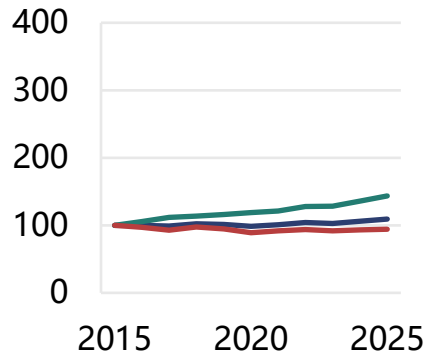
十国十年：清洁增长速度与化石轨迹分化

2015=100；蓝：需求，绿：清洁发电，红：化石发电；2025 年估算

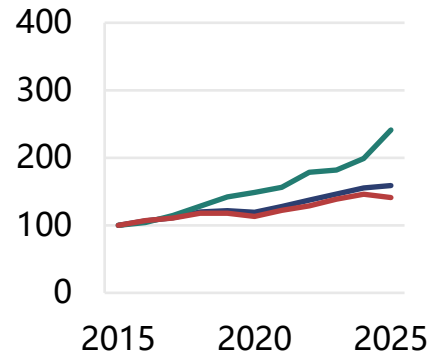
中国



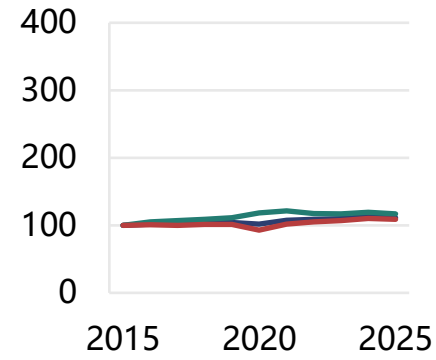
美国



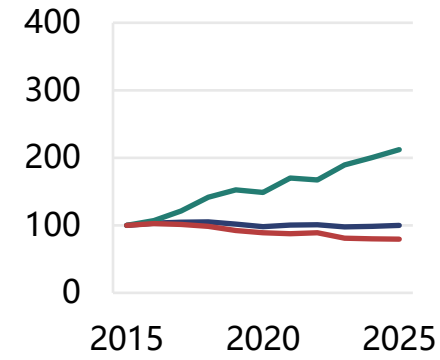
印度



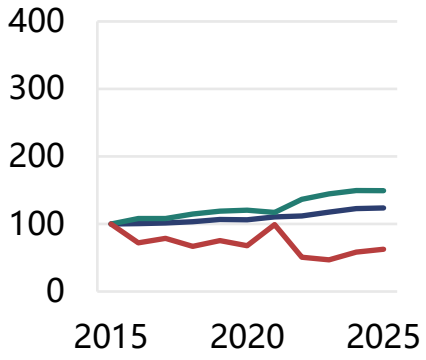
俄罗斯



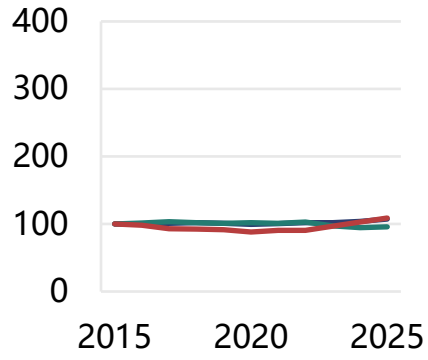
日本



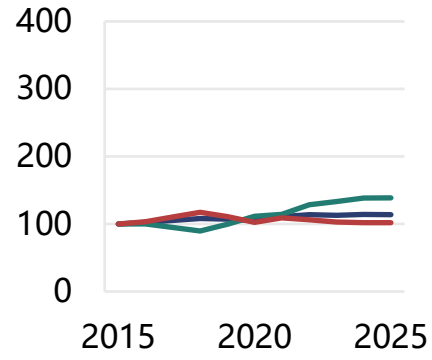
巴西



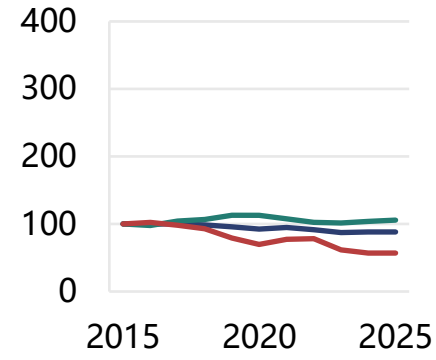
加拿大



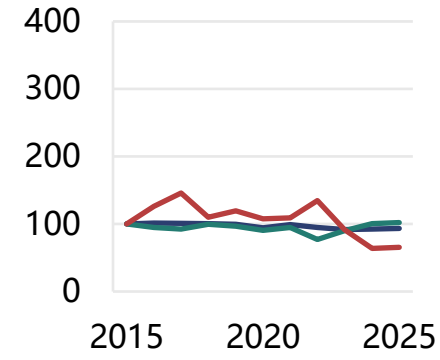
韩国



德国

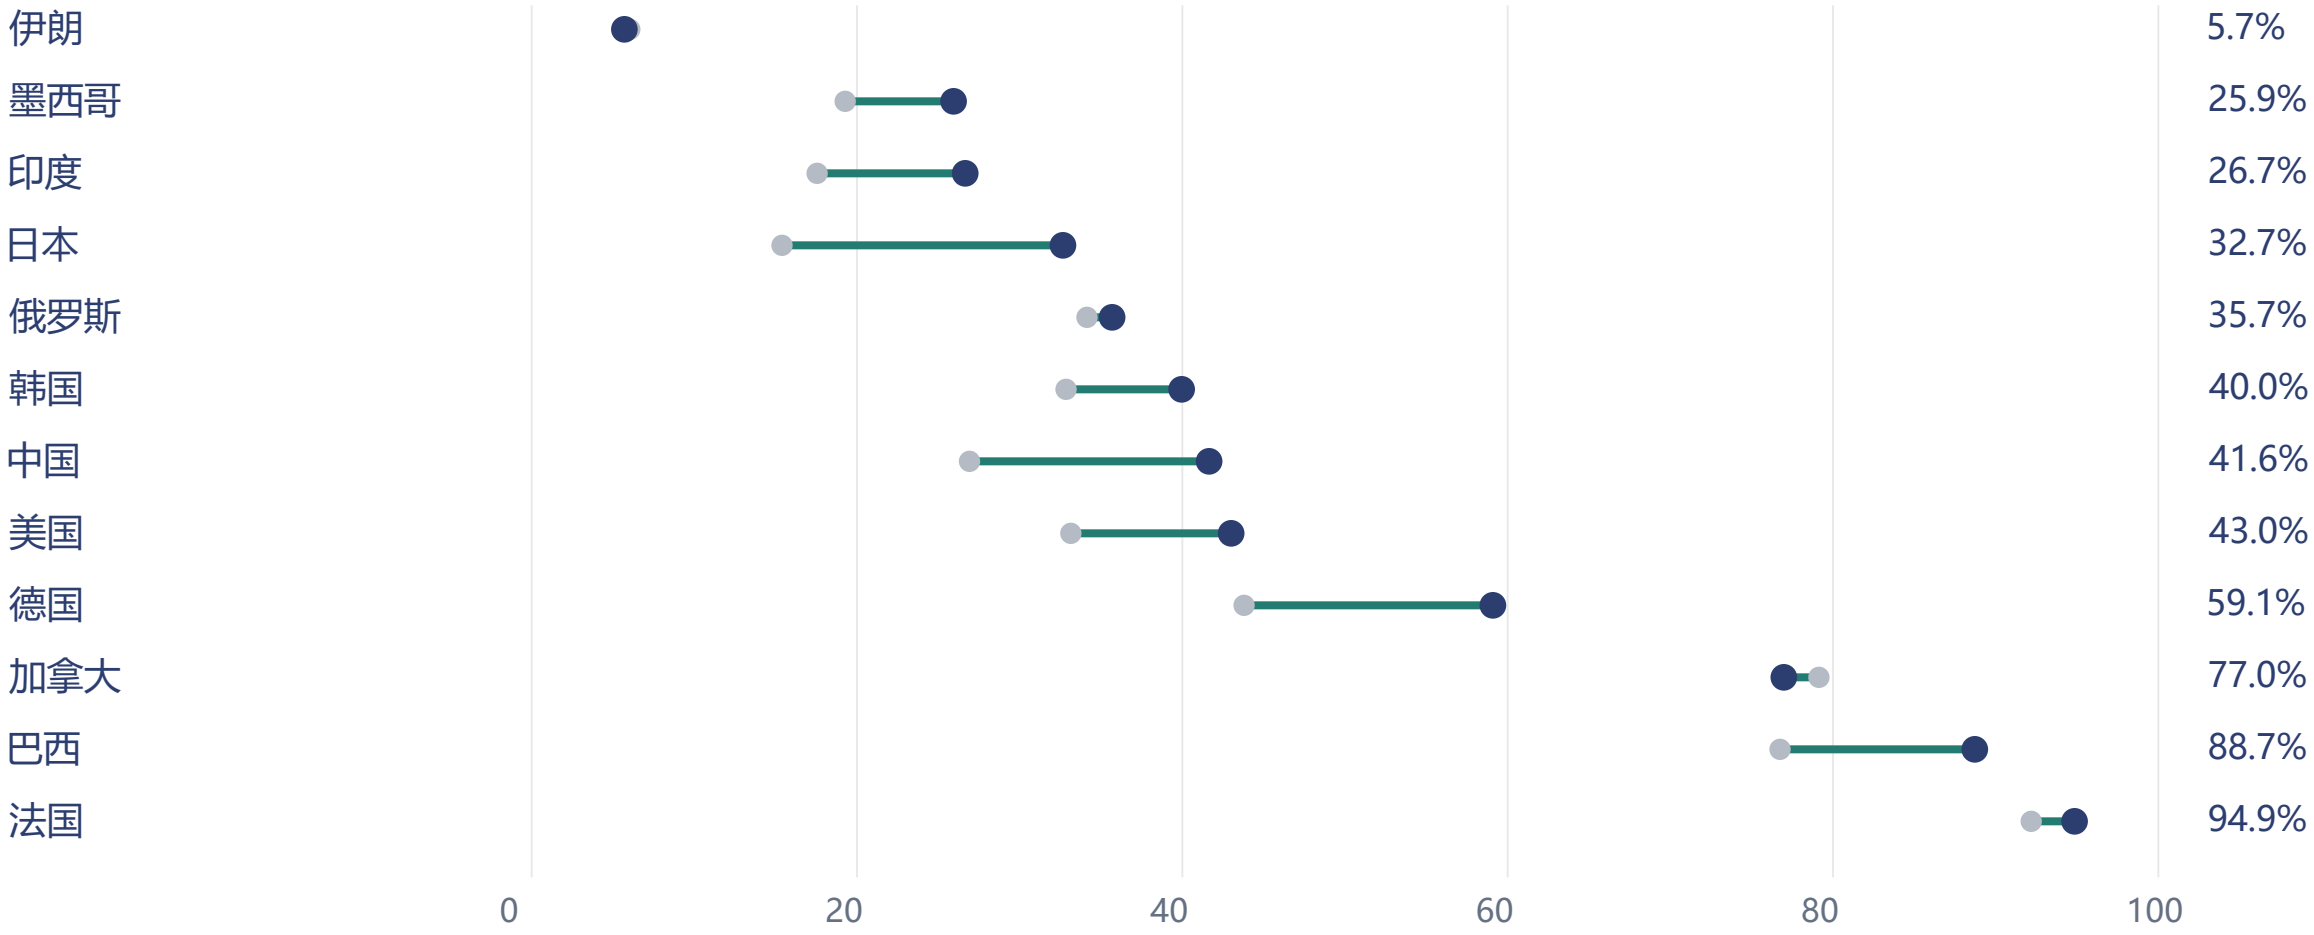


法国



清洁份额的十年变化：同一终点，路径不同

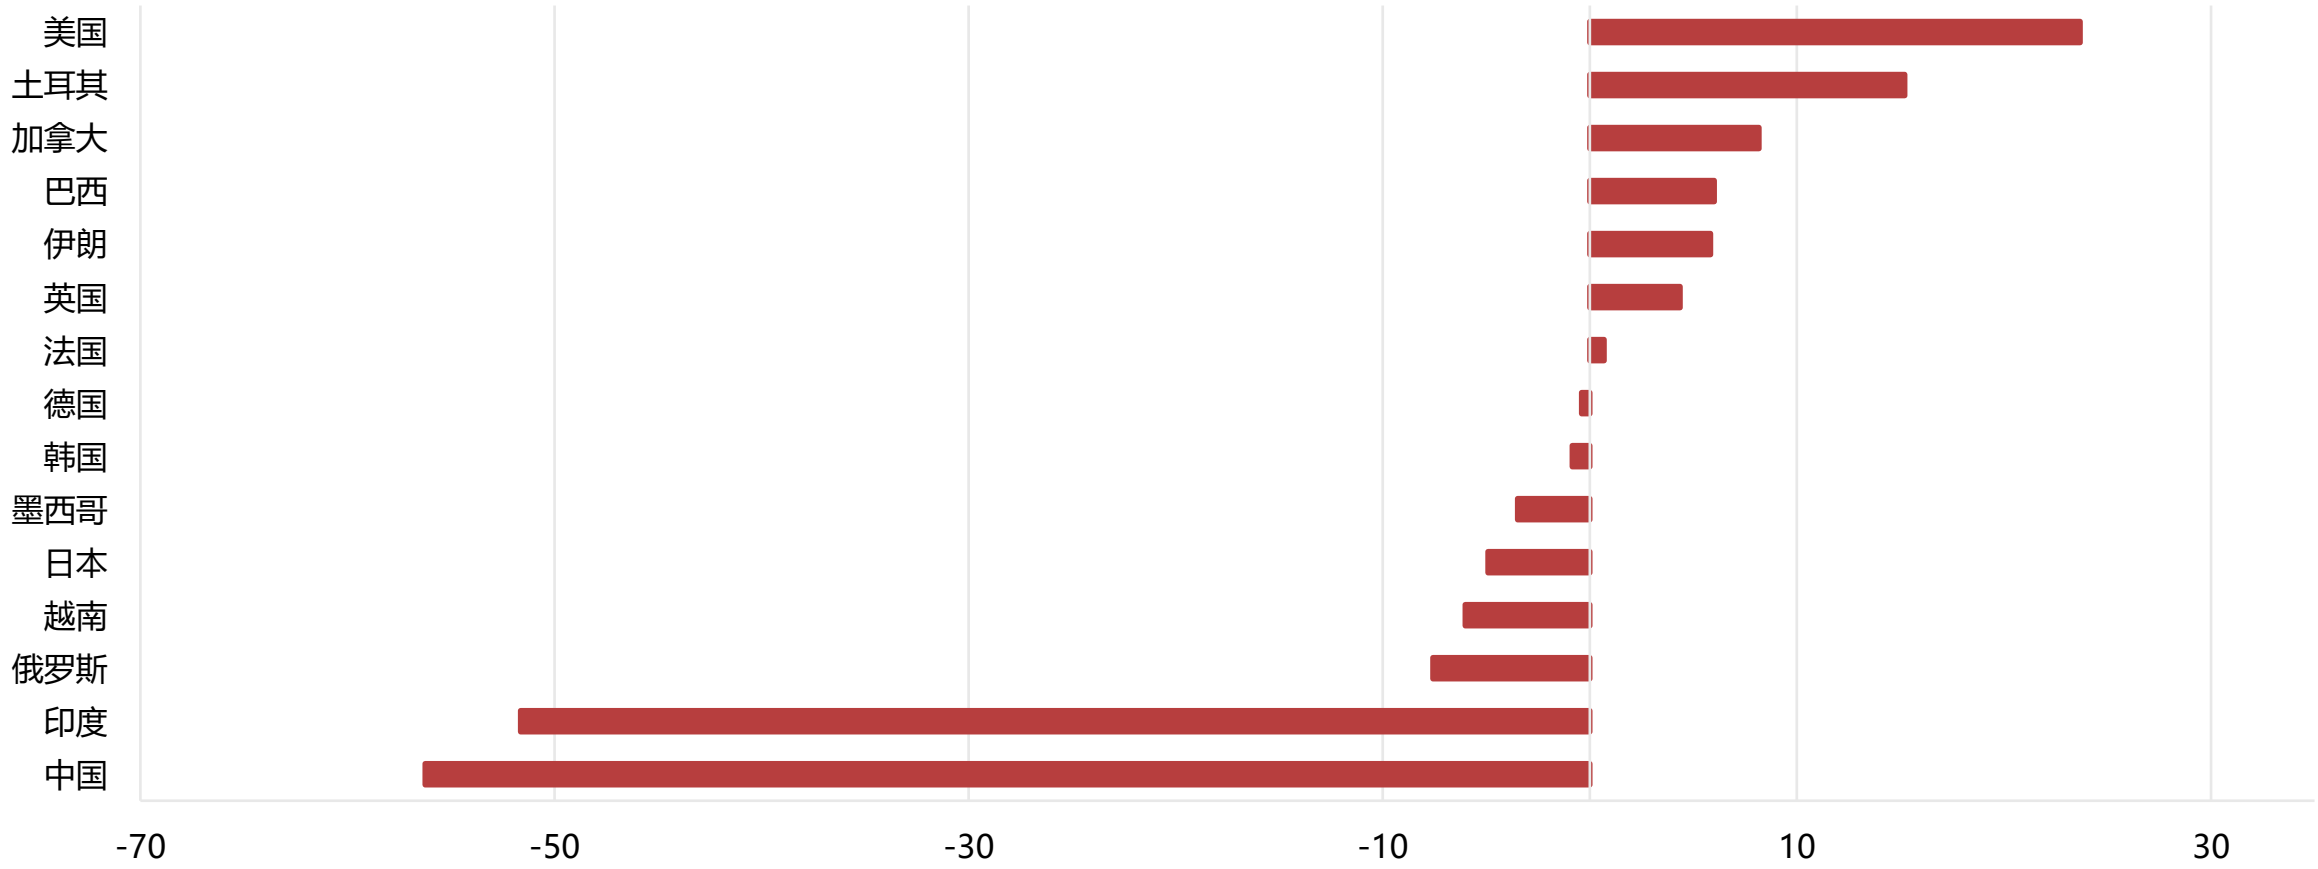
2015 → 2025 清洁发电份额 / %；灰点2015，蓝点2025；2025 年估算



风光扩张推动多数主要用电国家提升清洁份额；核电与水电决定各国起点。

中国与印度合计压低化石发电 107.9 TWh

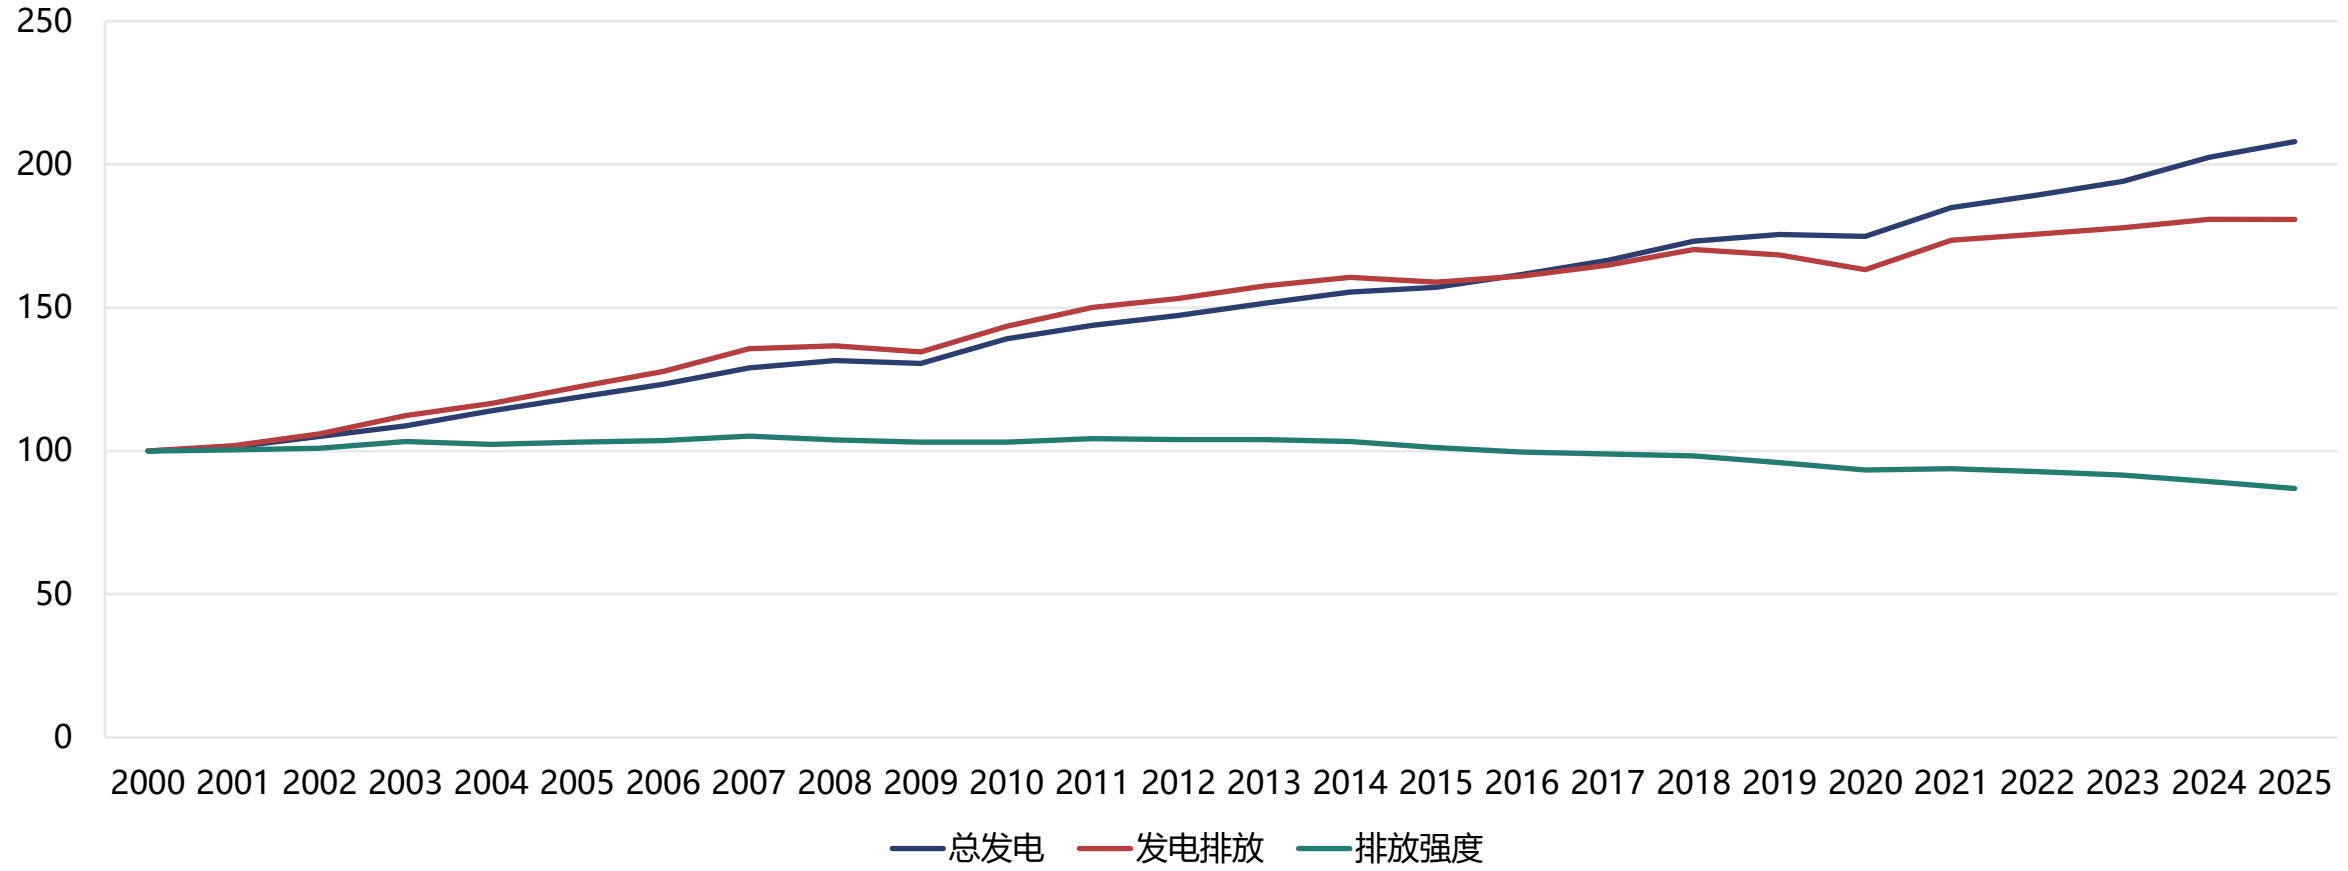
2024→2025 化石发电变化 / TWh；主要用电国家，2025 年估算



中国 −56.3、印度 −51.6 TWh 的降幅，被美国 +23.7 TWh 等增长部分抵消。

排放强度下降，发电扩张抵消了大部分收益

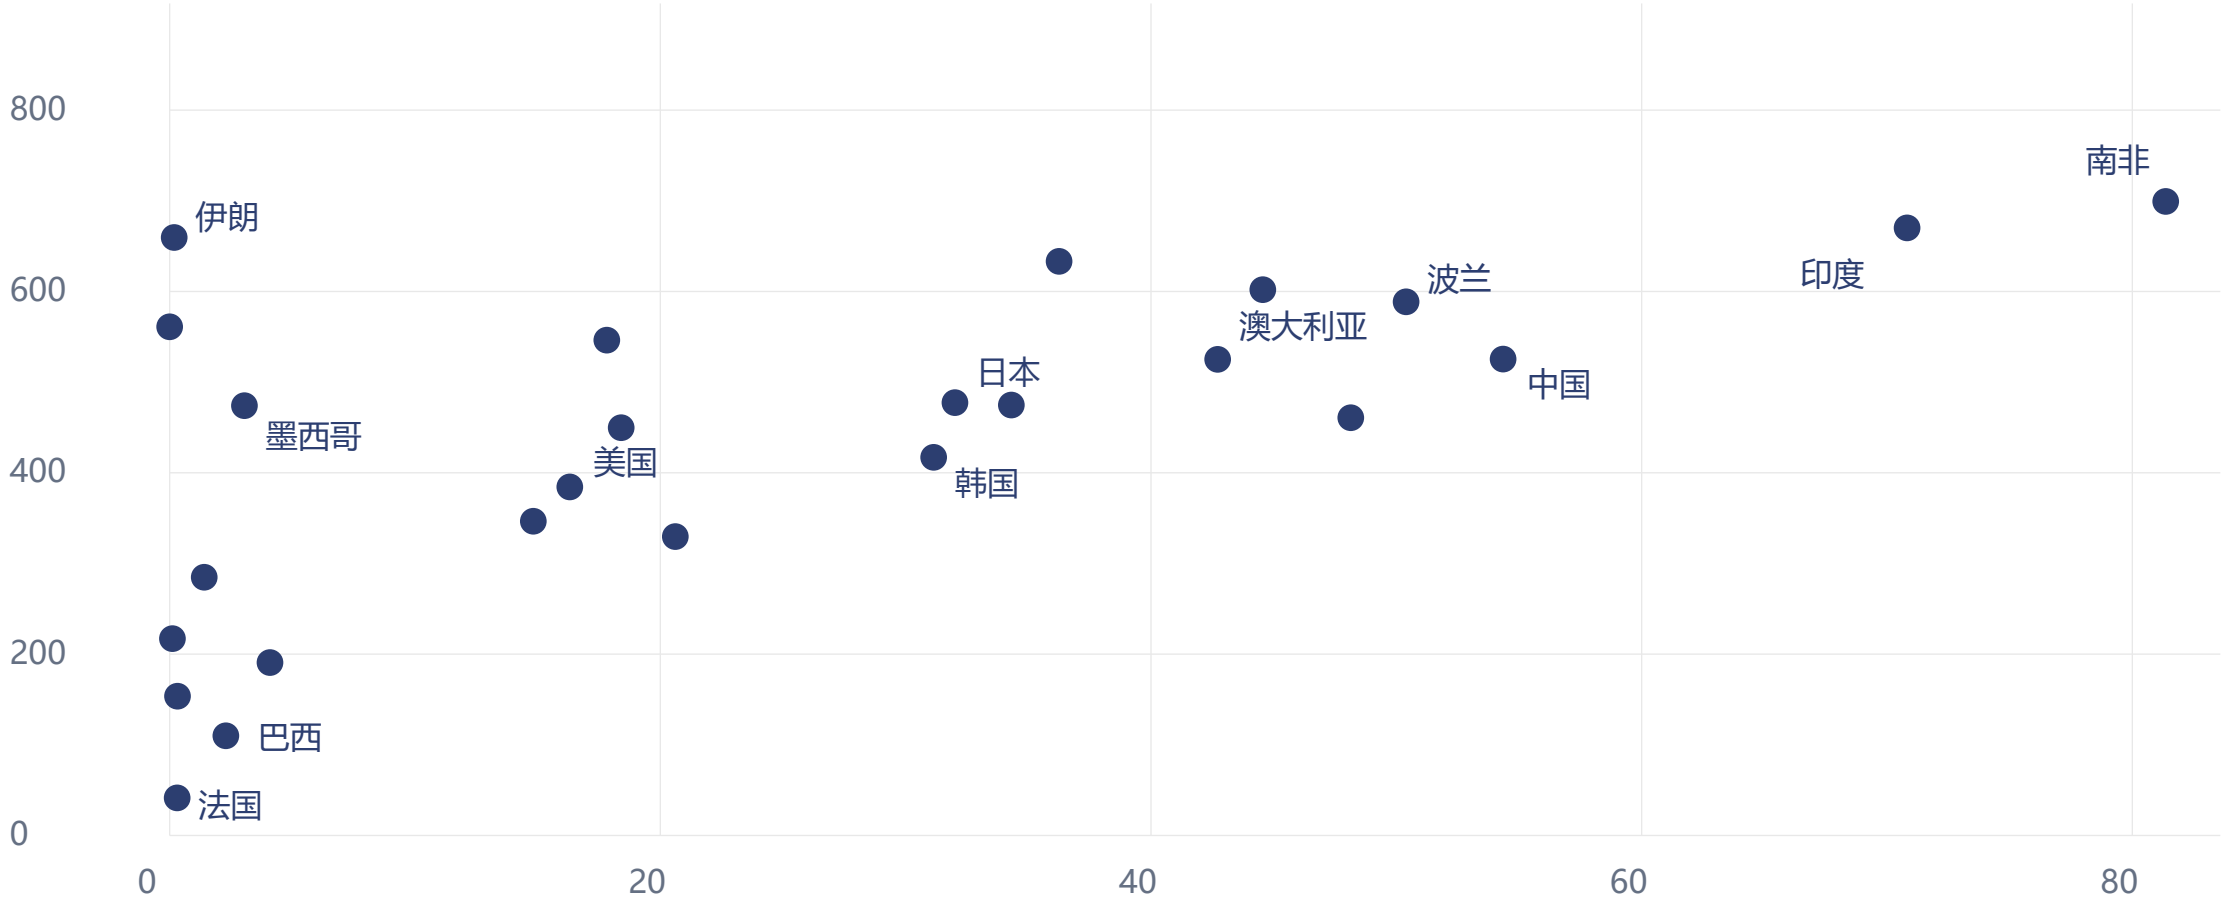
全球发电、排放与排放强度；2000=100，2025 年估算



2025 年排放强度 458.3 gCO_2e/kWh，电力排放 14.56 $GtCO_2e$。

煤电份额解释了主要国家排放强度的差异

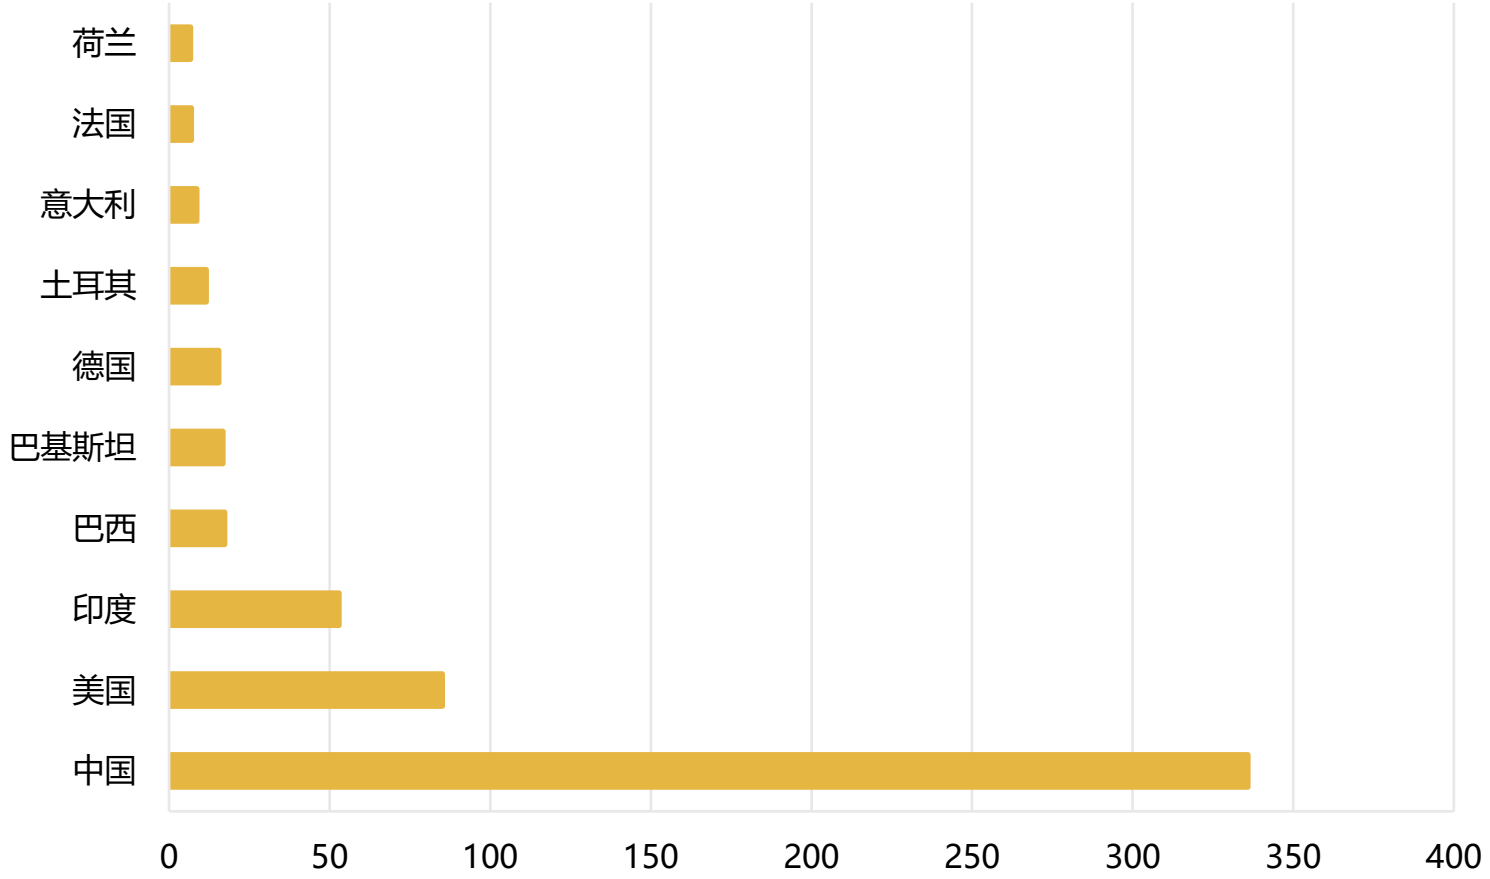
2025 年 25 国估算；横轴煤电份额 / %，纵轴排放强度 / gCO_2e/kWh



煤电占比高的国家集中在高排放强度区；水电、核电占比高的法国和巴西位于低位。

太阳能贡献全球新增发电的四分之三

2024→2025 太阳能发电增量 / TWh；2025 年估算



635.5 TWh

全球太阳能发电增量

74.8%

相当于全球新增需求的比例

29.7%

太阳能发电同比增速

清洁电力已覆盖新增需求，深度减排需要更大净增量

2025 年全球清洁增量 / 需求增量 = 104.5%；2025 年估算

01 维持增长领先

清洁发电增加 886.9 TWh，超过需求增量 37.8 TWh。

化石发电因此下降 0.21%；扩大两者差额才能加快下降。

02 抓住大国分化

中国与印度合计减少化石发电 107.9 TWh。

美国需求增加 131.0 TWh，清洁增量 105.1 TWh，化石发电回升。

03 把低碳供给转成替代量

全球风光增加 840.5 TWh，水电仅增加 2.9 TWh。

持续扩张风光、核电与其他清洁供给，才能共同覆盖新增负荷。

长上下文
企业知识助手如何扩容

从单机瓶颈到 Prefill / Decode 解耦集群

性能边界 · KV 内存 · 调度策略 · 集群运行

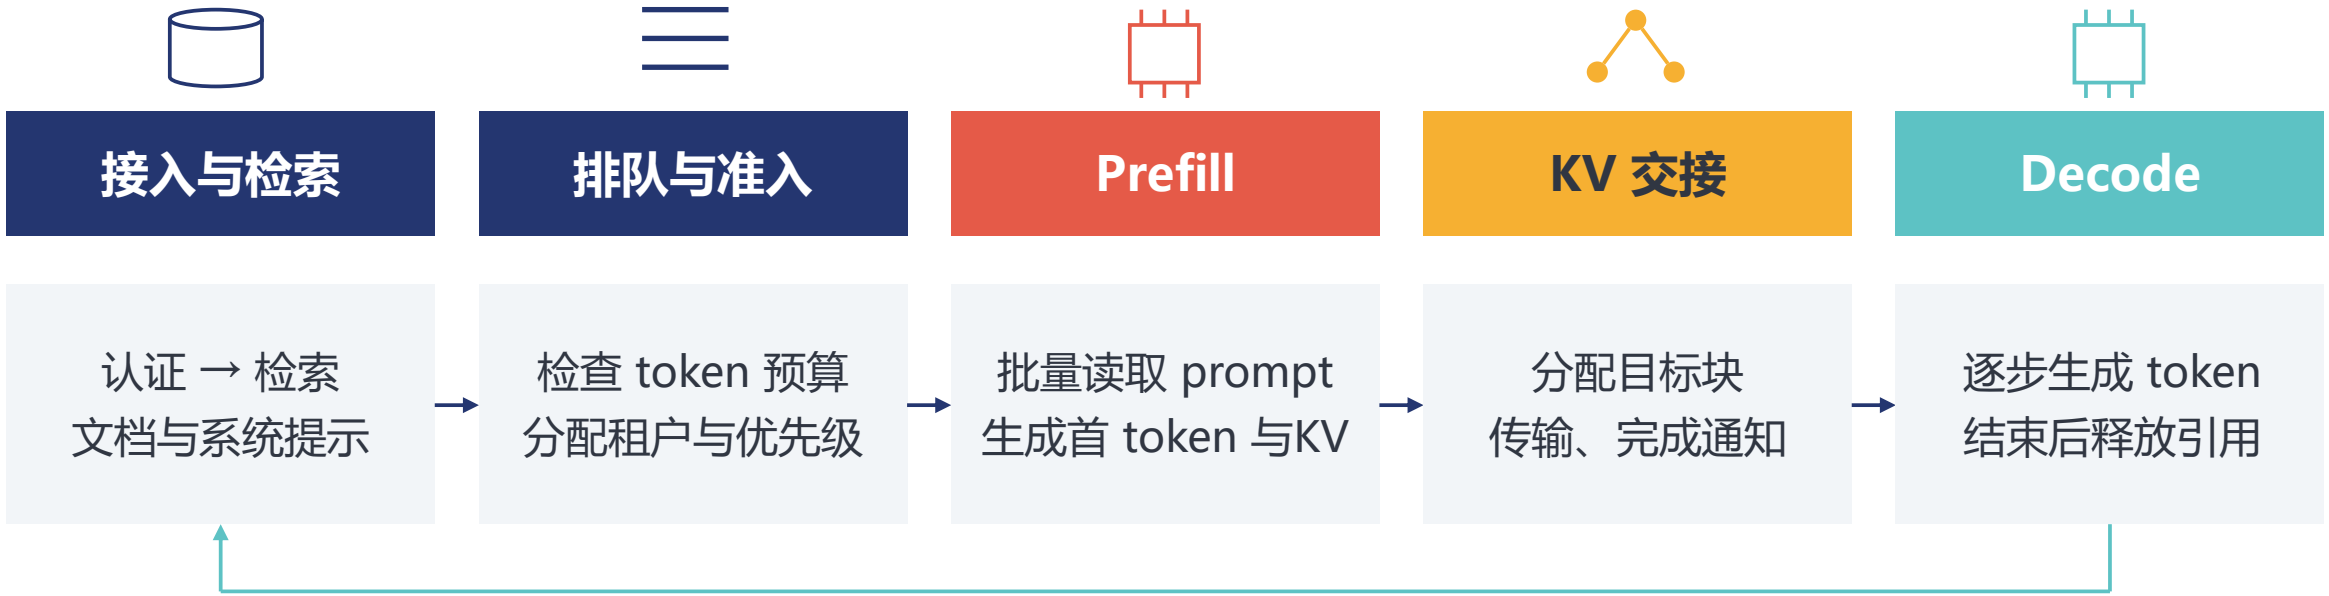
2026 年 10 月 18 日

先固定一个可验收的知识问答场景

维度	设计示例：企业知识助手	扩容时要保住什么
模型与精度	Qwen2.5-7B-Instruct；BF16 权重 / KV	答案质量、引用正确性与权限边界
请求长度	基线 8,192 输入 + 256 输出 token	压力组：输入升至 32,000 token
复用与租户	16 个活跃会话；同租户 6,144 token 前缀	跨租户缓存隔离；热 / 冷请求分别统计
延迟目标	p95 TTFT ≤ 2 s；p95 请求 TPOT ≤ 40 ms	同时满足两项的请求比例 ≥ 95%
到达过程	基线 Poisson；另加阶跃与突发回放	从 0.2 req/s 扫到失稳，再退回容量边界

容量的分母是满足质量与延迟目标的请求；后续内存、网络和成本都沿用这组参数。

请求走完五段链路，首 token 才能到达用户



流式返回：逐 token → detokenize → SSE → 浏览器

同机服务省掉跨设备 KV 交接；解耦把它加入 TTFT 关键路径，并增加一处故障边界。

TTFT、TPOT 与 ITL 描述不同的等待



$$TTFT = t_1 - t_0$$

$$TPOT = (t_n - t_1) / (n - 1)$$

指标	观测单位	容量判定中的作用
ITL	相邻 token 到达间隔	发现输出卡顿；需定义 token 加权或请求加权
p95	请求指标的95分位	联合达标率需逐请求同时核对TTFT与TPOT
有效吞吐	req/s 或 token/s；goodput 为达标 req/s	goodput = 完成请求速率 × 联合 SLO 达标比例

256 个输出 token、TTFT 2 s、TPOT 40 ms，对应单请求端到端延迟约 12.2 s。

Prefill 吃计算，Decode 反复读取权重与历史 KV

Prefill · 一次处理多个 token

输入矩阵较大，权重读入被多个 token 摊薄。

长序列注意力工作随上下文增加；一次长 prefill 会延长共批 decode 的等待。

目标：压低首 token 执行时间与排队时间。

Decode · 每轮推进一个 token

每个活跃序列每轮生成一个 token。

小批次常受内存带宽约束；并发上升后 KV 读取、计算与通信都可能成为瓶颈。

目标：保持步间节奏，并利用批次摊薄权重读取。

调度器同时面对“长任务快速启动”和“短步持续推进”；拆池的收益来自解除这两类资源竞争。

KV 容量按 token 累积，不能只看模型参数量

$$M_KV = 2 \times L \times H_KV \times d_head \times b \times T$$

Qwen2.5-7B 配置	取值	BF16 KV 推导
层数 L / KV头数 H_KV	28 / 4	2 × 28 × 4 × 128 × 2 B
头维度 / 每元素字节	3,584 ÷ 28 = 128 / 2 B	57,344 B = 56 KiB / token
8,192 输入 / 256 输出	448 MiB / 最多14 MiB	每会话上界 462 MiB
16 会话 / 无共享	16 × 462 MiB	7.219 GiB KV；另计权重与运行时

GPU 内存预算

权重常驻
+ 活跃 KV
+ 激活 / 工作区
+ CUDA Graph
+ 分配与安全余量

示例可用 KV 池为24 GiB时：8,192+256最多容纳53会话；32,000+256最多13会话。

共享前缀把重复计算与重复 KV 变成一份

16个会话 · 每个8,192输入 + 256输出 · 同租户完整前缀6,144 token



共享 336 MiB + 16 × 私有126 MiB = 2.297 GiB

token 顺序、模型版本、LoRA 与盐一致

完整块复用；引用计数归零才可回收

知识片段放在稳定前缀中才产生复用；把每次变化的检索结果插到前部，会使后续缓存键一起变化。

PagedAttention 用块表连接逻辑序列和物理 KV

逻辑视图：示意块大小4 token

请求 A	2	7	4
请求 B	2	7	9

物理块池：地址可以不连续

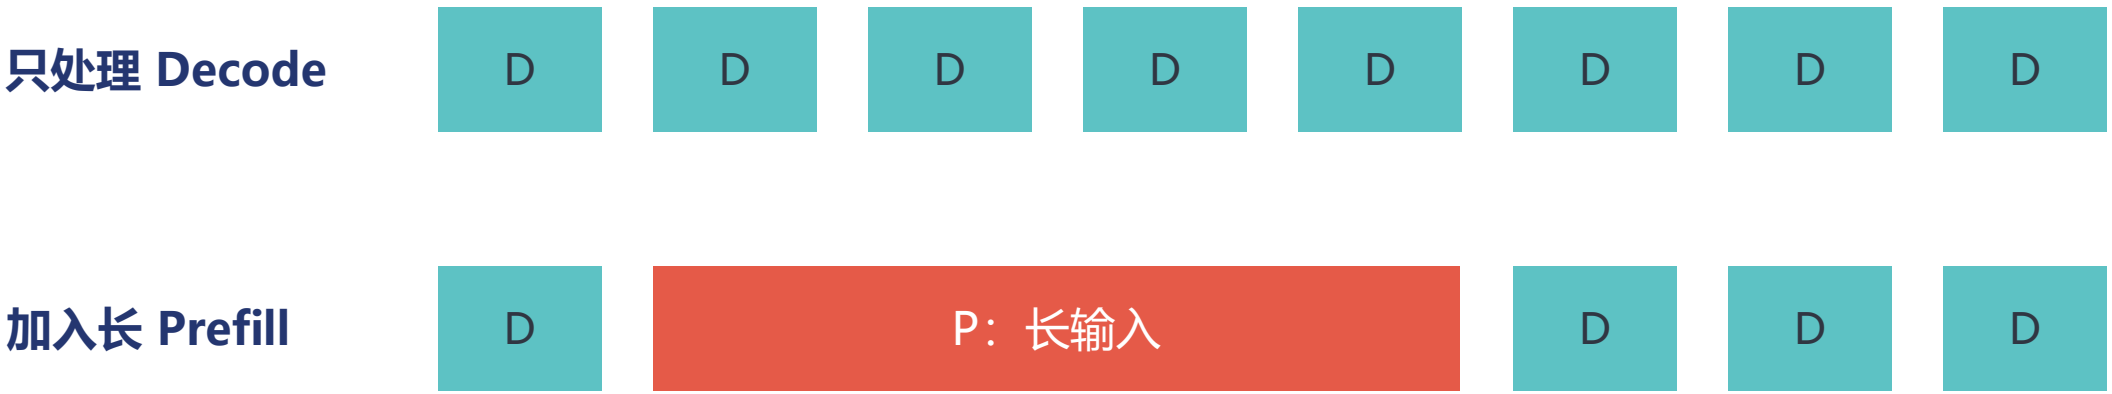
0	1	2	3	4
5	6	7	8	9

块2和块7由A/B共享；各自追加到块4与块9。
引用计数管理共享块；写入已共享的尾块时复制。

分页减少连续预留与外部碎片；最后一个块仍可能有内部碎片，容量模型必须计入尾块。

连续批处理提高利用率，长 prefill 仍会阻塞短步

同一GPU上的迭代示意（宽度表示相对执行时长）



新请求不必等整批结束；完成的序列退出，等待序列进入。
当长 prefill 占据一次迭代，其间已有输出流暂停，ITL尾部拉长。

将活跃序列数、每轮 token 预算和输入长度一起观察，才能区分计算饱和、队列积压与 KV 不足。

Chunked Prefill 把长输入拆进 Decode 的剩余预算

设计示例：每轮token预算 B=2,048；32个Decode序列先占32

先排 Decode
32 token

→

计算余量
2,048 − 32

→

放入 Prefill
最多2,016 token

→

下一轮继续
8,192输入约5轮

预算较小

单轮 prefill 较短，输出卡顿减轻；输入分更多轮完成。

预算较大

首 token 可更快完成；共批 decode 的迭代时长上升。

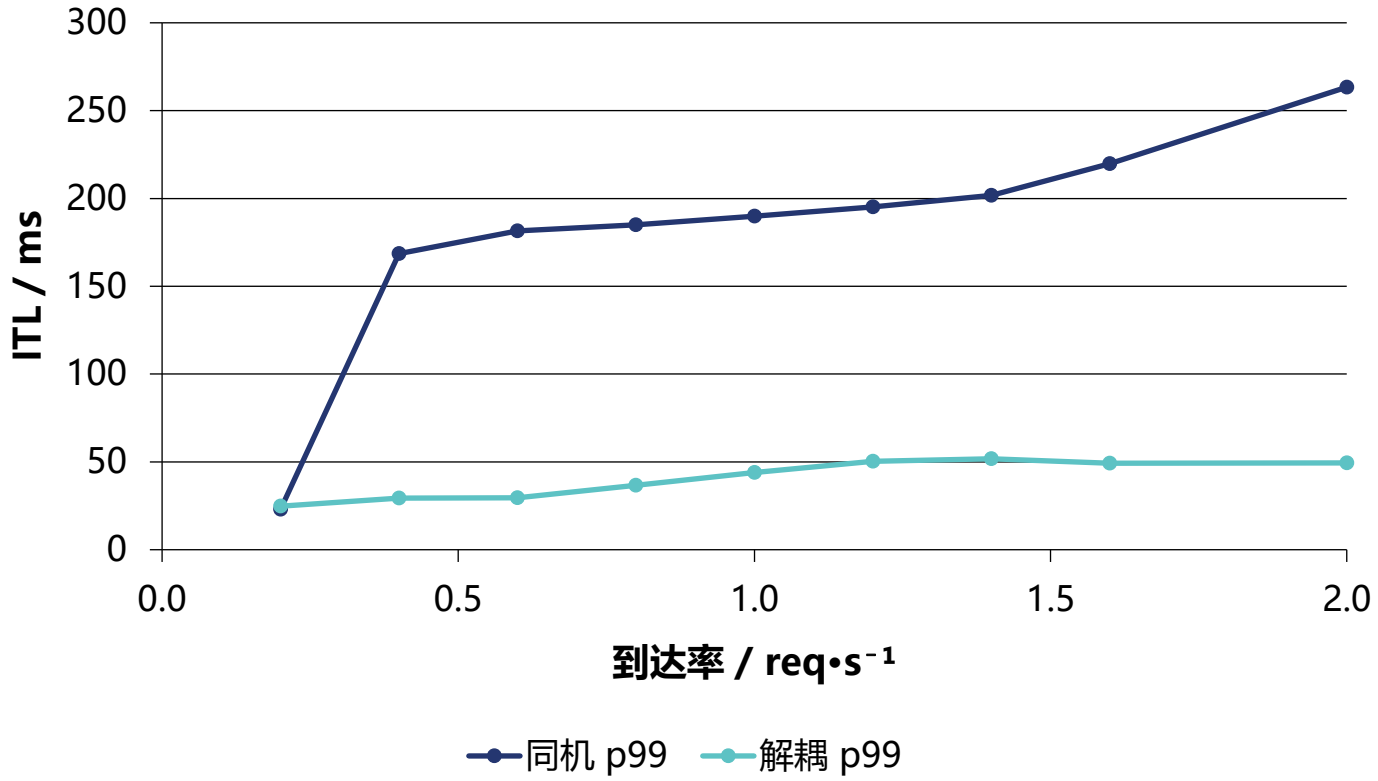
从冷缓存、长输入和突发流量回放中选择预算；以联合 SLO 达标率检验，避免只优化平均 token/s。

准入控制提前约束未来 KV，而非等到 OOM

入口门槛	预算 / 状态	动作与隔离边界
请求级	输入token + max_output ≤ 上限	超长请求转异步摘要或拒绝；显式返回原因
租户级	并发、排队token、缓存盐	交互请求与离线任务分队列；防止共享缓存跨权域
实例级	空闲KV块 − 已预留增长空间	先预留增长额度；内存不足时停止接入新会话
队列级	等待时间 + 预计执行 > deadline	及时拒绝或降级；取消后释放块与租约
调度级	优先级 + aging + 每租户权重	保障交互响应，同时给长期等待任务推进机会

内存抢占触发重算会同时放大计算与延迟压力；准入预算应覆盖输入、输出增长及传输驻留。

公开实验：ITL 尾部变平，TTFT 却超过目标



Qwen2.5-7B-Instruct
2×L40S 48 GB；无NVLink
约8K输入 / 256输出
每档100次Poisson到达
前缀缓存关闭
同机：单进程DP=2
解耦：1P+1D，NIXL

0.2 req/s 的中位TTFT
同机0.7 s → 解耦2.2 s
约470 MB KV传输耗时1.3 s

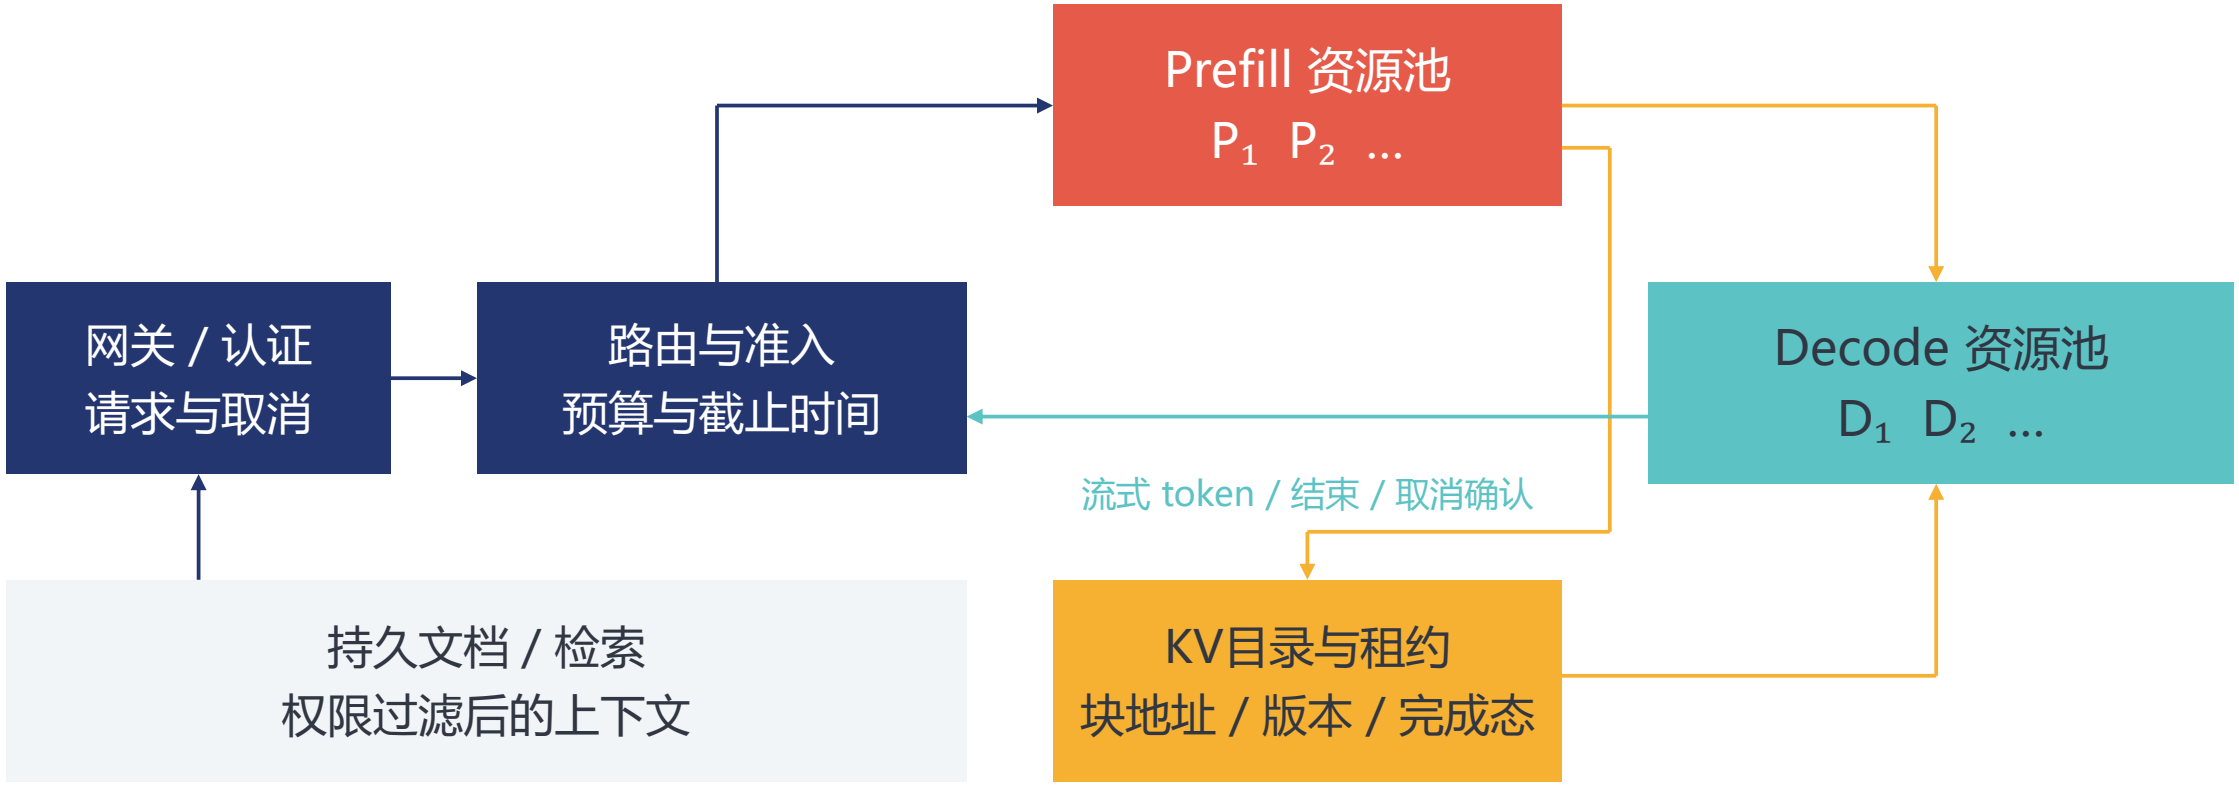
双 L40S 未支持 GPU P2P；解耦先解决了输出卡顿，传输完成检测与拷贝路径仍支配首 token。

TP / PP / DP / EP 解决不同的扩容约束

方式	拆分对象	主要收益	主要代价	本场景起点
TP	单层张量 / 算子	分摊权重与计算	每层集合通信；要求高带宽	模型能单卡时先测TP=1
PP	模型层 / 流水阶段	跨卡容纳大模型	流水气泡；阶段间等待	模型跨节点时考虑
DP	完整模型副本	请求水平扩容	重复权重；缓存分散	单卡可装下时增副本
EP	MoE专家	专家权重分布	token All-to-All；负载不均	Qwen2.5-7B为稠密模型
组合	TP×PP后再复制	适配容量与服务流量	运维和路由状态增多	P池与D池分别寻找配置

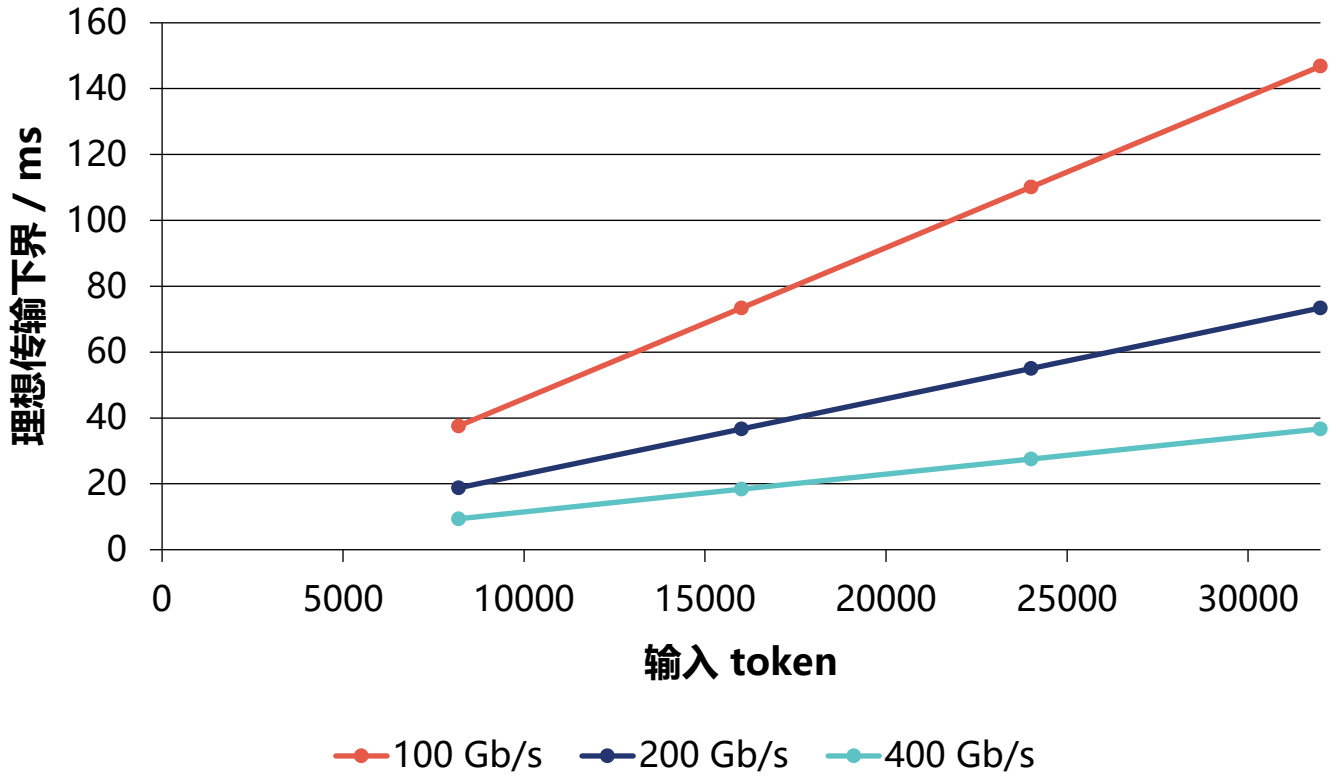
先满足单实例显存与时延，再复制实例扩吞吐；跨节点 TP 的通信成本必须与拆池传输一起测。

P/D 解耦将调度、KV 交接与输出流组成闭环



计算路径、KV数据路径、取消与租约控制路径分别限流；Decoder接管成功后才释放源端驻留。

网络线速给出下界，交接开销决定真实 TTFT



8,192 token → 448 MiB
100 Gb/s：37.6 ms
200 Gb/s：18.8 ms
400 Gb/s：9.4 ms

T交接 = 分配 + 协议 + 拷贝 + 完成检测 + 排队

公式按100%线速、无争用计算；实测要包含GPU↔NIC路径、主机中转、块布局变换和并发传输。

路由在缓存命中与队列等待之间做显式权衡

首 token 前主要开销：排队 + 未命中 Prefill + KV 交接

候选实例（示例）	缓存命中	排队 / 执行 / 交接	首 token预计
A：会话亲和	6,144 token	0.80 + 0.20 + 0.02 s	1.02 s
B：空闲副本	0 token	0.05 + 0.65 + 0.02 s	0.72 s
路由动作	选B并更新会话位置	携带相同token IDs、模型和模板版本	优先满足deadline

会话状态：conversation_id → 模型版本 → token前缀哈希 → KV位置 / 租约

多轮回传 KV 时必须保持聊天模板与实际 token 前缀一致；删除历史推理片段会破坏缓存语义。

资源池按瓶颈独立扩展，拓扑优先级进入调度

节点 1 · 同机高速互联

P分片
同层KV生产

D分片
同层KV消费

对应层KV留在本节点；PP激活跨节点

节点 2 · 同机高速互联

P分片
同层KV生产

D分片
同层KV消费

对应层KV留在本节点；PP激活跨节点

跨节点网络：测量端到端有效带宽与拥塞。
DistServe在25Gb/s跨节点测试床将对应阶段P/D配对到同节点；拓扑约束改变最优并行组合。

公开结果的比较单元必须固定模型、负载和 SLO

DistServe 2024	vLLM基线	DistServe	条件
代码补全 / OPT-66B	1.0×请求率	5.7×请求率	HumanEval；TTFT125ms / TPOT200ms
文档摘要 / OPT-66B	1.0×请求率	4.3×请求率	LongBench；TTFT15s / TPOT150ms
统一口径	每GPU达标请求率	目标达标率90%	FP16；A100-80GB；Poisson到达

MLPerf Server：带延迟约束的随机到达
MLPerf Offline：批量到达，优化总吞吐

采购复测锁定：模型/精度/准确率门槛
输入输出分布/硬件数/场景/计量单位

长上下文助手应重放自己的8K/32K分布；DistServe摘要输入受OPT窗口约束，被截到2,048 token。

失败恢复先保护流式语义，再选择重算或重试



重试共享总预算并加入退避与抖动；Decode故障同时影响多个Prefill源时，限流可阻断重试风暴。

把端到端 SLO 拆到队列、计算、传输与回收

层级	核心指标	联动诊断
用户边界	TTFT / 请求TPOT / ITL / 联合达标率	按输入长度、租户、热冷缓存分桶
调度	等待请求、队列token、抢占次数	排队升高且GPU未满：查准入或通信阻塞
GPU / KV	活跃序列、KV占用、前缀命中token	高抢占 + 低命中：查增长预留和缓存抖动
传输	字节、时长、失败、驻留	分离有效带宽与通知/排队时间
回收	取消耗时、泄漏块、重算请求	超时后仍占块会造成持续容量下降

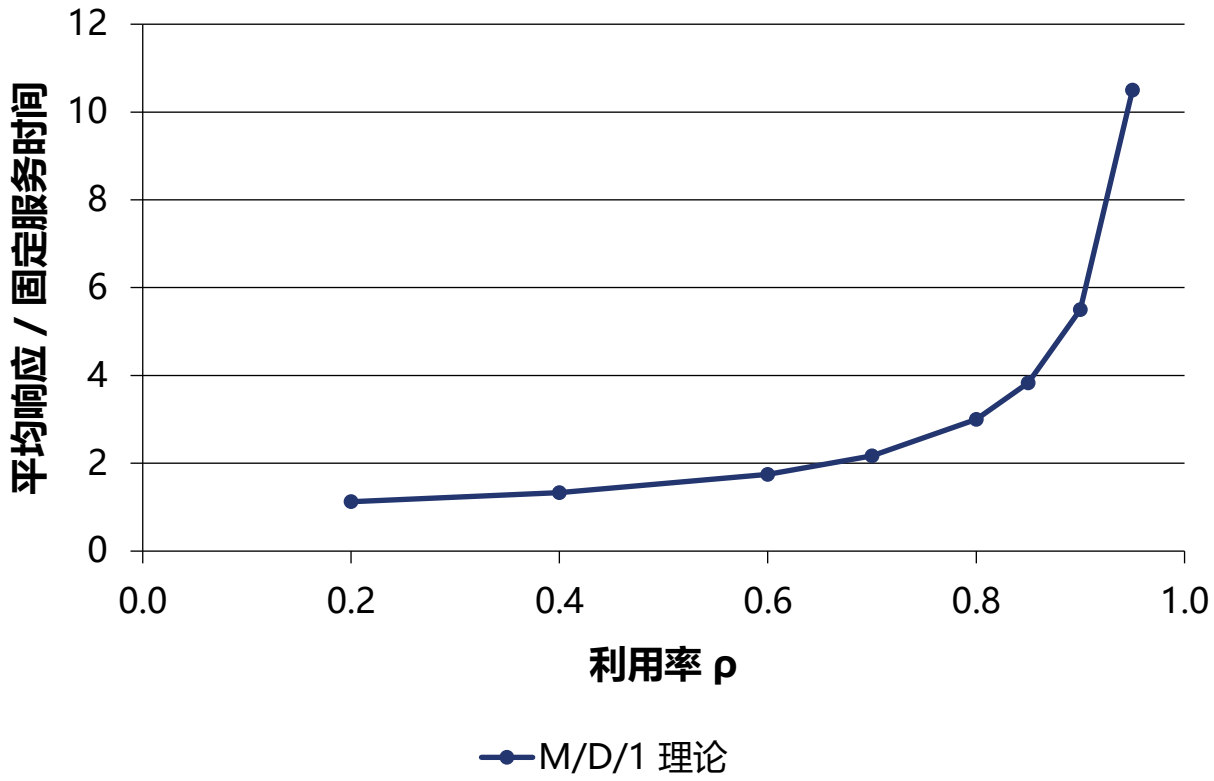
trace_id：接入 → 检索 → 排队 → prefill → transfer → decode → 结束/回收

指标分位数描述分布，trace解释个案；直方图桶应覆盖2s与40ms目标附近，避免聚合掩盖长尾。

容量边界对上下文长度与利用率都高度敏感

输入token	每会话KV上界	24GiB KV池上限
8,192	462 MiB	53
16,000	889 MiB	27
24,000	1,326.5 MiB	18
32,000	1,764 MiB	13

输出固定256 token；BF16 KV；
未计尾块、碎片与安全余量。



理论ρ从0.8升至0.95，平均响应从3倍升至10.5倍服务时间；扩容阈值应留在排队曲线拐点前。

成本除以有效工作量，重试和闲置才会显形

每千个达标请求成本 = 1,000 × 每小时总成本 / (3,600 × goodput)

设计算例（成本单位CU）	同机副本	P/D池
GPU + CPU/网络每小时费用	2×1 + 0.2 = 2.2 CU	2×1 + 0.4 = 2.4 CU
完成请求速率 / 联合达标比例	1.0 req/s / 80%	1.0 req/s / 95%
有效请求速率	0.80 req/s	0.95 req/s
每千个达标请求成本	0.764 CU	0.702 CU
与同机成本相等所需达标率	80%	87.3%（相同完成速率）

若解耦达标率低于87.3%，这组算例的额外运行费用尚未被有效产出抵消；成本门槛应进入压测。

上线用相同流量回放逐步验证，并保留同机回退池

01 正确性

冻结模型、tokenizer与聊天模板。

冷/热缓存输出对齐；检查跨租户隔离、引用与取消语义。

02 性能边界

同GPU预算对照
独立副本与P/D。

扫描长度与到达率、
前缀命中和突发；
测量联合达标率。

03 故障演练

注入慢链路、进程退出与租约过期。

确认重试受控，
故障后KV块已回收，
输出没有重复拼接。

04 灰度与回退

从小流量逐档放量。

达标率或错误率越线，
立即切回同机池；
保留完整链路追踪。

设计示例放量门槛：每档至少覆盖一个业务高峰；联合SLO≥95%，并核对正确性与每千达标请求成本。

先消除浪费，再用解耦隔离确证的阶段干扰

测到的主瓶颈	优先动作	转向下一步的证据
模型或KV放不下	量化/模型并行/长度与并发预算	保留质量目标后，内存与延迟稳定
重复前缀计算多	前缀缓存 + 版本/权限一致的路由	命中token上升，排队与prefill耗时下降
长prefill使输出卡顿	先调chunked-prefill；同预算对照P/D	真实KV交接开销小于TTFT余量
到达量超过单实例容量	复制实例；P与D按各自队列扩池	联合SLO与单位有效成本同时改善

架构选择的三条硬边界

显存容纳完整活跃状态 • 网络交接落在TTFT预算内 • 有效吞吐足以覆盖运营成本

容量：128k 上下文把显存并发压至 3 路

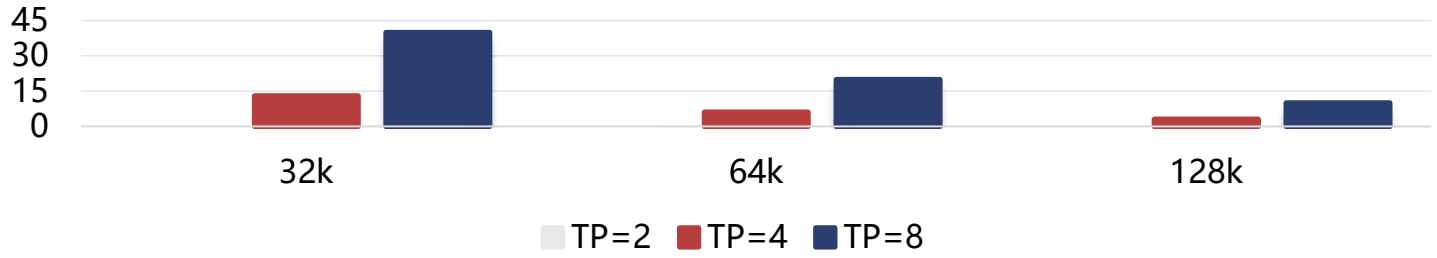
长上下文推理集群：容量、排队与能耗如何共同决定部署方案 · SKILL应用测试

一副本 = 4 × H100 SXM；BF16 权重预算 140 GB



GiB / 副本

可同时驻留的完整序列数



KV 随总长度线性增长

2 × 80 层 × 8 KV 头 × 128 维
× 2 byte = 320 KiB / token

32k / 64k / 128k
每序列占 10 / 20 / 40 GiB

接纳规则直接绑定显存

可用 KV = 4 × 80 GB − 140 GB
− 4 × 8 GiB = 135.6 GiB

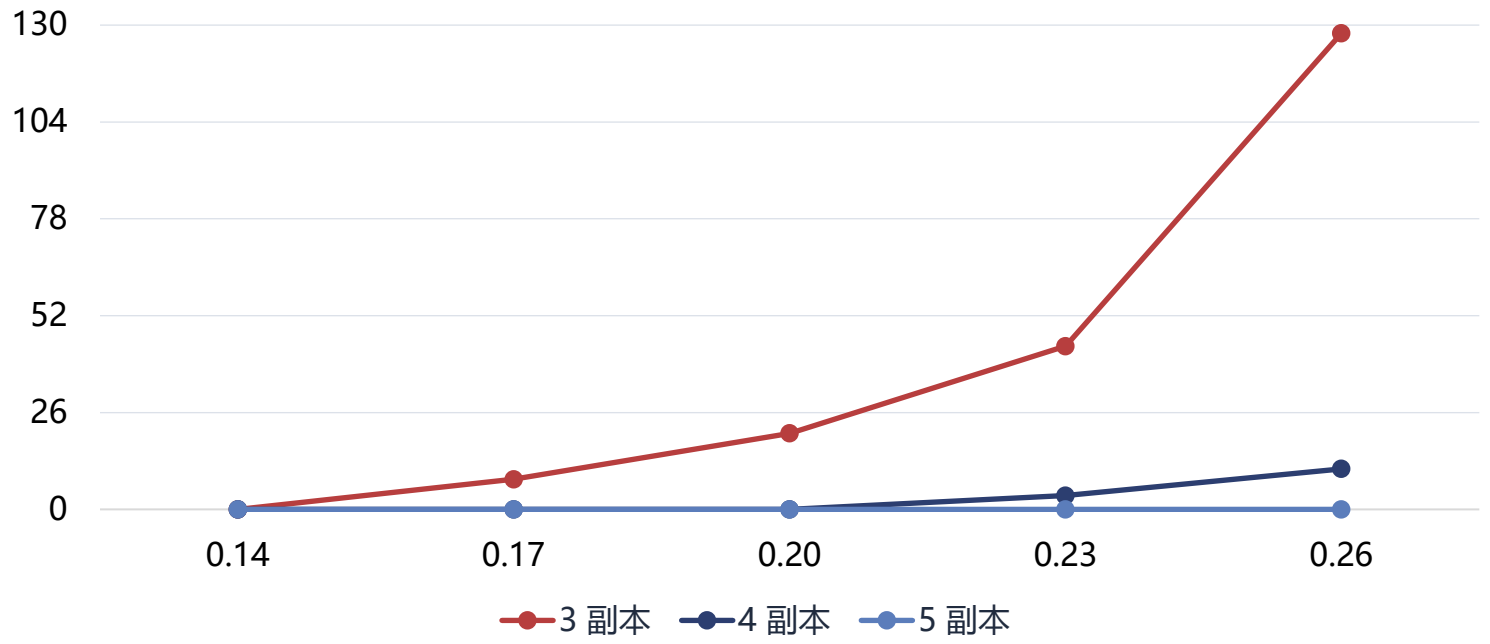
并发上限 = floor(135.6 / 40)
128k：3 路；留存余量 15.6 GiB

部署含义：先按“输入 + 最大输出”预留 KV；TP=4 的 128k 请求每副本最多接纳 3 路。

排队：85% 占用率已把尾部等待放大

128k 固定长度规划情景：每副本 3 个服务槽；平均驻留 32 s；到达率 λ = 0.24 请求/s

队列等待 p95（秒）随流量陡升



横轴：到达率（请求/s） · 目标：队列等待 p95 ≤ 10 s

扩容应在排队拐点之前

副本 / GPU	占用率	等待 p95
3 / 12	85.3%	58.5 s
4 / 16	64.0%	5.9 s
5 / 20	51.2%	0.0 s

M/M/c：$c = 3r$；$\rho = \lambda \times 32 / c$

$P(Wq>t)=C\cdot\exp[-(c/32-\lambda)t]$

$Wq95=\max[0,\ln(C/0.05)/(c/32-\lambda)]$

C 为 Erlang C 等待概率。

Poisson 到达；指数服务；FCFS。

32 s 驻留须用并发回放校准。

4 副本把占用率降至 64%，p95 等待降至 5.9 s；流量 +20% 时应重算接纳与副本数。

架构：拆分预填充前，先算 KV 搬运时间

DistServe（OSDI 2024）分离 Prefill / Decode，以减少阶段干扰；新成本是 KV 传输与额外权重副本

路由、接纳与两阶段资源池

接纳 / 路由
按长度分池；预留最大 KV

↓

Prefill 池
分块预填充；缓存公共前缀

↓

Decode 池
维持 TPOT；按 KV 余量接纳

KV 传输：Prefill 完成后进入 Decode 池

一次完整 KV 搬运的时间（秒）

总长度	100 Gb/s	200 Gb/s	400 Gb/s
32k	1.23	0.61	0.31
64k	2.45	1.23	0.61
128k	4.91	2.45	1.23

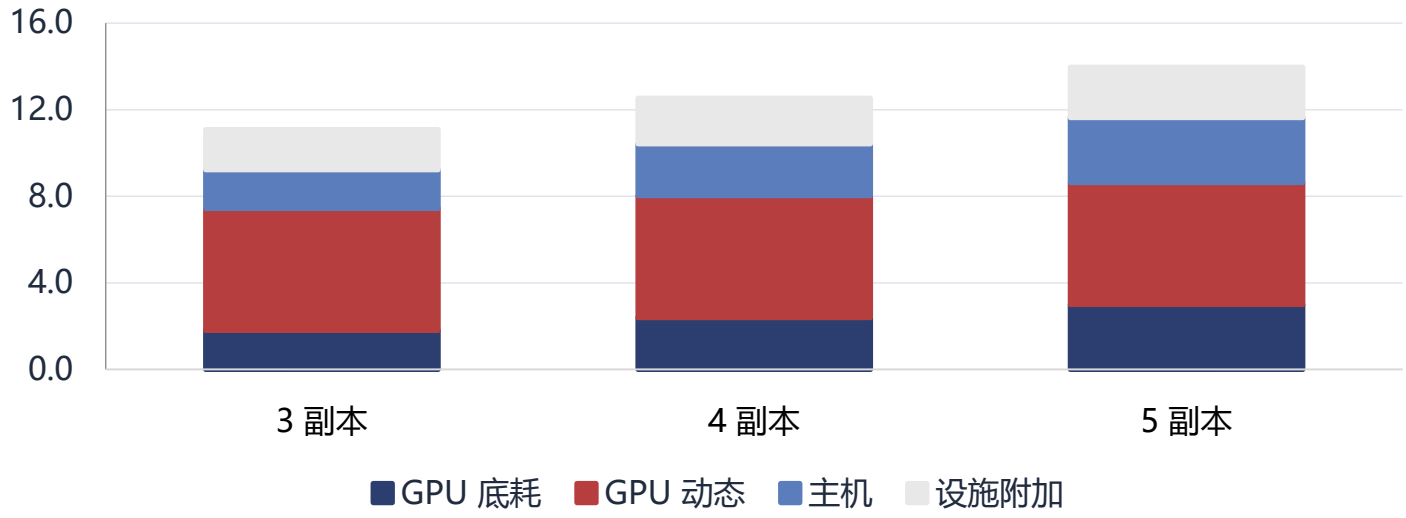
T = KV字节 / (带宽 ÷ 8 × 70%)
128k：42.95 GB / 35 GB/s = 1.23 s
λ = 0.24 时平均搬运 82.5 Gb/s；
2 倍突发需 164.9 Gb/s 有效吞吐。

若 TTFT 预算为 2 s，400 Gb/s 搬运已占 1.23 s；先测阶段干扰，再决定拆分与缓存复用。

能耗：16 张卡落在延迟与电力交集

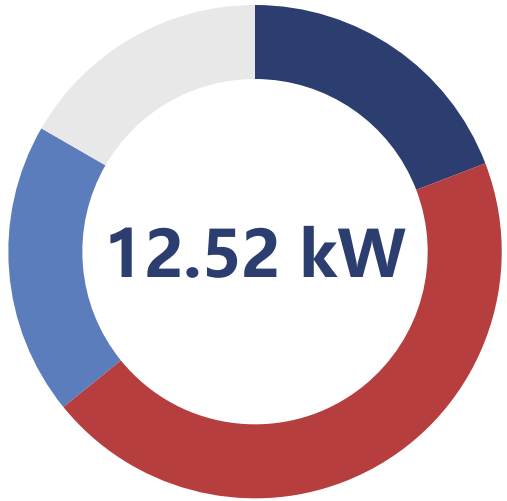
同一到达率 0.24 请求/s；功率随占用线性变化；GPU 150–700 W、主机 0.6 kW/副本、PUE = 1.20（假设）

副本越多，闲置与主机底耗越高



设施侧功率（kW） · 电力上限 13 kW

4 副本：电力构成



14.49 kWh / 千请求

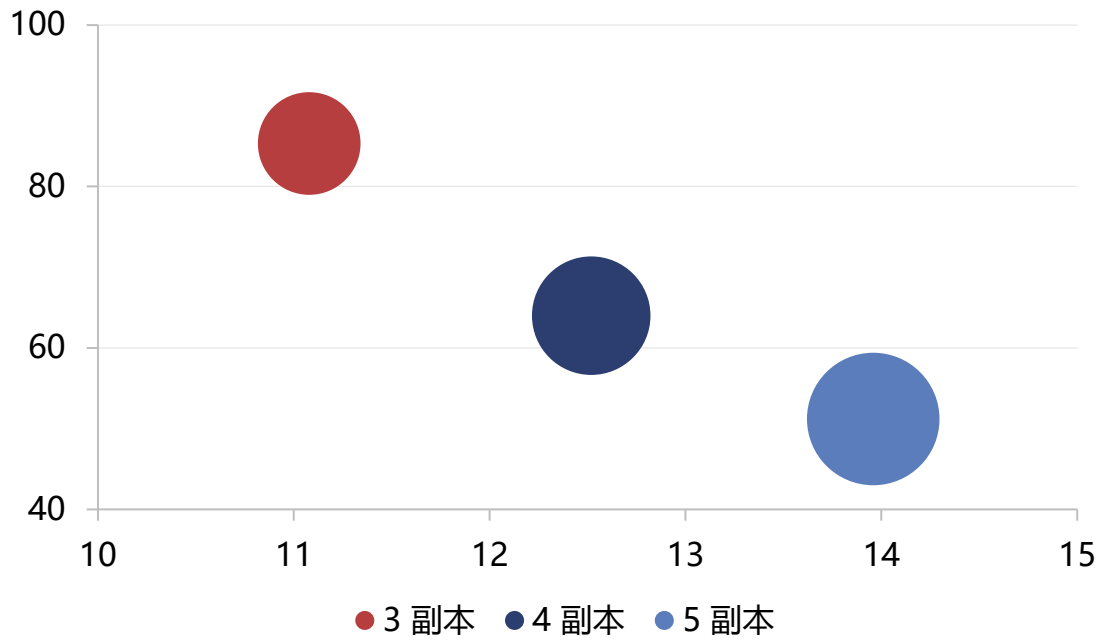
$P = 1.2 \times r \times [4 \times (0.15 + 0.55\rho) + 0.6]$ kW；每千请求用电 $E = P / (3.6\lambda)$。

3 副本超出等待 SLO；5 副本需 13.96 kW；4 副本在本情景满足 10 s 等待与 13 kW 电力约束。

部署：以 4 副本起步，把容错预算单列

容量、等待与功率共用同一输入：128k、3 槽/副本、32 s 驻留、0.24 请求/s；气泡面积代表服务槽数

占用率—功率决策平面



纵轴：槽占用率（%） · 横轴：设施功率（kW）

上线闸门：回放与容错一起过

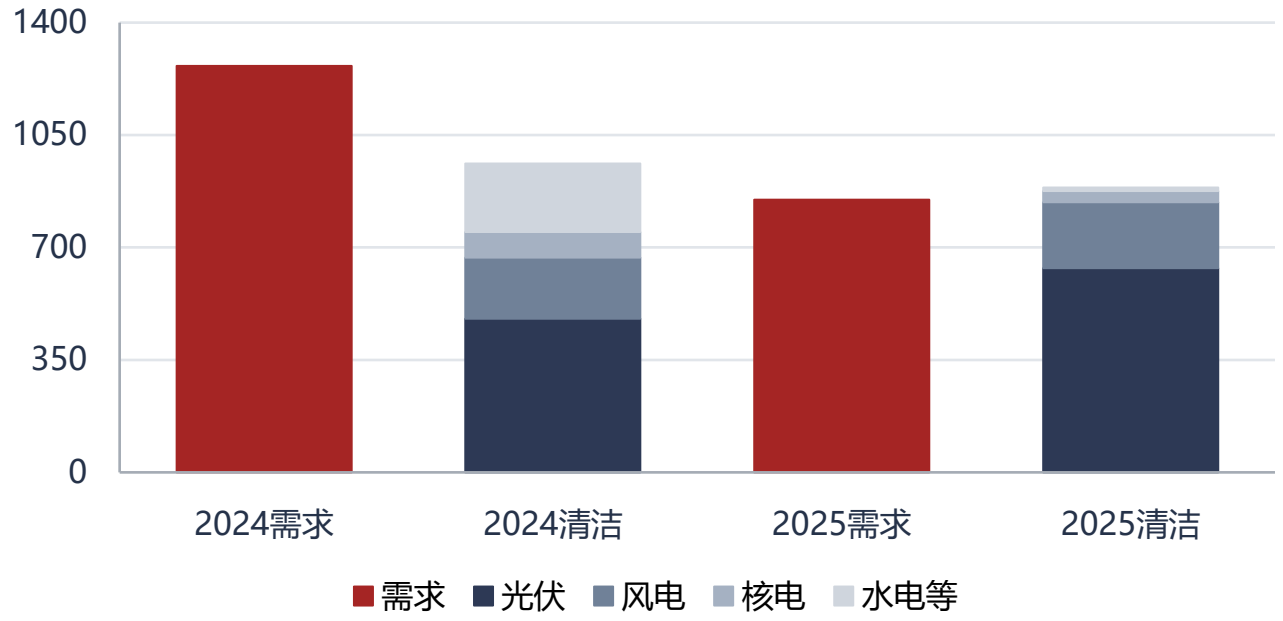
方案	GPU	等待 p95	功率/kW	判断
3 副本	12	58.5 s	11.08	等待超标
4 副本	16	5.9 s	12.52	正常推荐
5 副本	20	0.0 s	13.96	电力超标

① 按 32k / 64k / 128k 分桶回放，核对 TTFT、TPOT、KV 峰值与达标吞吐。
② N−1 需 5 副本、约 14 kW 电力预算。
③ +20% 流量使 4 副本等待 20.6 s、功率 13.87 kW；13 kW 下限流 0.256/s。

决策顺序：长度预算决定槽数；回放校准驻留时间；排队选副本；最后同时校验功率与 N−1。

全球化石发电微降，风光扩张与需求降速共同促成拐点

全球年度增量（TWh；2025 为估计值）



2025：清洁增量覆盖需求的 104.5%

全球增量（TWh）	2024	2025
需求	+1,265	+849
清洁发电	+962	+887
化石发电	+303	−38

清洁发电增量同比少了 75 TWh；需求增量减少 416 TWh，供需差额因此跨过零点。
风光合计新增 841 TWh，
覆盖需求增量的 99.0%。

光伏 +636 TWh
贡献清洁发电增量的 71.7%

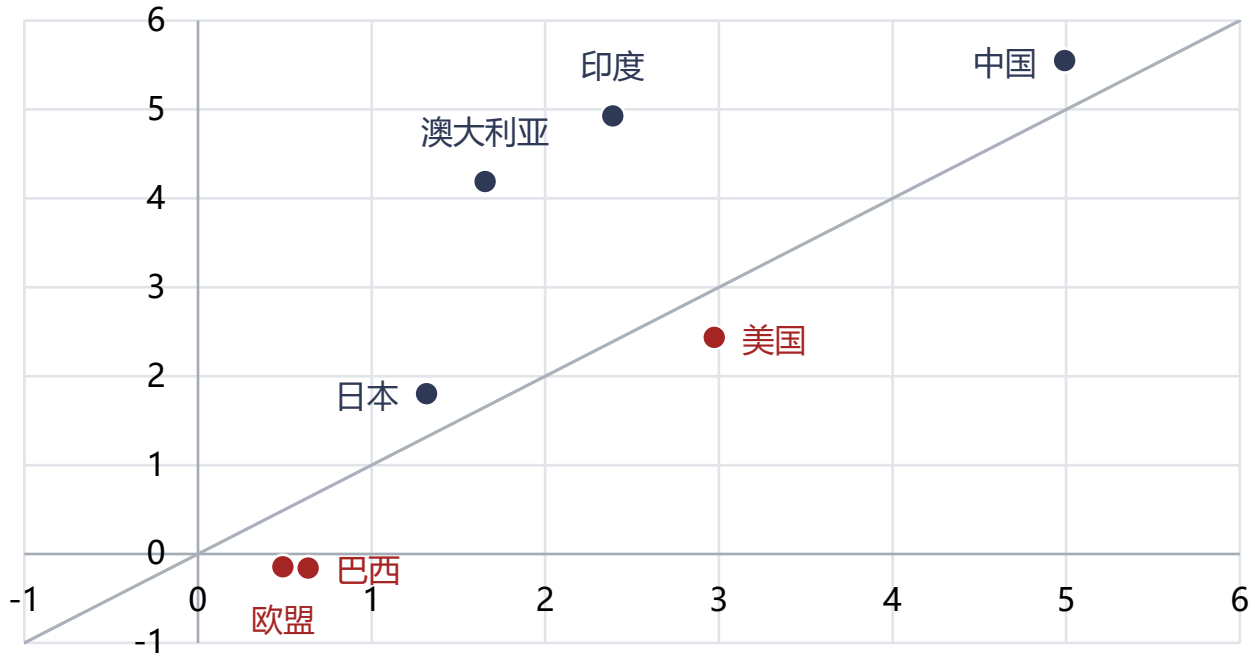
煤电 −63，气电 +36 TWh
煤电下降被气电增长部分抵消

2025 年化石发电 −0.21%
全球年发电量仍有 57.4% 来自化石

中印跨过替代门槛，美欧仍由化石发电填补缺口

2025 增量占 2024 需求的比例（%）

纵轴：清洁发电 + 净进口；横轴：需求



主要系统增量分解（TWh）

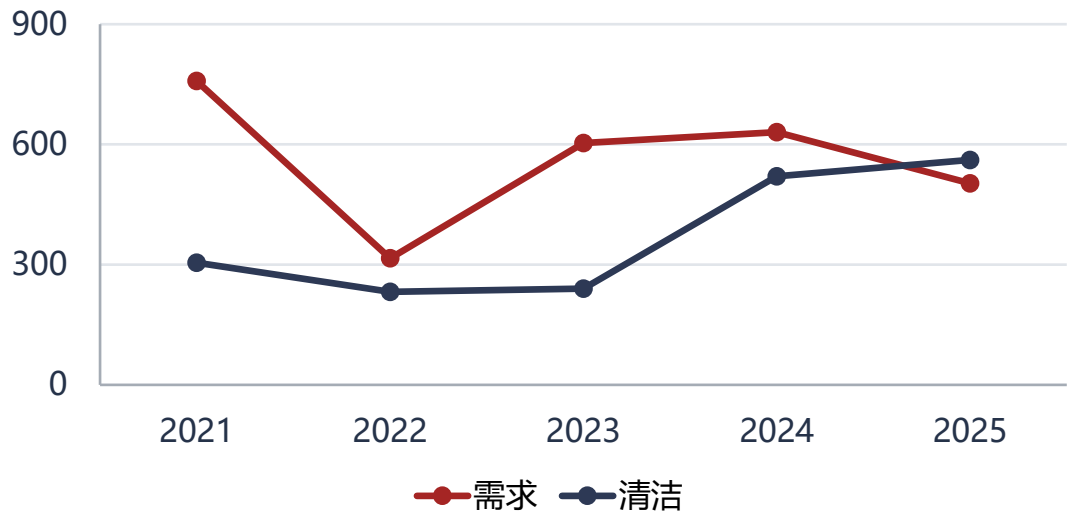
地区	需求	清洁	进口	化石
中国	+503	+561	−2	−56
印度	+49	+97	+4	−52
美国	+131	+105	+2	+24
欧盟	+14	+6	−10	+18

中印合计减少化石发电 108 TWh；
美欧合计增加 41 TWh。
对角线上方出现净替代，差距由清洁、需求和跨境电力的变化共同决定。

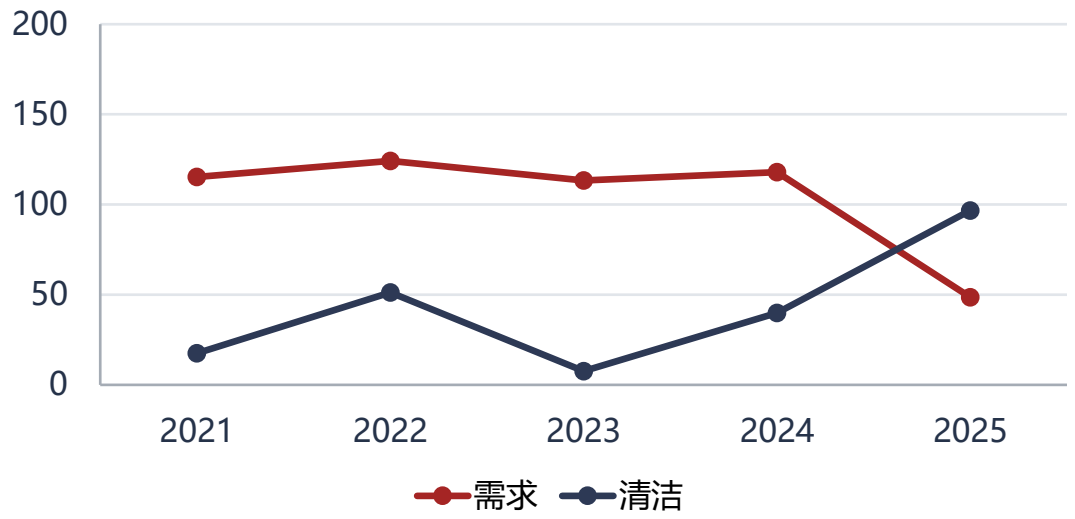
电量平衡：Δ化石 = Δ需求 − Δ清洁 − Δ净进口；净进口增加为正，净出口增加为负。

中国靠风光规模跨线，印度同时获得需求降速与水电助力

中国：年度电量增量（TWh）



印度：年度电量增量（TWh）

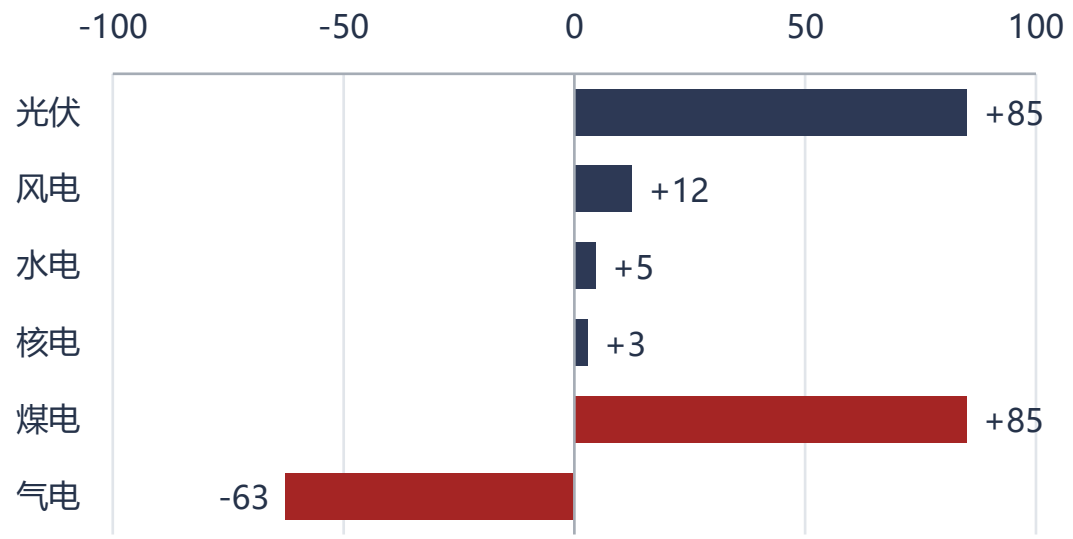


中国 | 清洁 +561，需求 +503 TWh
光伏 +336、风电 +138，合占清洁增量 84%。
水电 +45、核电 +37；净出口增加 2.5 TWh。
最终化石发电减少 56 TWh。

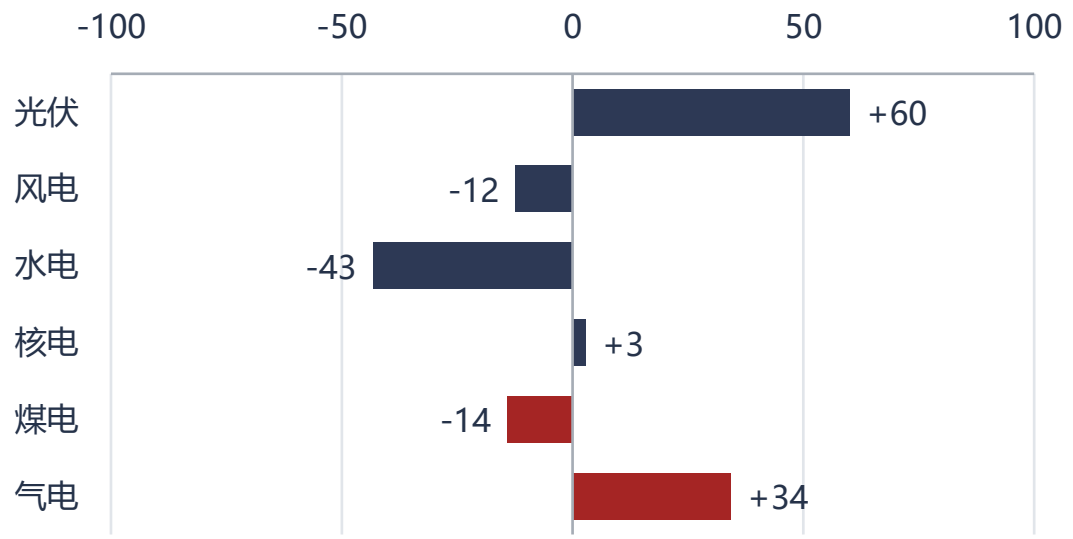
印度 | 清洁 +97，需求 +49 TWh
光伏 +53、风电 +22、水电 +21 TWh。
需求增速从 6.2% 降至 2.4%，温和天气压低制冷需求。
净进口多 3.5 TWh，化石发电净减 52 TWh。

美国需求快于清洁增长，欧盟水电回落吞噬光伏增量

美国：2025 主要电源增减（TWh）



欧盟：2025 主要电源增减（TWh）



美国 | 需求 +131 > 清洁 +105 TWh
光伏增加 85 TWh，覆盖约 65% 的需求增量。
煤电 +85、气电 −63 TWh，化石总量增加 24 TWh。

欧盟 | 光伏 +60，被水电 −43 与风电 −12 抵消
清洁 +6、需求 +14、净出口 +10 TWh。
气电增加 34 TWh 补位，煤电减少 14 TWh。

持续替代要同时扩大清洁发电、管理需求并平滑时空错配

全球下一年度化石发电变化（TWh）

情景演算：2025 需求为基数；各列为清洁增量

需求增速	+800	+1,000	+1,200
2%	−164	−364	−564
3%	+153	−47	−247
4%	+471	+271	+71

维持 2025 年的清洁增量（887 TWh）时，
全球需求增长 2.79% 即耗尽替代余量。
清洁每增加 100 TWh，或需求每减少 100 TWh，
化石发电就相应减少 100 TWh。

把年度新增量转成稳定的替代能力

01 扩大有效发电量
中国风光新增 474 TWh 是全球替代的主力；建设进度应与并网、输电和利用小时一起管理。

02 控制新增负荷的尖峰
印度较低需求增速帮助清洁电力覆盖增长；工业能效、制冷效率和可调负荷共同影响需求门槛。

03 补足天气与小时缺口
欧盟水电少 43 TWh，跨区互济、储能和稳定清洁电源共同填补缺口，考核减少的煤气电量。

替代进度的核心读数：清洁增量 − 需求增量 + 净进口增量；全球净进口项为零。

继承先建立子对象，再提供基类视图

C++17 • 类定义

```
struct Base {
  int id = 7;
  const char* kind() const { return "Base"; }
  virtual const char* speak() const {
    return "Base";
  }
  virtual ~Base() = default;
};
struct Derived : public Base {
  int score = 90;
  const char* kind() const { return "Derived"; }
  const char* speak() const override {
    return "Derived";
  }
};
```

main 内：引用和指针绑定同一个对象

```
Derived d;
Base& r = d;
Base* p = &d;
```

类关系：派生类指向基类



d 的逻辑子对象结构



r.score 编译错误：成员查找使用 Base 接口。

虚调用选择实现，按值复制改变对象

main 内：沿用上一页的 Base / Derived

```
Derived d;
Base& r = d;
Base* p = &d;
r.kind();
r.speak();
p->speak();
r.Base::speak();
Base copy = d;
copy.speak();
```

按值复制会切片

d：Derived 对象
Base 部分 + score

按值复制 →

copy：Base
id = 7

override 核对覆盖签名；
参数或 const 不匹配会触发编译诊断。

表达式的返回值与选择依据

表达式	返回	选择依据
r.kind()	Base	非虚，按 Base 类型
r.speak()	Derived	虚调用，动态类型是 Derived
p->speak()	Derived	同一个 d，经指针调用
r.Base::speak()	Base	显式限定，调用 Base 实现
copy.speak()	Base	copy 是独立 Base 对象

成员查找先检查静态类型的接口。
未显式限定的虚调用，再选择动态类型的最终覆盖者。

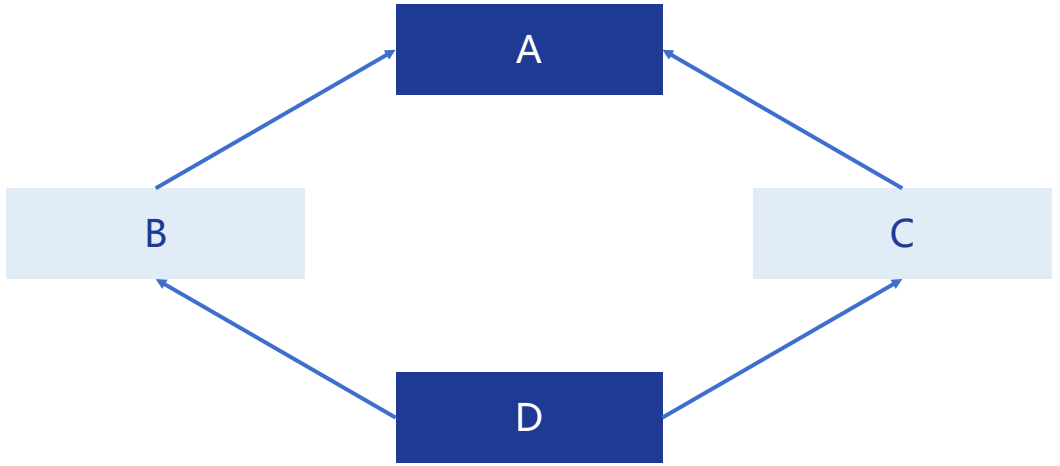
经 Base* 删除动态创建的 Derived 时，
虚析构使派生析构链执行。

普通菱形：两条路径保留两份 A

C++17 • 类定义与构造日志（包含 <iostream>）

```
struct A {
  int id;
  explicit A(int n) : id(n) {
    std::cout << "A(" << id << ") ";
  }
};
struct B : A {
  B() : A(1) { std::cout << "B "; }
};
struct C : A {
  C() : A(2) { std::cout << "C "; }
};
struct D : B, C {
  D() { std::cout << "D\n"; }
};
```

继承关系：箭头由派生类指向基类

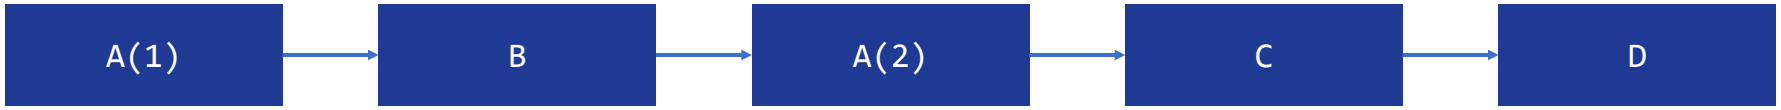


按声明顺序构造 B、C；各自先构造自己的 A。

B::A：id = 1　　**C::A：id = 2**

编译错误：A& a = d;
原因：从 D 到 A 的基类转换有歧义。

D d; 的输出



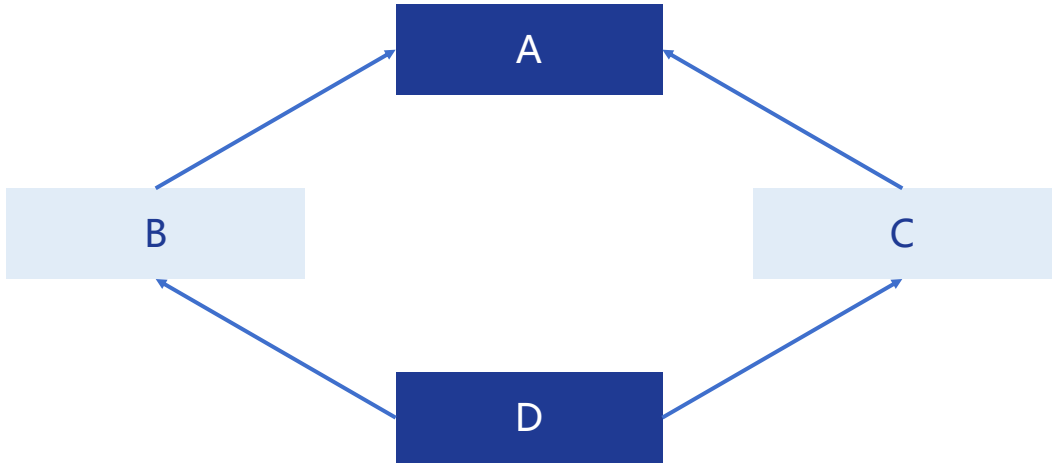
虚继承：共享 A，由最派生类初始化

C++17 • 类定义与构造日志（包含 <iostream>）

```
struct A {
  int id;
  explicit A(int n) : id(n) {
    std::cout << "A(" << id << ") ";
  }
};
struct B : virtual A {
  B() : A(1) { std::cout << "B "; }
};
struct C : virtual A {
  C() : A(2) { std::cout << "C "; }
};
struct D : B, C {
  D() : A(9) { std::cout << "D\n"; }
};
```

D 构造时，B/C 的 A 初始化器被忽略。
单独构造 B：A(1) 生效。

继承关系：箭头由派生类指向基类



先构造虚基类 A，再按声明顺序构造 B、C。

共享 A：id = 9；经 B、C 转成 A* 后指针相等

D d; 的输出



共享 A 的虚函数需要唯一最终覆盖者

C++17 • A 提供虚函数，D 统一覆盖

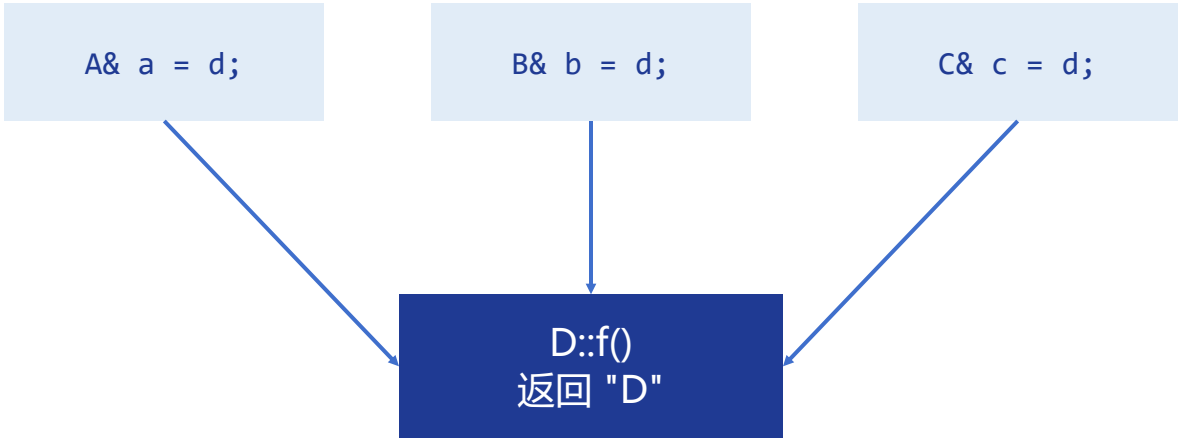
```
struct A {
  virtual const char* f() const { return "A"; }
  virtual ~A() = default;
};
struct B : virtual A {
  const char* f() const override { return "B"; }
};
struct C : virtual A {
  const char* f() const override { return "C"; }
};
struct D : B, C {
  const char* f() const override { return "D"; }
};
```

显式限定可直接调用某一路实现

```
D d;
d.B::f();  // returns "B"
```

先辨认“有几份基类子对象”，再检查“虚函数最终由谁覆盖”。

同一个 D 对象，三种基类引用



若 D 没有覆盖 f，B::f 与 C::f 同时成为候选；
共享 A 的最终覆盖者不唯一，类定义编译失败。

virtual 函数 选择调用实现	virtual 继承 共享基类子对象

用矩阵把问题写清楚

求 J 的最小值：参数 β 改变线性项，第二个变量必须非负。

LaTeX 源码

```
\[
Q=\begin{pmatrix}2&1\\1&2\end{pmatrix},\qquad
b=\begin{pmatrix}3\\\beta\end{pmatrix},\qquad
x=\begin{pmatrix}x_1\\x_2\end{pmatrix}.
\]
\begin{equation}\label{eq:objective}
J(x)=\frac12 x^{\mathsf T}Qx-b^{\mathsf T}x,
\qquad x_2\ge0.
\end{equation}
```

排版结果

$$Q=\begin{pmatrix}2&1\\1&2\end{pmatrix},\qquad b=\begin{pmatrix}3\\\beta\end{pmatrix},\qquad x=\begin{pmatrix}x_1\\x_2\end{pmatrix}.$$

$$J(x)=\frac12 x^{\mathsf T}Qx-b^{\mathsf T}x,\qquad x_2\ge0. \tag{1}$$

导言区加载宏包
\usepackage{amsmath}

曲率
Q 的特征值为 1 和 3

可行域
$x_2 \ge 0$，最优解唯一

align：让驻点条件逐行可追踪

LaTeX 源码

```
\begin{align}
\nabla J(x)&=Qx-b=0
  \label{eq:stationary}\\
2x_1+x_2&=3 \notag\\
x_1+2x_2&=\beta
  \label{eq:system}
\end{align}
\[
x^{\mathrm u}=
\begin{pmatrix}2-\beta/3\\2\beta/3-1\end{pmatrix}.
\]
```

排版结果

$$\nabla J(x) = Qx - b = 0 \tag{2}$$

$$2x_1 + x_2 = 3$$

$$x_1 + 2x_2 = \beta \tag{3}$$

$$x^{\mathrm{u}} = \begin{pmatrix} 2 - \beta/3 \\ 2\beta/3 - 1 \end{pmatrix}.$$

& 放在等号前形成对齐锚点；\\ 分行，\notag 去掉当前行的编号。

梯度为零 → 解出无约束候选 → 检查 x_2 是否非负

split：长推导保持一个编号

固定 $x_2 = t \geq 0$ → 按 x_1 最小化 → 得到一元函数 g(t)

LaTeX 源码

```
\begin{equation}\label{eq:reduced}
\begin{split}
g(t)&=J\!\left(\frac{3-t}{2},t\right)\\
&=\left(\frac{3-t}{2}\right)^2
  +\frac{3-t}{2}t+t^2\\
&\quad-3\frac{3-t}{2}-\beta t\\
&=\frac34t^2+
  \left(\frac32-\beta\right)t-\frac94.
\end{split}
\end{equation}
```

equation 给整段推导编号

$$
\begin{aligned}
g(t) &= J\left(\frac{3-t}{2}, t\right) \\
&= \left(\frac{3-t}{2}\right)^2 + \frac{3-t}{2}t + t^2 \\
&\quad - 3\frac{3-t}{2} - \beta t \\
&= \frac{3}{4}t^2 + \left(\frac{3}{2} - \beta\right)t - \frac{9}{4}.
\end{aligned} \tag{4}
$$

cases：约束决定分段解

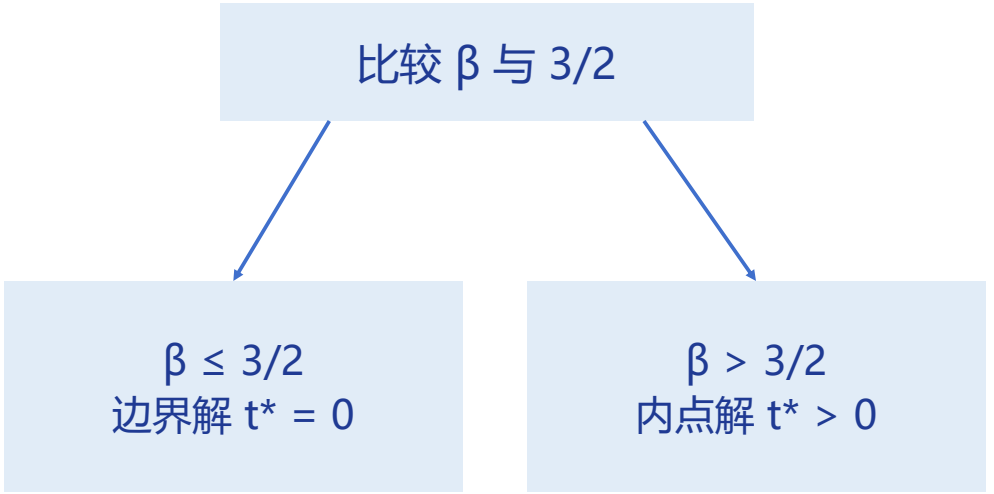
排版结果

$$t^* = \begin{cases} 0, & \text{if } \beta \le \frac{3}{2}, \\ \dfrac{2\beta - 3}{3}, & \text{if } \beta > \frac{3}{2} \end{cases}, \qquad x^* = \begin{pmatrix} (3 - t^*)/2 \\ t^* \end{pmatrix}. \tag{5}$$

g′(t) = 3t/2 + 3/2 − β
驻点 t = (2β − 3)/3。
驻点为负时，最小值取边界。

LaTeX 源码

```
\begin{equation}\label{eq:constrained}
t^*=\begin{cases}
0,&\text{if }\beta\le\frac32,\\[4pt]
\dfrac{2\beta-3}{3},&\text{if }\beta>\frac32
\end{cases},\qquad
x^*=\begin{pmatrix}(3-t^*)/2\\t^*\end{pmatrix}.
\end{equation}
```



编号与引用串起完整论证

驻点条件 (2)、(3) → 一元目标 (4) → 分段最优解 (5)

引用源码：标签随公式移动

```
From \eqref{eq:stationary} and \eqref{eq:system},
the unconstrained point is $x^{\mathrm u}=(2,-1)^{\mathsf T}$
when $\beta=0$.

Equation \eqref{eq:reduced} gives
$g'(t)=\frac32t+\frac32>0$ for $t\ge0$.

Thus \eqref{eq:constrained} yields
\[
x^*=\begin{pmatrix}3/2\\0\end{pmatrix},
\qquad J(x^*)=-\frac94.
\]
```

引用效果：自动生成括号和编号

From (2) and (3), the unconstrained point is $x^{\mathrm{u}} = (2, -1)^{\mathsf{T}}$ when $\beta = 0$.
Equation (4) gives $g'(t) = \frac{3}{2}t + \frac{3}{2} > 0$ for $t \geq 0$.
Thus (5) yields

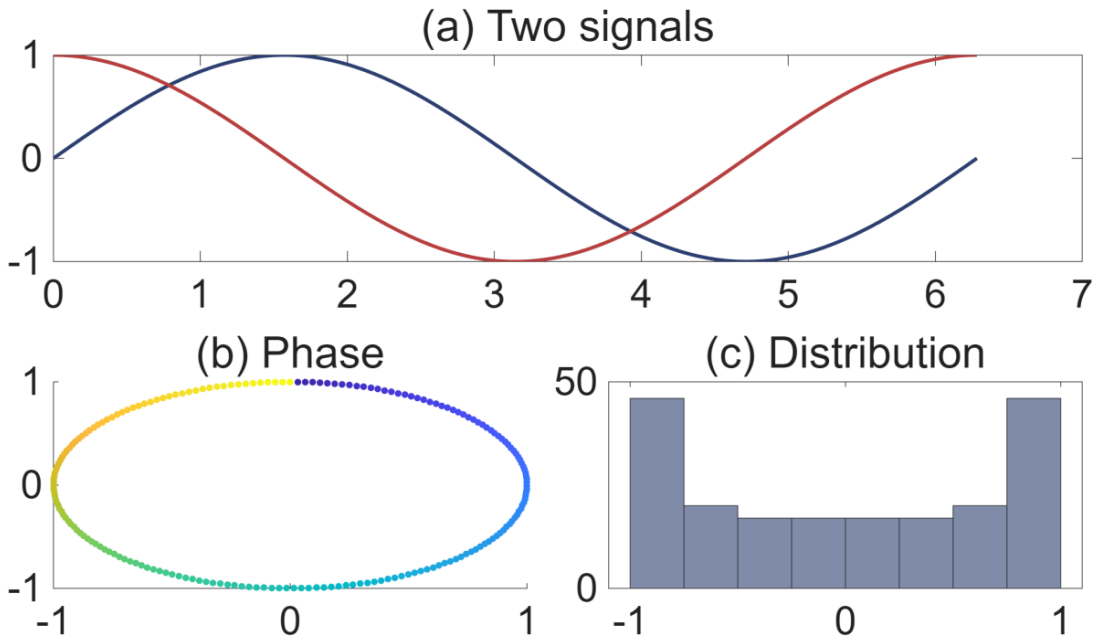
$$x^* = \begin{pmatrix} 3/2 \\ 0 \end{pmatrix}, \qquad J(x^*) = -\frac{9}{4}.$$

β = 0 时，无约束点 (2, −1) 不可行。
在 t ≥ 0 上，g′(t) > 0，边界点 (3/2, 0) 给出最小值 −9/4。

MATLAB tiledlayout

多面板科学绘图
从网格到完整图组

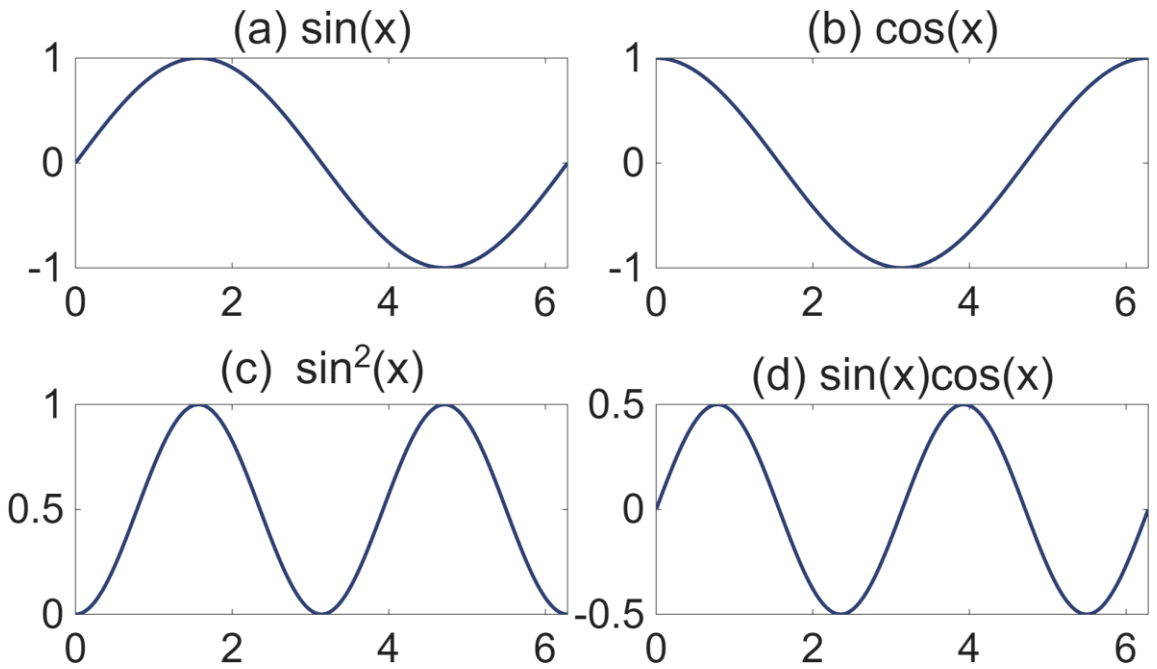
建立布局与坐标轴的层次关系
组合折线、相图与分布图
统一标签、范围与导出对象



作者：SKILL应用测试

先建网格，再逐格绘图

```
x = linspace(0,2*pi,200);
y = sin(x); z = cos(x);
t = tiledlayout(2,2);
nexttile(t); plot(x,y);
nexttile(t); plot(x,z);
nexttile(t); plot(x,y.^2);
nexttile(t); plot(x,y.*z);
t.TileSpacing = "compact";
t.Padding = "compact";
```

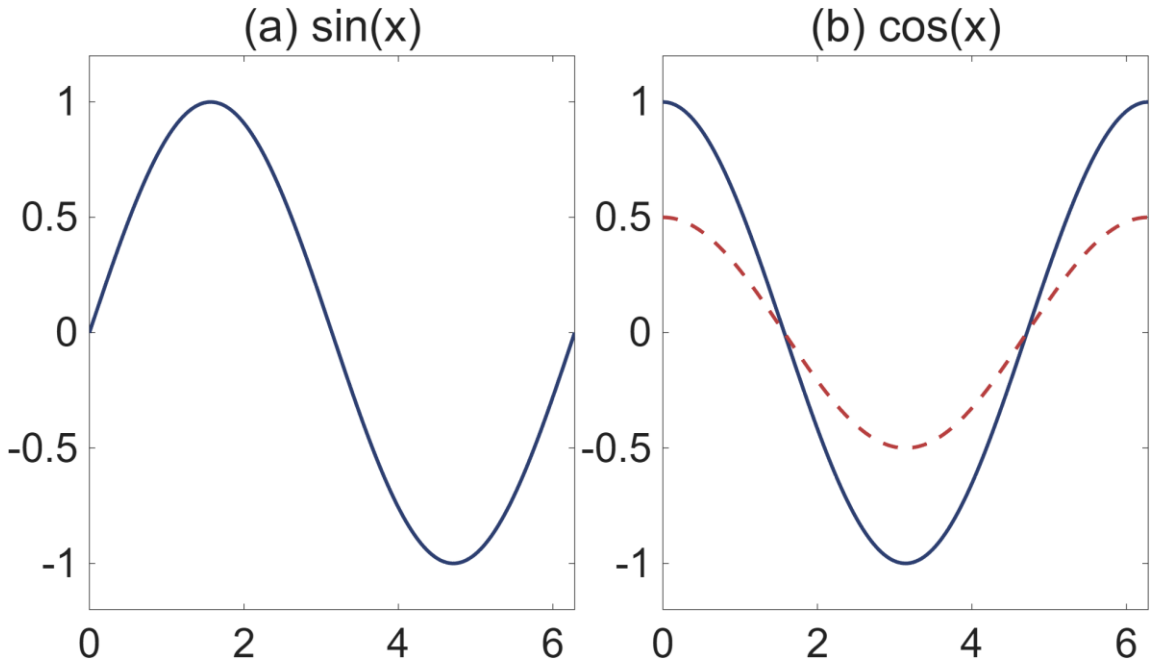


t 管理 2 行 × 2 列；nexttile 创建坐标轴。
默认逐行填充：左上、右上、左下、右下。

TileSpacing 控制图块之间的空隙；Padding 控制布局外围留白。

用坐标轴句柄精确控制图块

```
t = tiledlayout(1,2);
ax1 = nexttile(t,1);
plot(ax1,x,y);
ax2 = nexttile(t,2);
plot(ax2,x,z);
hold(ax2,"on");
plot(ax2,x,0.5*z,"--");
ylim(ax1,[-1.2 1.2]);
ylim(ax2,[-1.2 1.2]);
```

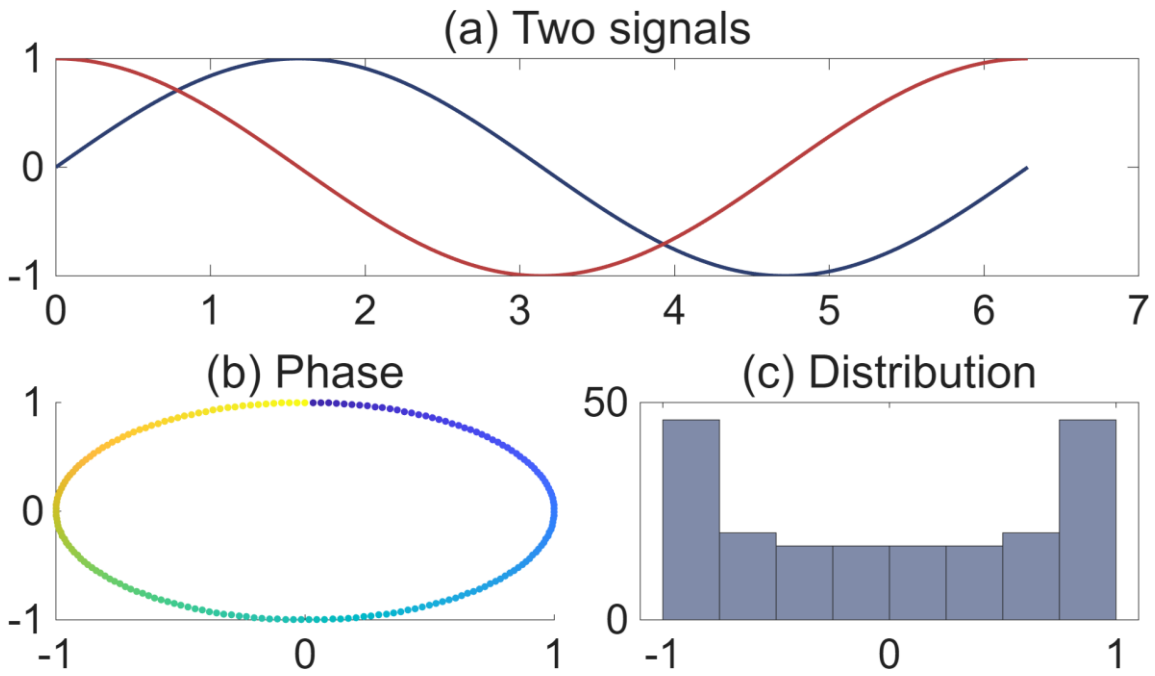


ax1、ax2 分别指向两个坐标轴。
hold(ax2,"on") 让虚线叠加到右侧图块。

多坐标轴场景显式传入 ax，后续 plot、title、ylim 都作用于目标图块。

跨格布局：主图与诊断图并置

```
t = tiledlayout(2,2);
nexttile(t,1,[1 2]);
plot(x,[y;z]);
nexttile(t,3);
scatter(y,z,22,x,"filled");
nexttile(t,4);
histogram(y,8);
```

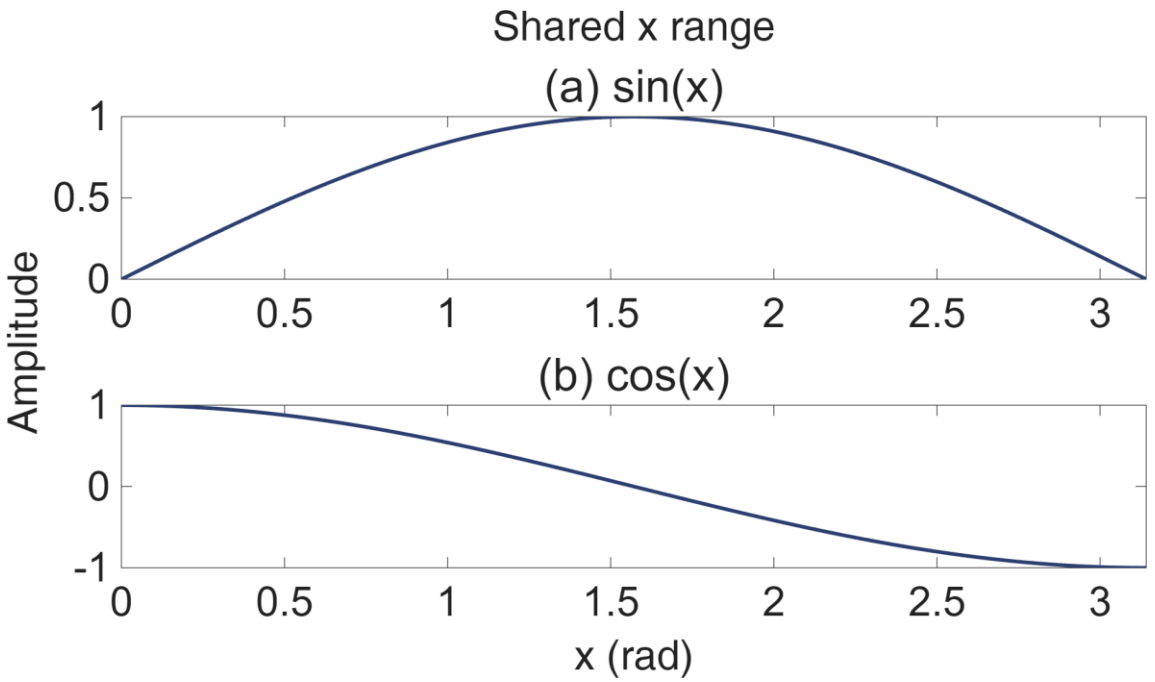


[1 2] 表示跨 1 行、2 列，起点为图块 1。
下排图块 3、4 保留给相图与直方图。

编号以原始网格为准；访问已跨格区域时，应保留相同起点与跨度。

共享标签，联动坐标范围

```
t = tiledlayout(2,1);
ax1 = nexttile(t);
plot(ax1,x,y);
ax2 = nexttile(t);
plot(ax2,x,z);
linkaxes([ax1 ax2],"x");
xlim(ax1,[0 pi]);
xlabel(t,"x (rad)");
ylabel(t,"Amplitude");
```

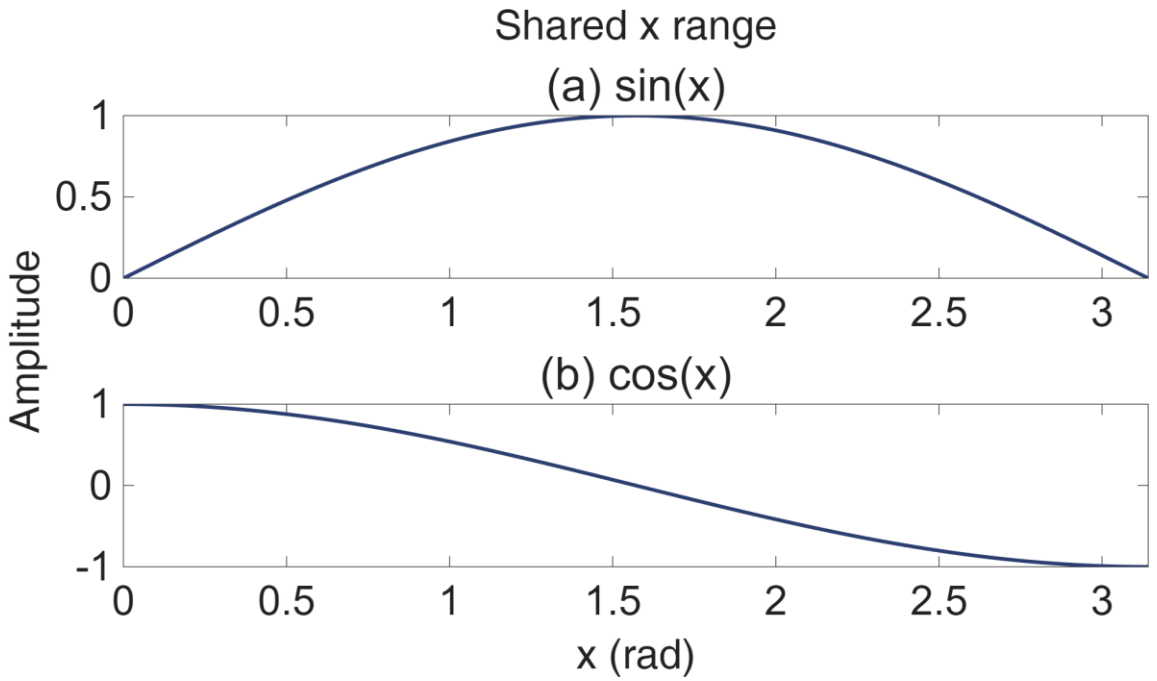


xlabel(t,...) 为整组添加共享标签。
linkaxes 联动范围；上下两图均显示 0 到 π。

共享标签只改变标注；统一尺度用 linkaxes，或分别设置 xlim / ylim。

导出整个布局，保留完整图组

```
exportgraphics(t,"figure.png", ...
    "Resolution",300);
exportgraphics(t,"figure.pdf", ...
    "ContentType","vector");
```



传入 t：保存全部图块与共享标签。
传入 ax：只保存一个坐标轴。
PNG 适合插图；矢量 PDF 适合放大与排版。

检查顺序：图块位置 → 轴范围与单位 → 标签和图例 → 最终导出尺寸。